



UNIVERSIDAD POLITÉCNICA DE MADRID (UPM)

Escuela Técnica Superior de Ingenieros Industriales

ANÁLISIS Y PREDICCIÓN DE LA LESIVIDAD EN ACCIDENTES DE TRÁFICO MEDIANTE LA APLICACIÓN DE RANDOM FOREST

TRABAJO DE FIN DE GRADO

Junio 2021

Grado en Ingeniería en Tecnologías Industriales

Especialidad Organización Industrial

Autor

Juan Herrera Briones

Tutores

José Manuel Mira McWilliams
M.ª Almudena Sanjurjo de No

AGRADECIMIENTOS

Me gustaría mostrar mi agradecimiento a mis tutores José y Almudena, por haberme dado la oportunidad de realizar este proyecto que ha despertado en mí tanto interés y, sobre todo, por haber estado dispuestos en todo momento a ayudarme y resolverme las diferentes dudas que se me iban planteando.

Por otro lado, quiero agradecer a mi familia el apoyo y motivación constantes que he sentido de su parte durante todos estos años y que, junto a su cariño, me han sido fundamentales en esta etapa de mi vida.

Por último, también quiero dar las gracias a todos mis amigos, tanto a los que he conocido en la Escuela como al resto, por haber estado a mi lado en las buenas y en las malas, y por haberme permitido disfrutar de grandes momentos a vuestro lado que nunca olvidaré.

RESUMEN

Introducción

La seguridad vial constituye uno de los ámbitos de mayor importancia y repercusión a nivel mundial, generando un enorme impacto, tanto social como económico, sobre cada uno de los diferentes estados. En el aspecto social, los accidentes de tráfico suponen una de las principales causas de fallecimientos, produciéndose alrededor de 1.350.000 muertes al año en todo el mundo por estos motivos, según la Organización Mundial de la Salud (OMS). Además, existe una desigualdad territorial en cuanto a este tipo de sucesos, siendo los países menos desarrollados los que sufren una mayor cantidad de siniestros viales y donde se alcanzan las cifras de mortalidad más altas. Por otro lado, en el aspecto económico, los países se ven obligados afrontar un gran desembolso como consecuencia de los accidentes de tráfico producidos, el cual representa aproximadamente un 2% de su PIB.

Todo ello motiva que se lleve a cabo un más que significante trabajo y esfuerzo constante por parte de los distintos organismos en la materia referida a la seguridad vial. En este aspecto, durante los últimos años han sido creadas y puestas en marcha numerosas campañas y planes de acción, con los que se ha conseguido lograr una reducción de la siniestralidad y mortalidad en las carreteras.

Bajo este contexto, surge el proyecto en cuestión, que busca analizar y predecir la lesividad que se alcanza en los accidentes de tráfico empleando técnicas de análisis de datos. Concretamente, se utiliza para ello la técnica del *Random Forest* (Bosque Aleatorio), que forma parte de la disciplina del *Machine Learning* (aprendizaje automático). Esta última se encuentra en auge actualmente, y se basa en la capacidad de aprendizaje de manera autónoma por parte de los sistemas a partir de una gran cantidad de datos, sin requerir de un trabajo constante paralelo que sea realizado por un ser humano.

Objetivos

El objetivo de este Trabajo de Fin de Grado es analizar y predecir la lesividad que se alcanza en los accidentes de tráfico según algunas de las características propias del siniestro. Para conseguirlo, se crean diversos modelos estadísticos de *Random Forest*, en los que la variable a predecir (variable respuesta o de salida) es la lesividad del accidente, mientras que las variables que condicionan dicha predicción (variables de entrada) son varias características del mismo.

Además, estos modelos generados van a permitir estimar la influencia o importancia de cada uno de los factores estudiados (variables de entrada) sobre la lesividad de los siniestros viales, de manera que sea posible conocer en qué aspectos es de más provecho trabajar con el objetivo de reducir la mortalidad de los accidentes de tráfico.

Metodología

Como se ha comentado anteriormente, para originar los distintos modelos predictivos del trabajo se emplea la técnica del *Random Forest*, incluida dentro de la disciplina del *Machine Learning*, y cuya creación se basa en los *CART* (*Classification and Regression Trees*).

Los Árboles de Clasificación y Regresión, también conocidos como *Classification and Regression Trees* (*CART*), permiten predecir, a partir de un conjunto de datos, el valor de una variable respuesta en función de ciertas características que se denominan variables de entrada. Estos árboles de decisión pueden ser de clasificación si la variable respuesta es de tipo categórico (solo puede tomar una serie concreta de valores), o de regresión si ésta es de tipo continuo (puede tomar cualquier valor).

Su formación tiene lugar mediante la realización de particiones o divisiones sucesivas del conjunto inicial de datos con el que se trabaja, dando lugar a diferentes regiones en las que se va obteniendo cada vez una mejor y más homogénea clasificación, facilitando la predicción.

Por otro lado, un modelo de *Random Forest*, denominado a su vez Bosque Aleatorio, está constituido por una gran cantidad de árboles de decisión, en cuya construcción han sido incorporadas ciertas fuentes de aleatoriedad, que han hecho disminuir la correlación existente entre los distintos árboles que forman el bosque y han incrementado la fiabilidad de las predicciones realizadas.

De esta forma, en los problemas de clasificación, el valor de la variable de salida predicho por el modelo es el de la clase más votada por todos los árboles que forman el bosque, mientras que, en los problemas de regresión, es la media entre las predicciones de todos los árboles. Por último, cabe destacar que esta técnica además permite medir la importancia de cada una de las variables en la salida del modelo.

Base de datos

La base de datos empleada en este proyecto fue elaborada a partir de fuentes de la Dirección General de Tráfico (DGT) y, posteriormente, fue tratada por la investigadora Almudena Sanjurjo de No. En ella, están representados los diferentes accidentes de tráfico producidos en vías interurbanas desde el año 2004 a 2013 entre dos vehículos. Así, cuenta con un total de

145.904 registros, sumado a 111 variables para cada uno de ellos que hacen referencia a ciertas características o factores específicos del accidente.

Procedimiento

Antes que nada, es preciso señalar que en este proyecto se trabaja con problemas de clasificación, ya que la variable respuesta es de tipo categórico y únicamente puede tomar una serie de valores concretos. Además, se emplea el lenguaje de programación R y el entorno estadístico *RStudio* para generar e implementar los diferentes algoritmos predictivos.

En primer lugar, se realiza una elección de las variables de la base de datos inicial que se consideran las más significativas en los accidentes de tráfico, y que van a ser las que se analicen y estudien en este trabajo. Estas variables son: *Lesividad, Localización (o existencia) de las lesiones más graves, Defecto físico previo, Condiciones psicofísicas, Sexo, Infracciones de velocidad, Infracciones administrativas, Infracciones del conductor, Estado del vehículo, Luminosidad, Factores atmosféricos* y *Tipo de accidente.* Entre ellas, se escoge la lesividad del accidente (*Lesividad*) como la variable a predecir, es decir, como la variable respuesta de los distintos modelos.

Posteriormente, se escogen los parámetros más importantes del algoritmo de *Random Forest*, procurando seleccionar un valor lo más idóneo posible para ellos. A su vez, se lleva a cabo una partición de la base de datos, en la que el 70% de sus observaciones pasan a formar el conjunto de datos para entrenamiento (*training set*), y el 30% restante el conjunto para pruebas (*test set)*. Éstos se utilizan para entrenar y generar el modelo, y para medir su fiabilidad realizando la validación cruzada, respectivamente.

A continuación, se procede a la generación de los modelos principales del trabajo, los cuales pretenden analizar y predecir la lesividad en los accidentes de tráfico, y constituyen el núcleo principal del proyecto.

- Para la creación del primer modelo, se realiza una normalización de las variables de entrada, que se convierten en variables binarias o ternarias. Por otro lado, la variable respuesta (la lesividad del accidente) puede tomar los siguientes valores: *1 = Muerto, 2 = Herido grave, 3 = Herido leve, 4 = Ileso, 5 = Se ignora*.

- En segundo lugar, se efectúa una modificación de la variable de salida, es decir, de la lesividad del accidente. Ésta pasa a ser una variable binaria que adquiere el valor *"1"* si se trata de un *muerto* o *herido grave*, o el valor *"0"* si es un *herido leve*. Las observaciones de clase *ileso* y *se ignora* se omiten. De esta forma, se genera el segundo modelo predictivo.

- Por último, para la elaboración del tercer y definitivo modelo principal del trabajo, se realiza un equilibrado de la base de datos utilizada en el modelo anterior, de manera que la proporción de observaciones de cada una de las clases existentes sea similar.

Finalmente, se realizan varios modelos extra a partir del último modelo principal, con el objetivo de observar los cambios de fiabilidad o precisión que se producen. Estos modelos extra se crean de las siguientes formas:

- Suprimiendo una o varias variables de entrada del algoritmo generado.
- Modificando el valor de alguno de sus parámetros más importantes.

Resultados y conclusiones

En primer lugar, se exponen brevemente las medidas o magnitudes más importantes que se obtienen para los diferentes modelos de predicción, y que permiten realizar consideraciones acerca de ellos. En este aspecto, el *Out of Bag (OOB) Error* es una medida del error que comete el algoritmo a la hora de realizar predicciones. A su vez, conviene destacar la matriz de confusión generada mediante el conjunto de datos reservado para pruebas (*test set*), en la que se muestran las predicciones realizadas por el modelo frente al valor real que toman cada una de dichas observaciones predichas. Esta matriz se emplea como método de comprobación (validación cruzada) del algoritmo y, a partir de ella, se calcula la precisión global del modelo junto con las diferentes precisiones locales de cada una de las clases de respuesta posibles. También, se obtienen ciertas medidas que expresan la importancia que tiene cada variable sobre la lesividad de los accidentes de tráfico (variable respuesta).

Respecto al primer modelo predictivo del trabajo, su *OOB Error* (30,22%) y su precisión global (70%) obtenidas pueden considerarse aceptables. Sin embargo, las precisiones locales de los casos de lesividad más alta, esto es, de los de clase *"0"* (*muertos*) y *"1"* (*heridos graves*), resultan ser excesivamente bajas, con unos valores de 3% y 8,1%, respectivamente. Por ello, este modelo no puede ser empleado para establecer conclusiones, y se decide proceder a su modificación, de manera que el nuevo análisis generado se centre en los sucesos de mayor lesividad.

De esta manera, surge el segundo modelo principal del proyecto, en el que el *OOB Error* (12,98%) y la precisión global (86,91%) son más que correctas. Sucede igual o incluso mejor con la precisión local de la nueva clase *"0"* (*heridos leves*), que alcanza un valor del 98,5%. En cambio, la precisión de las observaciones correspondientes a la nueva clase *"1"* (*muertos* o *heridos graves*) es bastante mala, llegando solamente a un valor del 15,1%. Este hecho se debe al desequilibrio existente en la base de datos empleada para este modelo, en la que la clase *heridos leves* es claramente mayoritaria frente a la de *muertos* o *heridos graves*. De este modelo tampoco pueden sacarse conclusiones certeras en cuanto a la lesividad de los accidentes.

Así, en el tercer y último modelo principal del trabajo, en el que ya se ha realizado un equilibrado del conjunto de datos, se logra un *OOB Error* y una precisión global correctas (26,55% y 74,1% respectivamente), mientras que la precisión local relativa a las observaciones de mayor lesividad, *muertos* o *heridos graves*, es también muy favorable con un 81,4%. Este último tipo de casos con un grado de lesividad más alto son los que más interés de estudio presentan para el análisis llevado a cabo. Por otro lado, la precisión local de la clase *heridos leves* adquiere un valor del 66,1%. De esta forma, de este modelo sí es posible sacar conclusiones e información de gran utilidad para el ámbito de la seguridad vial, referente a la lesividad de los accidentes de tráfico.

En este sentido, se concluye que las variables de entrada que presentan mayor importancia o tienen más influencia sobre el grado de lesividad de un accidente de tráfico son la existencia de lesiones y las infracciones cometidas por el conductor, según uno de los criterios, y que el accidente se origine por alcance o que sea de tipo frontal, según el otro de los criterios. Esto indica que lo más conveniente y provechoso para reducir la lesividad de los siniestros viales sería poner el foco y trabajar en dichas áreas.

Al contrario, el modelo concluye que las variables de menor importancia y que presentan una menor influencia sobre la lesividad son la luminosidad y los factores atmosféricos, si se emplea el primero de los criterios, o los accidentes de tipo lateral y la luminosidad, si se utiliza el segundo criterio.

Finalmente, mediante los modelos extra del proyecto se confirma la gran importancia de la presencia de lesiones sobre los grados altos de lesividad, obteniendo una disminución del 4,9% en la precisión local si se suprime dicha variable. También, se confirma la prácticamente nula relevancia de la luminosidad y de los factores atmosféricos sobre la lesividad, al no producir su omisión cambios apreciables en la fiabilidad del modelo. Por último, estos modelos demuestran que se ha realizado una elección correcta del valor escogido para los parámetros más importantes del algoritmo.

Palabras clave

Accidente de tráfico, lesividad, seguridad vial, *Machine Learning*, *CART* (*Classification and Regression Trees*), *Random Forest*, predicción, análisis, modelos, variables, *Out of Bag (OOB) Error*, matriz de confusión, precisión global, precisión local.

Códigos UNESCO

120304; 120323; 120603; 120903; 120914; 332702; 520501.

ÍNDICE

AGRADECIMIENTOS **2**

RESUMEN **4**

1. INTRODUCCIÓN **11**

1.1. La seguridad al volante 11

1.1.1. Trascendencia de los accidentes de tráfico 11

1.1.2. Situación en España 14

1.2. Justificación del proyecto 17

1.3. Machine Learning 18

2. OBJETIVOS **20**

3. METODOLOGÍA **21**

3.1. Introducción 21

3.2. Classification and Regression Trees (CART) 21

3.2.1. Formación de los árboles 21

3.2.2. Función de impureza 23

3.2.3. Ventajas y limitaciones de CART 25

3.3. Random Forest 26

3.3.1. Algoritmo de formación del Random Forest 27

3.3.2. Out of Bag Error 29

3.3.3. Overfitting 30

3.3.4. Validación cruzada 31

3.3.5. Importancia de las variables 33

3.3.6. Ventajas y limitaciones del Random Forest 35

4. HERRAMIENTAS **36**

4.1. Entorno estadístico R 36

4.2. Paquetes de R utilizados 36

4.3. Funciones de R utilizadas 37

5. BASE DE DATOS **38**

5.1. Introducción 38

5.2. Estudio de las variables 38

5.3. Modificación de las variables 40

6. PROCEDIMIENTO 43
6.1. Metodología del algoritmo 43
6.2. Elección de parámetros de los modelos 44
6.3. Modelos realizados 46
6.3.1. Modelos principales del trabajo 46
6.3.2. Modelos extra 50
6.4. Medidas a obtener en los modelos 52
6.4.1. Medidas de error del modelo 52
6.4.2. Medidas de importancia de las variables 55

7. RESULTADOS 57
7.1. Modelos principales 57
7.1.1. Modelo 1 57
7.1.2. Modelo 2 62
7.1.3. Modelo 3 66
7.2. Modelos extra 70
7.2.1. Eliminando una variable de entrada 71
7.2.2. Eliminando las dos variables de mayor importancia 85
7.2.3. Eliminando las dos variables de menor importancia 87
7.2.4. Eliminando las variables referidas a infracciones 89
7.2.5. Eliminando las variables referidas al tipo de accidente 90
7.2.6. Modificando *Ntree* 91
7.2.7. Modificando *Mtry* 92

8. CONCLUSIONES DEL TRABAJO 95

9. LÍNEAS FUTURAS DE INVESTIGACIÓN 97

10. PLANIFICACIÓN TEMPORAL 98

11. PRESUPUESTO 100

12. ACRÓNIMOS Y ABREVIATURAS 103

13. BIBLIOGRAFÍA 104

14. ÍNDICE DE FIGURAS 110

15. ÍNDICE DE TABLAS 113

16. ANEXO R 115

1. INTRODUCCIÓN

1.1. La seguridad al volante

1.1.1. Trascendencia de los accidentes de tráfico

La seguridad vial que rodea a los accidentes de tráfico constituye un ámbito de enorme importancia a nivel internacional, y sobre el cual se trabaja profundamente de manera continua día tras día con el objetivo de establecer e implementar distinto tipo de medidas de seguridad que provoquen una disminución del número de accidentes producidos y, sobre todo, del grado de lesividad que sufren las personas involucradas en los mismos.

Según datos de la Organización Mundial de la Salud (OMS), mueren alrededor de 1.350.000 personas cada año como consecuencia de accidentes de tráfico, y entre 20 y 50 millones de personas sufren algún tipo de traumatismo no mortal pero que puede causarles algún tipo de discapacidad. De esta forma, los accidentes de tráfico constituyen una de las principales causas de fallecimiento en todos los rangos de edad a nivel mundial. Además, cabe destacar el enorme impacto que tienen sobre el núcleo de población joven, donde representa la principal y mayoritaria causa de muerte de las personas con una edad de entre 15 y 29 años (Organización Mundial de la Salud (OMS), 2017).

Otro aspecto importante es la desigualdad económica que existe entre distintos territorios alrededor del mundo y que también se ve reflejada en la seguridad vial, tanto en el número de accidentes que se producen como en el grado de lesividad que alcanzan las víctimas de éstos. Así, la mayor parte de los fallecidos en accidentes de tráfico se concentra en estados que cuentan con ingresos de nivel más bajo, en los que la tasa de mortalidad es el triple que la que existen en los países más desarrollados y con mayor poder adquisitivo. Según datos del año 2017 de la Organización para la Cooperación y el Desarrollo Económicos (OCDE), los países que cuentan con una mayor tasa de mortalidad en accidentes de tráfico son los países americanos de Colombia, Argentina, Estados Unidos y Chile, con una tasa anual mayor a 10 fallecidos por cada 100.000 habitantes. Por otro lado, los países que presentan la mejor y, por tanto, la menor tasa de mortalidad son Noruega, Reino Unido y Dinamarca, con 3 o menos muertos por cada 100.000 habitantes.

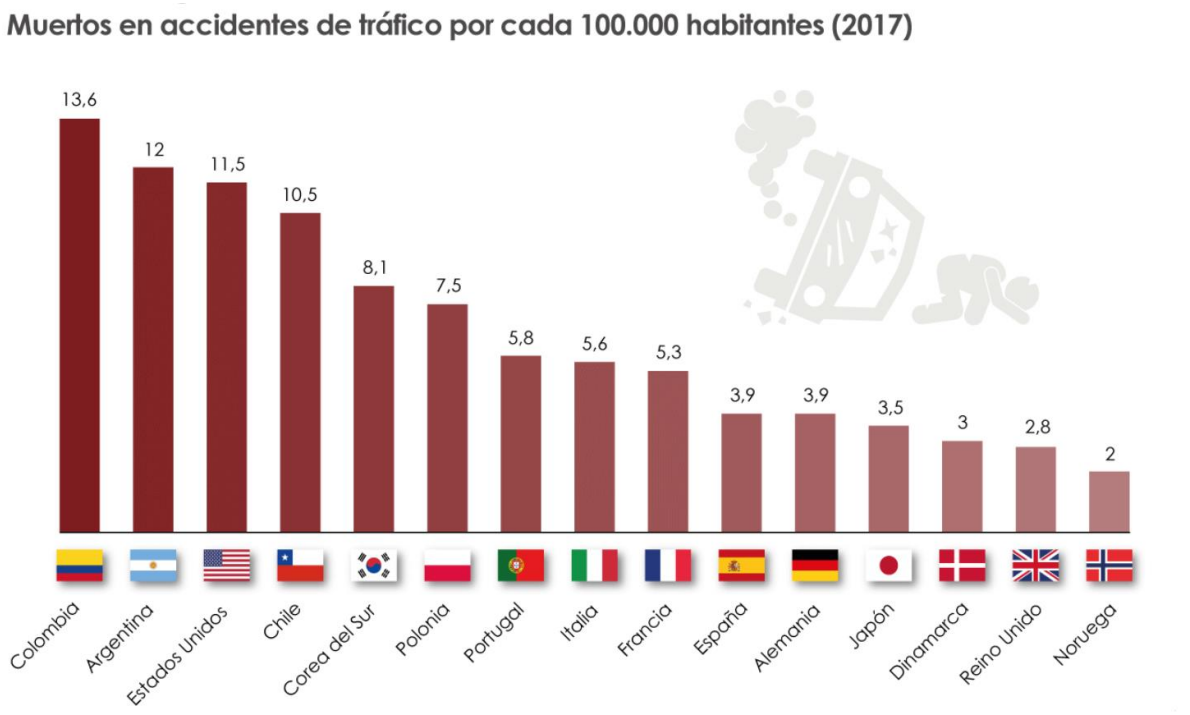


Figura 1. Muertos en accidentes de tráfico por cada 100.000 habitantes (2017). (Merino, 2020).

Pero no solo los accidentes al volante se ven condicionados por la situación económica que presenta cada país, sino que dichos accidentes también ejercen una gran influencia sobre la economía de cada territorio. Esto se justifica con el hecho de que los accidentes llevan asociados unos gastos y costes de dinero enormes para cada estado, los cuales se ven obligados a gastar cada año en este ámbito una cantidad de dinero que representa aproximadamente un 2% de su PIB.

Además, según un estudio realizado por el Banco Mundial, la situación económica de ciertos países que cuentan con niveles bajos o medios de ingresos podría verse favorecida si el número de heridos y fallecidos por estos accidentes fuese menor. Por ejemplo, se estima que, si los heridos y muertos disminuyesen a la mitad, el PIB per cápita podría ascender un 22% en Tailandia, un 15% en China o un 7% en Filipinas.

Todo lo comentado anteriormente evidencia la enorme influencia y repercusión que marcan la seguridad vial y los accidentes de tráfico en el día a día de la sociedad, a la vez que justifica que uno de los aspectos más importantes y en los que más se intente trabajar sea el grado de lesividad que se alcanza en los accidentes, procurando obtener al máximo su disminución para que el número de fallecidos en las carreteras sea lo menor posible.

Con esta finalidad, varios organismos internacionales preparan y presentan distintos planes de acción en el tiempo. La Organización de las Naciones Unidas (ONU) proclamó en 2011 el Decenio de Acción de la Seguridad Vial (2011-2020), que pretendía la disminución de los

fallecidos en accidentes de tráfico mediante estrategias y programas de seguridad vial sostenibles. Posteriormente, en el año 2015 incluyó la mejora de la seguridad vial en los denominados Objetivos de Desarrollo Sostenible enmarcados en la Agenda 2030. Finalmente, se ha proclamado recientemente el Segundo Decenio de Acción para la Seguridad Vial (2021-2030), en el que se ha marcado como objetivo la reducción a la mitad de los fallecimientos y lesiones severas por accidente de tráfico durante esa etapa de tiempo. A su vez y de manera paralela, la Unión Europea (UE) también está comprometida en conseguir una mejora de la seguridad vial a lo largo del tiempo. Para ello, en la Declaración de la Valeta de 2017 se estableció el compromiso de los Estados Miembros de la Unión Europea de seguir implementando estrategias y medidas que permitiesen obtener para el año 2050 el objetivo de Visión Cero (ninguna víctima mortal en accidentes de tráfico), y una disminución considerable de los muertos y heridos graves durante el decenio 2021-2030.

Como resultado de todas estas políticas y estrategias que han sido llevadas a cabo a cabo durante tantos años por la mayoría de estados, los datos estadísticos han ido mejorando a lo largo del tiempo, reduciéndose el número de accidentes totales producidos y su tasa de mortalidad. Estas mejoras se pueden observar en los siguientes gráficos correspondientes a la Unión Europea, donde se muestran el número de víctimas mortales en accidentes de tráfico (Fig. 2) y su tasa de mortalidad por cada 100.000 habitantes (Fig. 3) a lo largo de los últimos 20 años.

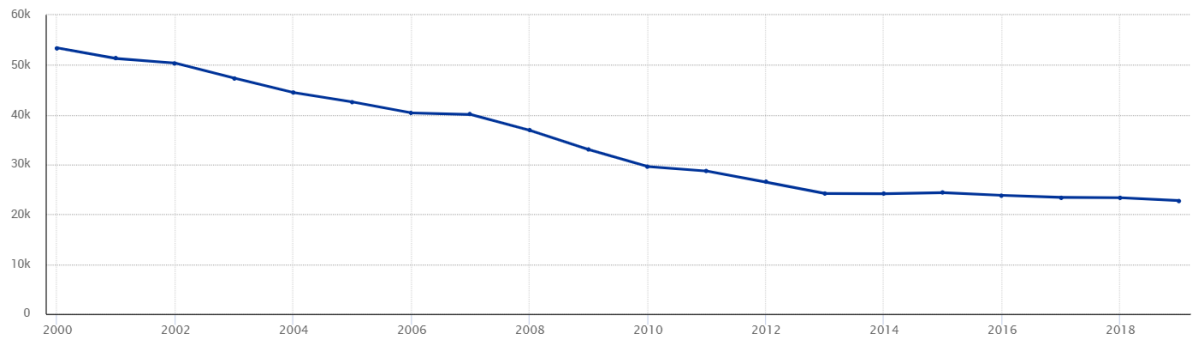


Figura 2. Número de víctimas mortales en accidentes de tráfico en la Unión Europea. (Eurostat, 2021).

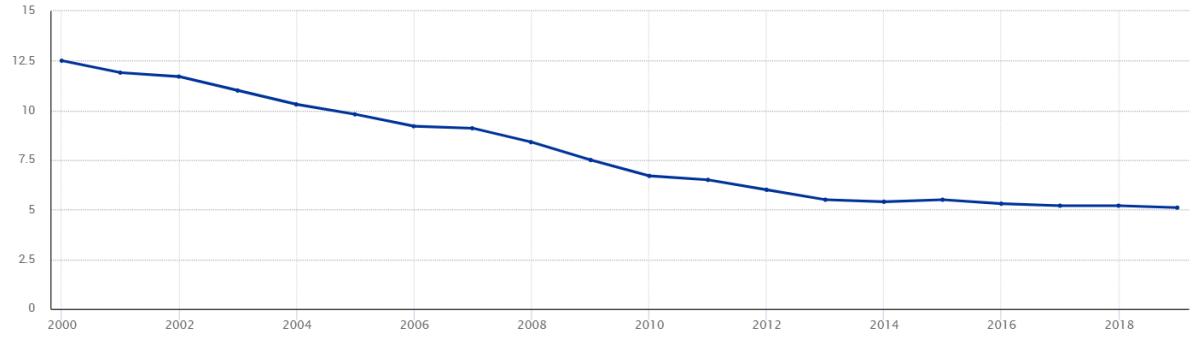


Figura 3. Tasa de mortalidad (por cada 100.000 habitantes) en accidentes de tráfico en la Unión Europea. (Eurostat, 2021).

Estos datos muestran la mejoría que se ha producido a lo largo de los últimos años, pero, sin embargo, es necesario y de vital importancia continuar con la implementación de medidas y estrategias dirigidas a seguir mejorando la seguridad vial en las carreteras, a la vez que los vehículos van evolucionando tecnológicamente y van incorporando nuevos sistemas de seguridad que los hacen más seguros, persiguiendo el objetivo conjunto de seguir reduciendo año a año el número de accidentes de tráfico y su tasa de mortalidad.

1.1.2. Situación en España

Con el paso de los años el número de víctimas mortales que se han producido dentro del territorio nacional de España en accidentes de tráfico ha ido descendiendo. Esta tendencia a la baja se ve representada en los siguientes gráficos, que muestran el número de personas fallecidas en este tipo de sucesos (Fig.4) y la tasa de mortalidad por cada 100.000 habitantes (Fig.5) que se ha alcanzado a lo largo de los últimos años en las carreteras españolas.

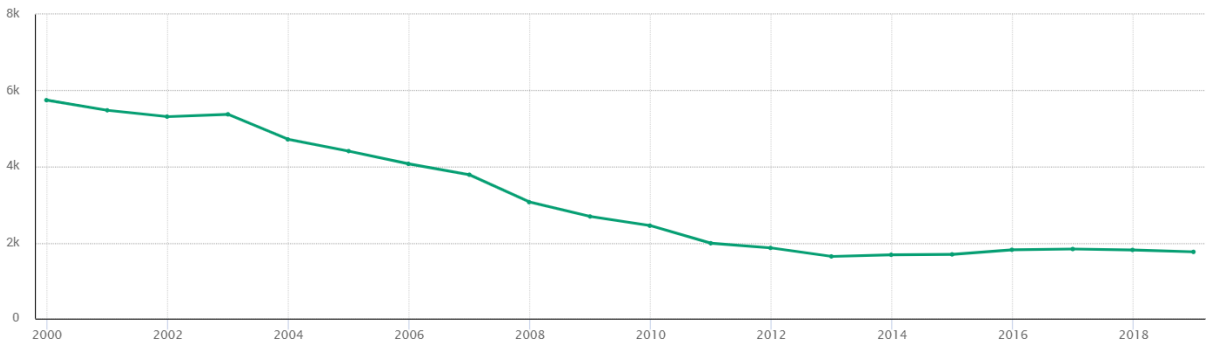


Figura 4. Número de víctimas mortales en accidentes de tráfico en España. (Eurostat, 2021).

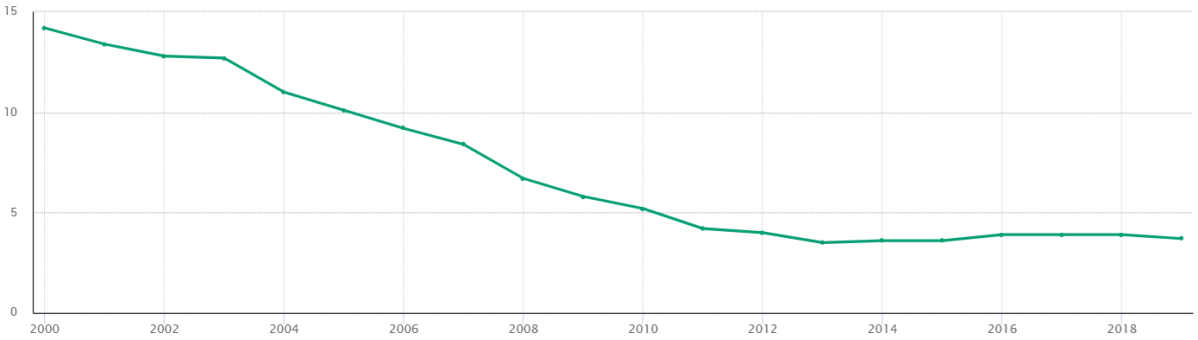


Figura 5. Tasa de mortalidad (por cada 100.000 habitantes) en accidentes de tráfico en España. (Eurostat, 2021).

Como datos más concretos, durante la anualidad del 2019 se produjeron en España un total de 104.080 accidentes con víctimas, de los que 1.651 fueron accidentes mortales (un 1,59% del total de producidos y a una media de 4,5 siniestros mortales por día), y en los que fallecieron un total de 1.755 personas (a una media de 4,8 al día). La tasa de mortalidad alcanzó un valor de 3,7 fallecidos por cada 100.000 habitantes (Dirección General de Tráfico (DGT), 2019).

Realizando una comparación entre la situación del año 2009 y la del 2019 en relación con el ámbito de la seguridad vial, se obtienen los datos y diferencias que se pueden observar en la tabla siguiente (Tabla 1).

	2009	2019	DIFERENCIA (%)
ACCIDENTES CON VÍCTIMAS	88.251	104.080	**+17,9%**
PERSONAS FALLECIDAS	2.714	1.755	**-35,3%**
TASA DE MORTALIDAD (CADA 100.000 HABIT.)	5,8	3,7	**-36,2%**

Tabla 1. Comparativa de datos de accidentes de 2009 vs 2019. (Diseño propio, (Dirección General de Tráfico (DGT), 2019)).

En primer lugar, conviene destacar que el aumento del número de accidentes con víctimas se debe al gran incremento de vehículos y conductores que ha tenido lugar en dicho periodo de tiempo, y que ha hecho, a su vez, aumentar en gran manera el número de desplazamientos que se realizan actualmente. De esta forma, se corrobora la tendencia positiva con la disminución del número de personas fallecidas y de la tasa de mortalidad, cuyo descenso porcentual supera por un muy amplio margen al aumento de los accidentes con víctimas.

Además, España se encuentra entre los países de la Unión Europea que han mejorado más los datos de seguridad vial en su territorio, logrando reducir el número de accidentes durante el decenio de 2010-2020 en un 44%, mientras que en el resto de países de la UE el descenso medio ha sido del 36% (Dirección General de Tráfico (DGT), 2021). Añadido a esto, la tasa de mortalidad nacional también ha sufrido una mayor caída que la que ha sufrido la media del resto de países europeos. Este último acontecimiento se puede observar de forma clara en la siguiente gráfica (Fig.6).

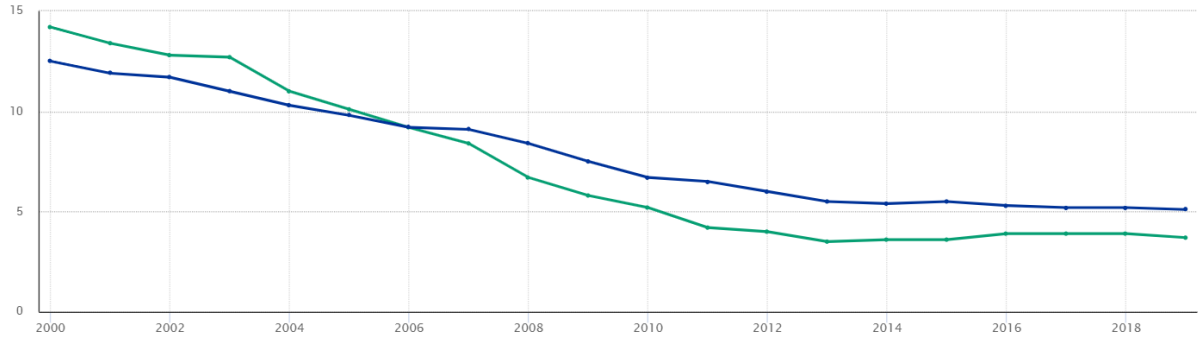


Figura 6. Evolución de la tasa de mortalidad en accidentes de tráfico en España (verde) vs en Europa (azul). (Eurostat, 2021).

Como ya se ha comentado en el apartado anterior, los accidentes de tráfico tienen un enorme impacto económico en cada estado, situación que, por supuesto, es extensible también a la nación española. En este aspecto, según un estudio realizado por el Ministerio de Empleo y Seguridad Social en la década entre 2010 y 2020 este ámbito ha supuesto un gasto medio de 250 millones de euros anuales. En cambio, otros estudios realizados por la Fundación Línea Directa y la Organización para la Cooperación y el Desarrollo Económicos (OCDE) estiman que el coste es mucho mayor, siendo de 13.000 millones de euros al año aproximadamente. A su vez, la exdirectora de la DGT, María Seguí, comentó que los accidentes de tráfico suponían una pérdida del 2% del PIB en España.

En otro aspecto, en España han surgido a lo largo de los últimos años distintas iniciativas o plataformas con el objetivo de velar por la seguridad vial en las carreteras y reducir el número de siniestros que se producen. Entre ellas destaca "Ponle Freno", que es una iniciativa por parte de "Compromiso Atresmedia" por la seguridad vial y la reducción de los accidentes de tráfico. La "Fundación MAPFRE" también intenta concienciar respecto a la seguridad en la carretera, y para ello puso en marcha la campaña "Objetivo Cero", con lo que se pretende hacer desaparecer las víctimas mortales en la carretera. De manera paralela, la Dirección General de Tráfico (DGT) lanza con regularidad campañas de concienciación sobre la importancia de la seguridad al volante y sobre la responsabilidad de los conductores.

Respecto al marco de medidas relacionadas con la seguridad vial que se han instaurado en España, destaca una de muy reciente aplicación, la limitación de la velocidad máxima a 30 km/h en vías urbanas. Esta medida se encuentra enmarcada dentro de la agenda 2030 y pretende conseguir ciudades más seguras, saludables y humanas, disminuyendo la lesividad y mortalidad de los accidentes que se produzcan dentro de núcleos urbanos.

Por todo lo comentado anteriormente, los datos relacionados con la seguridad en la carretera y los accidentes de tráfico en España llevan evolucionando positivamente desde hace muchos años. Sin embargo, éstos no son aún lo suficientemente buenos, lo que hace necesario que los distintos organismos gubernamentales y encargados de la seguridad ciudadana sigan trabajando de manera constante y profunda en este tema, con el objetivo final a largo plazo de hacer desaparecer las víctimas mortales en los incidentes de tráfico.

1.2. Justificación del proyecto

Actualmente, una enorme cantidad de datos estadísticos acerca de los accidentes que se producen en las carreteras se encuentran disponibles y son de fácil acceso para la mayor parte de la sociedad. Éstos muestran en detalle una gran cantidad de factores que pueden haber sido muy influyentes en los resultados de cada siniestro. Por ello, son muy comunes los estudios e investigaciones que analizan los accidentes viales, intentando encontrar ciertos puntos clave o ciertas variables que condicionan, en mayor o menor medida, estos sucesos.

Estos estudios permiten crear modelos que pueden generar información de gran valor en el camino a la reducción de la siniestralidad vial y de su mortalidad, permitiendo identificar el comportamiento que presentan las distintas variables, así como su influencia sobre los resultados finales de los accidentes.

En particular, este proyecto se basa en un análisis de varias variables típicas que aparecen en los siniestros viales, observando su relación directa con el grado de lesividad que alcanzan las víctimas involucradas en cada uno de dichos accidentes. Muestra de la posible utilidad de este

trabajo es el poder concluir qué factores son los que condicionan en mayor medida la lesividad de un siniestro en la carretera. Ello permitiría que se trabajase y se pusiese el foco sobre dichas variables, siendo así capaces de establecer medidas que disminuyesen la mortalidad.

Estos modelos de estudio pueden generarse a través de la aplicación de un amplio abanico de técnicas existentes de *Machine Learning*. En concreto, en este trabajo se procederá a la utilización de la metodología de *Random Forest* para analizar y predecir la lesividad de los accidentes. En los siguientes capítulos se explicará más en detalle en qué consiste esta técnica y cómo se aplicará exactamente para obtener los resultados deseados.

1.3. Machine Learning

El *Machine Learning*, también conocido como aprendizaje automático o aprendizaje de máquinas, es una disciplina que forma parte de la Inteligencia Artificial (IA) y de las ciencias de la computación que hace posible que los sistemas y computadoras sean capaces de aprender por sí solos de forma automatizada y autónoma, sin la necesidad de que un ser humano realice un trabajo constante de manera paralela.

Este aprendizaje se basa fundamentalmente en la adquisición de ciertas habilidades o desempeños que el sistema no poseía con anterioridad, y que le podrán ser de utilidad para su funcionamiento en el futuro. Principalmente, estas destrezas adquiridas consisten en poder realizar predicciones futuras y en conocer cuál va a ser el comportamiento de ciertos sectores del mercado o de ciertos grupos de usuarios de un determinado producto. Sin embargo, las distintas técnicas existentes de *Machine Learning* cuentan con un abanico mucho más amplio de posibilidades en cuanto a su utilidad.

El método o la forma en la que las máquinas logran automáticamente estos nuevos conocimientos se basa en el uso de algoritmos que son capaces de analizar una gran cantidad de datos, identificando patrones típicos de comportamiento en ellos que les hacen ir aprendiendo el funcionamiento de los sistemas, y les capacitan para poder predecir conductas futuras.

Los métodos de aprendizaje de estos algoritmos pueden dividirse en tres tipos o categorías principales:

- **Aprendizaje supervisado**: en este tipo de aprendizaje se proporciona al sistema una gran cantidad de datos, entre los que existen varias variables de entrada y una variable de salida (variable respuesta). La computadora realiza un entrenamiento con dicha base de datos para así poder realizar predicciones de la variable respuesta en función de los

valores que tomen las variables de entrada. Dentro de este tipo de algoritmos se encuentra la técnica que va a ser utilizada en este trabajo, es decir, el *Random Forest*.

- **Aprendizaje no supervisado**: en este caso los datos no contienen una variable respuesta o variable de salida a clasificar o estimar, sino que el algoritmo simplemente busca similitudes entre los nuevos datos que se le van introduciendo y otros que ya poseía. Esto se realiza sin un entrenamiento previo, a diferencia de lo que sucedía en el anterior método de aprendizaje. Un ejemplo de este tipo de algoritmos es el caso del reconocimiento facial, el cual busca similitudes con los rostros registrados.

- **Aprendizaje por refuerzo**: en este método el sistema aprende con su propia experiencia a base de prueba y error, recompensándose las decisiones tomadas correctamente y persiguiendo siempre la optimización de la ejecución de una tarea. Estos algoritmos no necesitan la introducción de mucha información para su funcionamiento, por lo que su uso es más asequible.

De esta forma, el *Machine Learning* es una materia que se encuentra en auge en la sociedad actual, ofreciendo una alternativa de estudio para las empresas en muchos de sus ámbitos y resultando su uso de gran utilidad. Sus posibilidades de aplicación son enormes, puede utilizarse para predecir errores en sistemas tecnológicos, detectar movimientos fraudulentos en cuentas bancarias, diagnosticar ciertas enfermedades de salud, etc.

Entre algunas de las empresas que han hecho empleo de estas novedosas técnicas se encuentra "Netflix", cuyo sistema de recomendación de contenidos se basa en técnicas de aprendizaje automático. Por otro lado, la empresa productora de aceites "Maeva" también está utilizando este tipo de metodologías para predecir a futuro el precio en el mercado de tres variedades distintas de aceite de oliva.

2. OBJETIVOS

El objetivo general del presente Trabajo de Fin de Grado es analizar el grado de lesividad que alcanzan las víctimas de un accidente de tráfico (variable de salida) en función de ciertos factores o de cuáles sean las condiciones en las que se da el suceso (variables de entrada).

Para ello, el objetivo específico principal de este proyecto radica en la construcción de un modelo estadístico que permita pronosticar con la mayor fiabilidad posible la lesividad de un accidente según cuáles sean sus condiciones o características, y que posibilite predecir a su vez cuáles son los factores de un accidente (variables de entrada) que tienen mayor influencia sobre la lesividad que se alcanza en este tipo de siniestros.

La construcción de estos modelos se realizará mediante la aplicación de *Random Forest*, la cual es una técnica de *Machine Learning*, estudiando los accidentes producidos entre dos vehículos entre los años 2004 y 2013, e intentando optimizar al máximo la construcción de dichos modelos para obtener unos resultados lo más fiables posibles.

Todo este trabajo se acomete con el objetivo final de poder implementar medidas preventivas idóneas en las áreas más indicadas, que permitan disminuir la mortalidad y la lesividad que se alcancen en los accidentes de tráfico.

Finalmente, conviene destacar que este proyecto se encuentra enmarcado dentro del doctorado de estudio de Almudena Sanjurjo de No y busca contribuir al mismo.

3. METODOLOGÍA

3.1. Introducción

En los siguientes apartados, se va a proceder a la explicación de la metodología concreta que se ha utilizado para el desarrollo de este trabajo. En primer lugar, se abordarán los *Classification and Regression Trees (CART)*, en los que está basada la técnica específica de *Machine Learning* escogida para la realización de este proyecto, *Random Forest*, qué pasará a comentarse más en profundidad posteriormente. Es muy importante la comprensión de estas metodologías para poder entender correctamente el análisis y el tratamiento que se harán a los datos tratados.

3.2. Classification and Regression Trees (CART)

Los *Classification and Regression Trees (CART)*, conocidos en castellano como *Árboles de Clasificación y Regresión*, son un método de tratamiento estadístico de datos que fue creado por Breiman, Friedman, Olshen y Stone en el año 1984. Por lo tanto, se trata de una herramienta moderna que no lleva excesivos años en uso y que en la actualidad se utiliza bastante en el ámbito de la estadística y análisis de datos, en el *Machine Learning* y en la minería de datos.

Esta técnica consiste principalmente en la realización de particiones binarias que darán lugar a un árbol de clasificación o de regresión, y que permitirá realizar predicciones de la variable dependiente (variable respuesta) del modelo. Para ello, se contará con un conjunto inicial de datos sobre el que se trabajará hasta conseguir la finalización del árbol.

Como expresa su nombre, existen dos tipos de árboles, los de clasificación, que son aquellos en los que la variable respuesta es de tipo categórico (serán con los que se trabaje en este proyecto); y los de regresión, en los que la variable respuesta es de tipo continuo, es decir, donde puede tomar cualquier valor.

3.2.1. Formación de los árboles

En primer lugar, se va a presentar el problema o caso de estudio que va a ser tratado mediante esta técnica. Se posee un conjunto de datos en el que se distinguen *n* variables independientes (variables de entrada) $X_1, X_2, \ldots, X_n$; y la variable dependiente (variable de salida o de respuesta) Y, la cual podrá tomar un total de *k* valores si es de tipo categórica, u otro cualquier valor si es de tipo continua. De esta forma, la variable de salida depende de las variables de entrada, y por

eso se le llama a la primera variable dependiente. Referido a este aspecto, los *Árboles de Clasificación y Regresión (CART)* centran su utilidad en la capacidad de predicción de la variable de salida en función del valor de las variables de entrada.

El proceso de formación de estos árboles se realiza mediante particiones o divisiones binarias del conjunto inicial de datos a partir de un nodo raíz, mediante las que se irán originando distintas regiones en las que se clasifiquen los datos, y en las cuales la variable respuesta irá adquiriendo una mayor tendencia a tener un valor determinado, facilitando así su predicción. Con estas continuas ramificaciones que dan lugar a nuevos nodos se obtiene una mejor clasificación de los datos y se obtiene información muy relevante acerca del comportamiento del modelo.

La siguiente imagen (Fig. 7) muestra el árbol para un ejemplo en el que existen dos variables de entrada X_1 y X_2. En él, se observa que han sido realizadas cinco particiones en total y que se ha dado lugar a seis regiones diferentes (R_1-R_6), en cada una de las cuales la predicción que da el árbol del valor que toma la variable de salida es la misma.

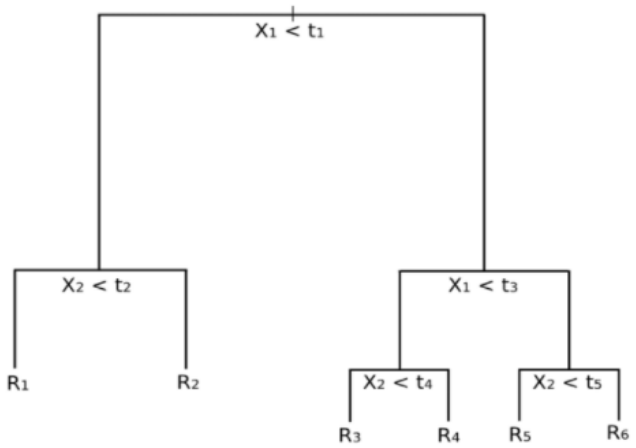


Figura 7. Ejemplo de un CART con dos variables independientes (X_1 y X_2) en el que se han realizado cinco particiones. (Alvear, 2018).

Por otro lado, en la siguiente ilustración (Fig. 8) se observan las distintas regiones en las que ha sido dividido el espacio de dos dimensiones en función de los valores de X_1 y X_2.

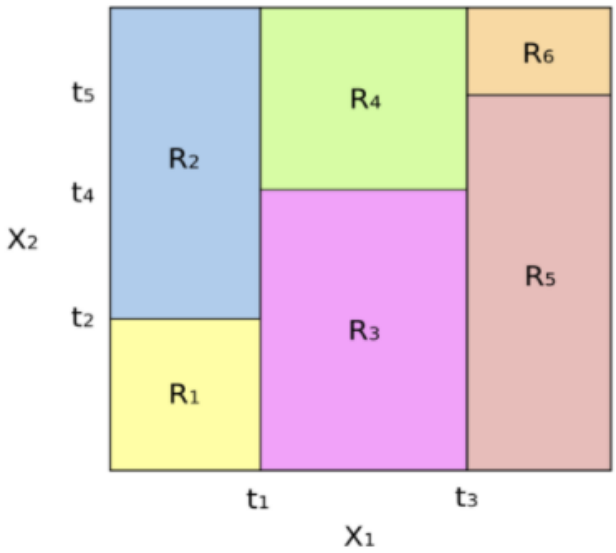


Figura 8. División del espacio de dos dimensiones en seis regiones (R_1-R_6). (Alvear, 2018).

Por tanto, los distintos elementos que componen un árbol son los siguientes:

- **Nodos**: a partir de los cuales tienen lugar las divisiones o particiones del árbol. El nodo inicial se denomina nodo padre o nodo raíz.
- **Ramas**: son los arcos que resultan de las bifurcaciones desde un nodo, y que lo unen con el nodo inmediatamente inferior.
- **Hojas**: son los nodos terminales, en los que se predice el valor de la variable respuesta.

Además, en la construcción de los árboles es necesario conocer cuál es el criterio que se ha de utilizar para realizar las particiones de los distintos nodos y cuando se han de finalizar dichas divisiones. Para ello, se utiliza la *Función de Impureza (Impurity Function)*, la cual se va a abordar en el siguiente apartado.

3.2.2. Función de impureza

Cuando se vaya a realizar una partición desde un nodo, se buscará realizarla en la variable de entrada que provoque una mayor disminución de la impureza de dicho nodo, o lo que es lo mismo, un mayor aumento de su pureza. De esta forma, se define la *Función de Impureza (Q)* como la suma de todas las impurezas en cada nodo.

Por otro lado, se define un nuevo parámetro (p_{mk}) que representa la proporción de muestras que se encuentran dentro de la región *m* que son de la clase *k*, o lo que es lo mismo, la probabilidad que hay de que la variable respuesta sea de una clase determinada en una región:

$$p_{mk} = \frac{1}{N_m} \sum_{x_i \in R_m} I\{y_i = k\}$$

- N_m: número de observaciones totales que existen en la región *m*.

Así, la predicción que se asigna a una región (o nodo terminal) será el valor de la variable respuesta que tenga mayor proporción en dicha región:

$$k(m) = \arg max_k \{p_{mk}\}$$

Volviendo al tema tratado en este apartado, la impureza en cada nodo puede medirse de tres maneras distintas:

- **Tasa de error de clasificación:**

$$\frac{1}{N_m} \sum_{i \in R_m} I\{y_i \neq k_k\} = 1 - p_{mk}$$

- **Índice de Gini:**

$$\sum_{k=1}^{k} p_{mk} \cdot (1 - p_{mk})$$

- **Entropía:**

$$-\sum_{k=1}^{k} p_{mk} \cdot \log p_{mk}$$

De esta forma, las particiones del *CART* se realizarán de manera que en cada nodo se alcance la impureza mínima y, por tanto, una pureza máxima en el árbol. Este criterio de impureza también se emplea para saber cuándo se ha de terminar de hacer ramificaciones, ya que el árbol no puede ser ilimitado. En este sentido, las anteriores tres medidas pueden utilizarse tanto para el crecimiento del árbol como para su poda, aunque para su crecimiento se suelen usar mayoritariamente el Índice de Gini y la Entropía, mientras que la Tasa de error de clasificación se reserva normalmente para su poda.

3.2.3. Ventajas y limitaciones de CART

Los *CART* presentan numerosas ventajas en su uso en comparación con muchas otras técnicas. Algunas de éstas son:

- No se necesita realizar un tratamiento previo de los datos de entrada, ya que admiten que éstos puedan tener cualquier tipo de distribución. Además, tampoco surge ningún problema en el caso de que falte algún dato en alguna variable.

- Permiten que el número de variables de entrada *n* supere al número de muestras con las que cuentan los datos.

- Los árboles son muy sencillos de comprender e interpretar.

- Se desenvuelven de manera más que correcta con un conjunto de datos muy grande, admitiendo una gran cantidad tanto de variables como de observaciones.

- Pueden tratar datos en los que las variables de salida sean tanto de tipo categórico como continuo.

- Se puede realizar su validación mediante pruebas estadísticas para confirmar su fiabilidad.

- Son capaces de predecir qué o cuáles variables tienen mayor importancia en la variable respuesta.

Sin embargo, como es normal, también presentan ciertas limitaciones en su funcionamiento, como:

- Tienen una varianza muy elevada, en los que cualquier cambio en los datos de entrada puede suponer una gran modificación en el árbol generado y en la predicción realizada por el modelo, lo que indica cierta falta de robustez.

- En su construcción tienen lugar divisiones de datos que son realizadas de manera muy rígida, lo que hace entrever cierta falta de suavidad en la formación de su estructura.

- Pueden generarse problemas de desequilibrio en el caso de que en el conjunto de datos utilizado una de las clases sea mayoritaria a la otra.

- Tienen tendencia al sobre-ajuste (*overfitting*), es decir, a seguir en exceso el patrón de comportamiento de los datos con los que se le entrena. Esto hace que el árbol aprenda muy bien estos datos, pero que su capacidad de análisis frente a otros distintos no sea tan buena. Por ello, se hace necesaria la aplicación de técnicas de poda del árbol generado.

- Al tratarse de un único árbol, su capacidad de predicción es bastante inferior a la que se puede conseguir con otras metodologías que usan una mayor cantidad de árboles como, por ejemplo, *Random Forest*, que es la técnica utilizada en este proyecto, y la cual se va a explicar a continuación con más detalle.

3.3. Random Forest

Random Forest, también conocido como *"Bosque Aleatorio"*, es una técnica específica de *Machine Learning* (aprendizaje automático) que ha sido escogida para emplear en el desarrollo de este trabajo, que permite realizar predicciones acerca de una variable de salida y estimar la importancia de cada una de las variables de entrada en la salida del modelo.

Esta metodología se basa en el uso de un gran conjunto de árboles de clasificación o regresión *(CART)* que han sido construidos mediante algoritmos que incorporan ciertos elementos de aleatoriedad, de ahí que se les denomine cómo bosques aleatorios. Además, estos algoritmos concretos de construcción producen una disminución de la correlación existente entre los distintos árboles que forman el bosque y, de esta manera, aumentan la fiabilidad de la predicción realizada.

El origen de esta técnica se remonta al año 1995, cuando Tin Kam Ho ideó los primeros algoritmos que se usarían en ella. Pero realmente fueron Leo Breiman y Adele Cutler quienes en el año 2001 desarrollaron de forma completa los algoritmos usados en el *Random Forest*, registrando su propia marca. Es decir, ésta es una técnica relativamente nueva y que se encuentra en uso desde hace no demasiado tiempo.

3.3.1. Algoritmo de formación del Random Forest

En este apartado se va a proceder a la explicación del algoritmo de formación del Bosque Aleatorio (*Random Forest*), así como de la forma en que se usa y de los distintos parámetros con los que cuenta el modelo.

Respecto al primero de los aspectos, cada uno de los árboles de decisión que conforma el bosque y, por tanto, el modelo, se construye de la siguiente manera:

1) Contando con una base inicial de datos en la que hay un total de *Z* observaciones, se va a dar lugar a un nuevo conjunto de datos, del mismo tamaño *Z*, escogiendo observaciones de manera aleatoria y con reemplazamiento del conjunto inicial de datos. Esta técnica utilizada es conocida como *"bootstrapping"*, la cual introduce el primer componente de aleatoriedad en el algoritmo y hace que cada árbol se forme a partir de datos distintos. Además, en cada nueva muestra de datos que se origina puede haber observaciones repetidas a causa de que es una técnica que se realiza con reemplazamiento.

2) A continuación, se va a construir un árbol de decisión usando el nuevo conjunto de datos originado en el paso anterior mediante "*bootstrapping"*. Pero dicha construcción va a tener la particularidad de que en cada partición que se realice en el árbol solamente se tengan en cuenta un número aleatorio de variables de entrada, y no todas. Este número de variables a tener en cuenta, *p*, será siempre menor que el número total de variables de entrada *n* del modelo, y va a ser constante en todo el proceso de formación del árbol. De esta forma, se incorpora la segunda fuente de aleatoriedad en el algoritmo de formación del *Random Forest*.

3) Se deja crecer el árbol hasta su máxima extensión posible, sin realizar ningún proceso de poda.

De la forma anteriormente explicada se da lugar a la formación de un árbol. En este momento, se ha de regresar al paso número 1) y repetir el proceso tantas veces como número de árboles de decisión (*Ntree*) se desee que tenga el modelo de *Random Forest* creado. Así, finalmente se obtiene un enorme número de árboles que conforman el bosque aleatorio típico de esta metodología.

Cabe destacar que, debido a lo comentado anteriormente, con *Random Forest* se pretende lograr una disminución de la varianza reduciendo la correlación existente entre los distintos árboles que forman el bosque aleatorio. Esto es posible gracias a la aleatoriedad de la que consta el

modelo, en el que cada árbol se origina a partir de datos distintos y se utiliza un número aleatorio de variables para realizar las divisiones de cada uno de los árboles.

Una vez haya sido finalizada la construcción del bosque aleatorio y, por tanto, del modelo, será posible su uso con el objetivo de realizar predicciones. En los problemas de clasificación, la predicción realizada por el *Random Forest* será la clase de la variable de salida más votada o mayoritaria entre todos los árboles de decisión que forman el modelo. Mientras, en los problemas de regresión se escogerá el valor promedio entre las predicciones que realice cada uno de los árboles. En la siguiente imagen (Fig. 9) se puede observar dicho funcionamiento.

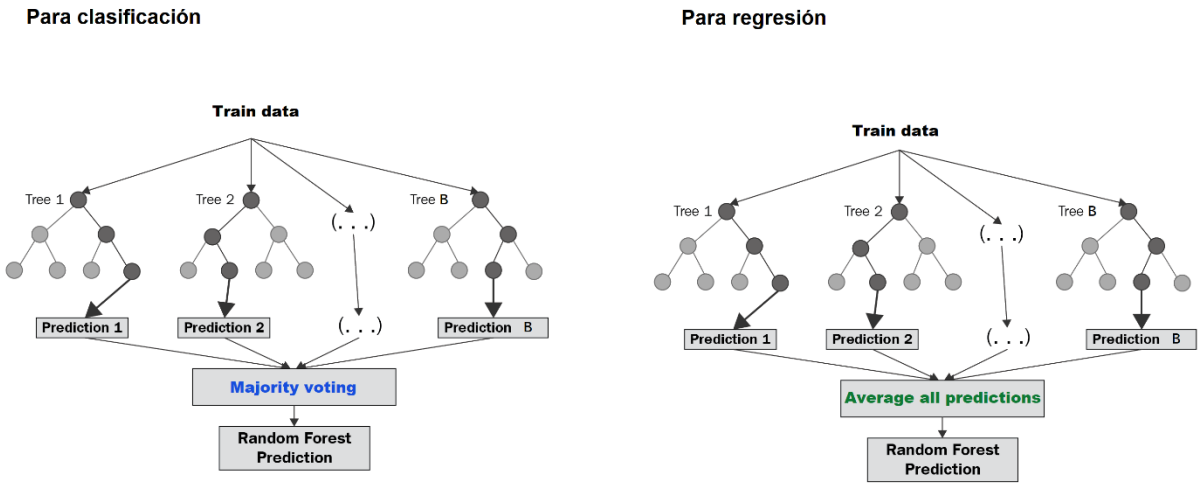


Figura 9. Random Forest para problemas de clasificación y de regresión. (Hernández, Modelos Predictivos, 2021).

De esta forma, los dos parámetros más importantes de un modelo de *Random Forest* son los siguientes:

- ***Ntree*:** número total de árboles de decisión que componen el bosque.
- ***Mtry*:** número *p* de variables que se tienen en cuenta en cada nodo para su partición.

La fiabilidad de predicción de cada modelo y su tasa de error dependen en gran medida del valor escogido para estos parámetros. Esto provoca que sea conveniente el estudio de cómo influyen dichos parámetros en los resultados del modelo, y qué valores concretos de éstos se han de escoger.

En primer lugar, a mayor número de árboles de decisión que conformen el modelo *(Ntree)* mayor será su precisión y fiabilidad, ya que se contará con una mayor cantidad de datos y referencias con las que hacer predicciones. Sin embargo, a partir de cierto número de árboles llega un momento en el que el error se estabiliza y ya no disminuye más, provocando únicamente un aumento en el tiempo que tarda el algoritmo en ejecutarse.

Por otro lado, respecto al valor *p* de variables tenidas en cuenta para la partición de cada nodo *(Mtry)*, una reducción de su valor provocará que disminuya la correlación existente entre los distintos árboles que forman el modelo, lo que es un punto a favor respecto a la fiabilidad de éste. Pero, este descenso en su valor también va acompañado de una disminución de la precisión de los árboles generados, al contar cada uno de ellos con menos posibilidades de bifurcación o división en cada nodo. Por ello, el valor idóneo de *Mtry* dependerá de cada problema.

Los precursores de esta técnica de *Machine Learning*, Breiman y Adele, recomiendan utilizar los siguientes valores para el parámetro *Mtry*:

- Para problemas de clasificación: $Mtry = \sqrt{n}$
- Para problemas de regresión: $Mtry = \frac{n}{3}$

Siendo *n* el número total de variables de entrada (variables independientes) del modelo.

3.3.2. Out of Bag Error

El *Out of Bag (OOB) Error* es una medida de error que se utiliza en los modelos de *Random Forest* y en otros algoritmos que también usan la técnica de *"bootstrapping"*, para cuantificar el error de predicción que se comete en ellos.

Al ejecutar la técnica de *"bootstrapping"*, escogiendo *Z* observaciones con reemplazamiento, normalmente alrededor del 36% de los datos iniciales quedan fuera del nuevo conjunto de datos que se forma y que se usa para crear el árbol de decisión. A este conjunto se le conoce como *Out of Bag (OOB) Dataset*.

De esta forma, se denomina *OOB Error* a la proporción de observaciones de este *OOB Dataset* que dan una predicción incorrecta de su valor de salida al ser ejecutadas a través de cada uno de los árboles en los que no han sido incluidas dichas observaciones.

Como se ha comentado anteriormente, los parámetros más importantes del modelo (*Ntree* y *Mtry*) tienen influencia en la precisión del modelo y, por tanto, en este *OOB Error*. En la

siguiente imagen (Fig. 10) se puede observar cómo evoluciona dicho error en función de *Ntree* y *Mtry*. A mayor número de árboles del modelo, menor es el error cometido, aunque llega un momento en el que el error se estabiliza y no disminuye más. Por ello, se dice que tiene una evolución asintótica respecto del parámetro *Ntree*. Sin embargo, la influencia del parámetro *Mtry* es menos generalizable y depende de cada problema. Aunque como se ha comentado en el apartado anterior, es aconsejable escoger los valores que recomendaron Breiman y Adele, y como se observa en la figura, el error es más alto cuando se trabaja con un mayor número de variables explicativas.

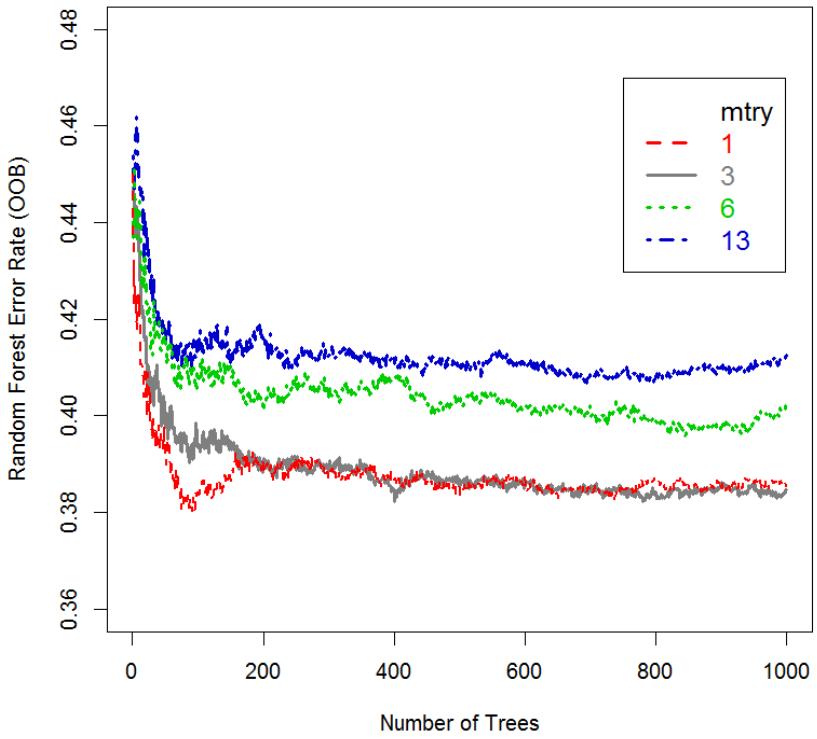


Figura 10. Variación del OOB Error en función de los parámetros Ntree y Mtry del modelo. (D. Buskirk & Kolenikov, 2015).

3.3.3. Overfitting

El *overfitting*, también conocido en castellano como sobre-ajuste, es un fenómeno que se produce en ciertos algoritmos estadísticos cuando el modelo es capaz de aprender de forma muy precisa los datos con los que se le entrena, pero tiene sendas dificultades a la hora de trabajar con datos nuevos y distintos con los que realizar predicciones fiables.

Este suceso suele ser muy común en los *CART (Classification and Regression Trees)*, en los que dicha problemática suele ser resuelta mediante procesos de poda de los árboles. Por otro lado, este inconveniente no suele aparecer en los modelos de *Random Forest*, lo que se debe a que en su algoritmo de formación se introducen varias fuentes de aleatoriedad, ya explicadas anteriormente, que hacen que los árboles presenten una gran distinción entre todos ellos. Sin embargo, la elección de unos valores incorrectos para los parámetros *Ntree* y *Mtry* puede originar ciertos problemas de este tipo, viéndose comprometida la precisión en las predicciones que realice el modelo con datos nuevos.

3.3.4. Validación cruzada

La validación cruzada, también conocida como *cross validation*, es una técnica que se utiliza en modelos estadísticos que tienen gran cantidad de datos con el objetivo de garantizar que los resultados obtenidos en el conjunto de datos de entrenamiento (*training*) y en el de prueba (*test*) son independientes entre sí. Su uso es muy común entre las distintas metodologías existentes de *Machine Learning*, sobre todo en aquellas que se basan en algoritmos de aprendizaje supervisado.

Su forma más simple de ejecución es mediante el método *holdout* o método de retención, en el que el conjunto inicial de datos se divide en dos subconjuntos, uno de entrenamiento (*training set)* y otro de prueba (*test set*). Para construir el modelo predictivo se utilizará únicamente el *training set*, y una vez éste quede realizado, se realiza la validación cruzada comparando los datos del *test set* con las predicciones que es capaz de realizar el modelo generado cogiendo como datos de entrada los mismos del *test set*. De esta forma, para comprobar la precisión del modelo se emplean datos que no han sido utilizados en su construcción, y se puede concluir que cuanto más se parezcan estos resultados obtenidos más fiable será el modelo.

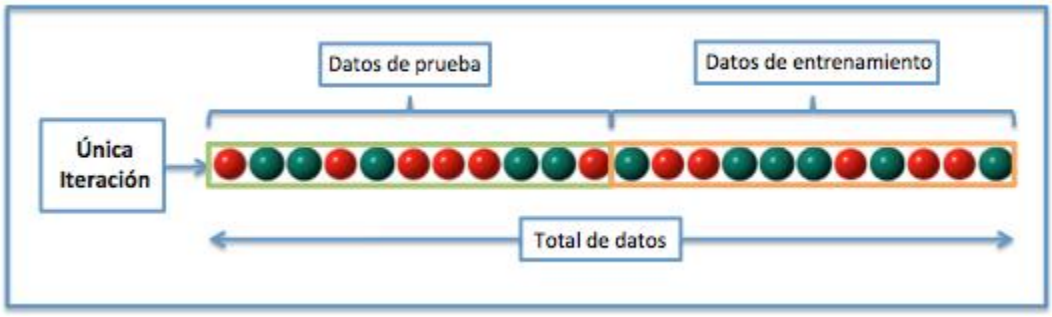


Figura 11. Método de validación cruzada holdout o de retención. (Wikipedia, s.f.).

Éste es un método muy práctico y sencillo que se utiliza en gran cantidad de algoritmos estadísticos, pero que, sin embargo, puede presentar ciertos problemas respecto a su variabilidad, ya que muestra una gran dependencia de la división inicial de datos que se haya realizado. Por ello, existen otros métodos de validación cruzada que intentan reducir estas limitaciones. Algunos de éstos son:

- **Validación cruzada de *K* iteraciones *(K-fold cross-validation)***: en este método se realizan *k* iteraciones, en cada una de los cuales se realiza un modelo predictivo y se aplica el método de comparación del *holdout*. Para ello, en primer lugar, el conjunto inicial de datos se divide en *K* subconjuntos, de los cuales uno de ellos se va a utilizar como datos de prueba (*test set*), mientras que el resto (*K*-1) se va a destinar a datos de entrenamiento (*training set*) que se utilizan para la realización del modelo en cada iteración. De esta forma, en cada uno de los modelos generados se van cogiendo un *training set* y *test set* diferentes. Finalmente, el resultado se obtendrá realizando la media aritmética de cada una de las *K* iteraciones (modelos).

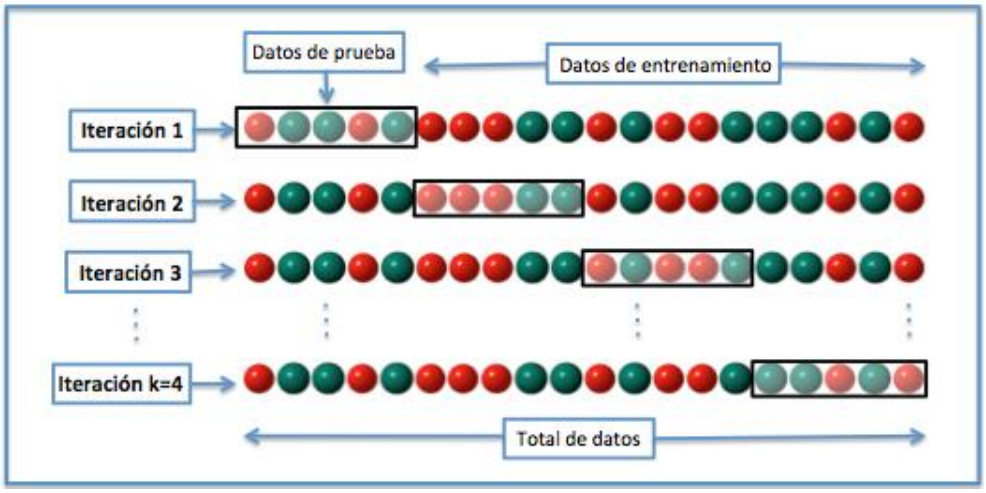


Figura 12. Validación cruzada de K iteraciones (K-fold cross-validation). (Wikipedia, s.f.)

- **Validación cruzada aleatoria *(Aleatory Cross Validation)*:** este método se basa en la división de manera totalmente aleatoria del conjunto inicial de datos, dando lugar a conjuntos de datos de entrenamiento (*training sets*) y de prueba (*test sets*) completamente diferentes unos de otros, aunque pueden solaparse. En esta técnica también se realizan una serie de iteraciones, y el resultado será la media aritmética de las distintas iteraciones (modelos) realizados. Por otro lado, como diferencia respecto al método anterior, en este caso el número de iteraciones puede ser menor que el número de subconjuntos en los que se dividían los datos en el procedimiento anterior.

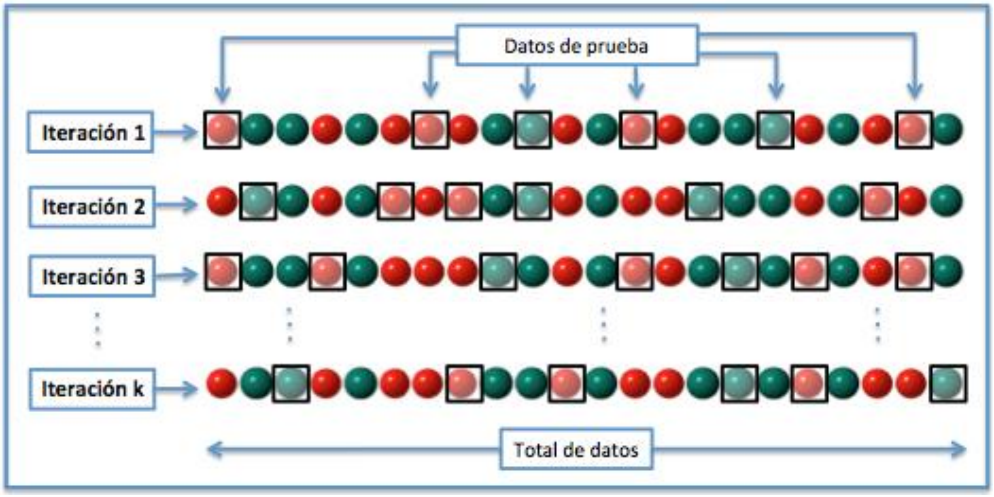


Figura 13. Validación cruzada aleatoria (Aleatory Cross Validation). (Wikipedia, s.f.).

Estas dos últimas metodologías tienen mayor precisión y suelen obtener mejores resultados que el método *holdout*. En cambio, sus costes computacionales son mucho mayores, requieren más tiempo, y a veces ni siquiera existen diferencias significativas en sus resultados. Es por ello, que en función de cada problema se optará por el uso de una u otra técnica de validación cruzada.

3.3.5. Importancia de las variables

El concepto de importancia de las variables resulta de gran importancia y su uso es muy frecuente tanto en regresión como en muchos modelos de *Machine Learning*. Sin embargo, no se trata de un ámbito sencillo, sino que requiere de cierta complejidad para su entendimiento y medición.

Este término hace referencia a la influencia que tiene cada una de las variables de entrada (variables independientes) en la salida del modelo, esto es, en el valor de la variable de salida (variable dependiente). Esta influencia se medirá observando cómo afectan ciertas variaciones de las variables sobre el modelo y sobre su respuesta. Así, las variables que produzcan una mayor variabilidad en la salida del modelo serán las que tenga más influencia y mejor expliquen el modelo y, por tanto, las más importantes.

De esta forma, existen distintas maneras de cuantificar dicha importancia de las variables. A continuación, se presentan las dos medidas con las que se va a trabajar en este proyecto:

- ***Mean Decrease Accuracy* (Disminución Media de la Precisión):** expresa cuánta precisión pierde el modelo mediante la supresión o exclusión de cada variable de entrada. A mayor pérdida de precisión, más importante y mayor influencia tendrá la variable sobre la respuesta del modelo estudiado.

- ***Mean Decrease Gini* (Disminución Media del Índice de Gini):** es una medida de la capacidad o contribución que ha tenido cada una de las variables en la construcción de los distintos árboles a la hora de realizar las particiones en los nodos buscando dar lugar a regiones lo más homogéneas o puras posibles. Al igual que en el caso anterior, cuanto mayor sea este valor, mayor importancia y mayor poder predictivo tendrá la variable considerada.

En los siguientes gráficos (Fig. 14) se puede observar la representación de ambas medidas de importancia para cada una de las variables independientes de un modelo.

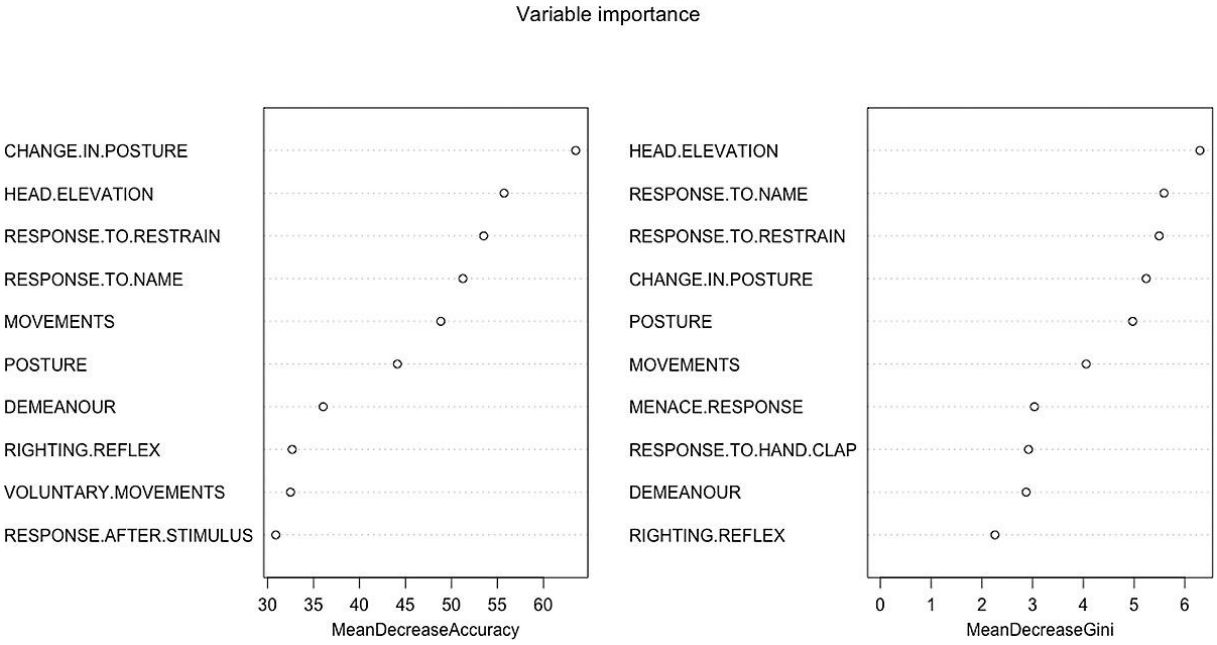


Figura 14. Representación de Mean Decrease Accuracy y Mean Decrease Gini para las variables de entrada de un modelo. (Martinez-Taboada & Ignacio Redondo, 2020).

3.3.6. Ventajas y limitaciones del Random Forest

Random Forest presenta numerosas ventajas, varias de las cuales coinciden con las de los *CART (Classification and Regression Trees).* Algunas de ellas son:

- Es un algoritmo de aprendizaje automático muy certero.
- Trabaja de manera eficiente con conjuntos iniciales de datos muy grandes.
- Es capaz de trabajar con un gran número de variables de entrada.
- Permite estimar la importancia de las distintas variables.
- Es capaz de trabajar correctamente, aunque existan datos incompletos.
- El pretratamiento y la preparación previa que hay que realizar de los datos es mínima.
- Su ejecución es bastante rápida, no requiere demasiado tiempo.
- Su fiabilidad de predicción es bastante buena, al incorporar ciertos elementos de aleatoriedad a la construcción de los distintos árboles.
- No se suele producir *overfitting (sobre-ajuste)* si se ha realizado una correcta elección de los parámetros del modelo.

Sin embargo, esta técnica de *Machine Learning* también muestra ciertas limitaciones o desventajas, entre las que destacan las siguientes:

- A diferencia de lo que sucede en los *CART*, la clasificación que realiza este algoritmo no es sencilla de interpretar.
- En el conjunto de entrenamiento del modelo es posible que aparezcan datos con ruido, lo que puede producir errores de predicción.
- Esta técnica no permite un análisis individual de cada árbol que compone el bosque.
- Se tiene poco control sobre lo que va realizando el modelo de manera interna.
- Pueden producirse problemas de desequilibrio si en la base de datos existe una clase de variable que es mayoritaria frente al resto.

4. HERRAMIENTAS

4.1. Entorno estadístico R

Para los distintos análisis llevados a cabo en este Trabajo de Fin de Grado se ha empleado el entorno estadístico R.

R es un lenguaje de programación que es muy utilizado y frecuente actualmente en todo tipo de investigaciones de carácter estadístico como, por ejemplo, en el campo del *Machine Learning* (autoaprendizaje), en minería de datos o en investigaciones biomédicas, entre otros. Además, se trata de un software de libre acceso con el cual es posible hacer uso de una gran cantidad de herramientas estadísticas, las cuales pueden descargarse a través de distintos *paquetes* desde la web oficial de *CRAN projects*.

En este proyecto, para la introducción de código y la obtención y visualización de los resultados, se ha utilizado *RStudio*, que es una *IDE (Integrated Development Environment)*, o lo que es lo mismo, un entorno de desarrollo integrado sencillo que facilita el trabajo en R.

4.2. Paquetes de R utilizados

En el desarrollo de este trabajo ha sido de vital importancia el uso de varias librerías (paquetes) propias del lenguaje R. Éstas son:

- ***caret:*** paquete que incluye numerosas funciones que facilitan el empleo de distintos métodos no sencillos de clasificación y regresión.

- ***readxl:*** librería que permite la importación de hojas de Excel a R.

- ***randomForest:*** paquete desarrollado por Andy Liaw y Matthew Wiener que posibilita la realización de *Random Forests* (Bosques Aleatorios) para problemas de clasificación y regresión, según los algoritmos establecidos por Leo Breiman y Adele Cutler.

4.3. Funciones de R utilizadas

Las distintas funciones de R que han sido utilizadas en el proyecto y que han posibilitado la obtención de resultados han sido las siguientes:

- ***read_excel():*** para importar y realizar la lectura de archivos .xls y .xlsx creados con Excel.
- ***factor():*** para convertir una variable en categórica o clasificatoria (factor).
- ***set.seed():*** para inicializar la generación de números aleatorios en un número concreto, y así poder obtener resultados replicables.
- ***createDataPartition():*** para realizar una división del conjunto inicial de datos, dando lugar a una partición de entrenamiento (*training set*) y a otra de prueba (*test set*).
- ***randomForest():*** para generar un modelo de *Random Forest* a partir de un conjunto inicial de datos, distinguiendo la variable respuesta (dependiente) de las de entrada (independientes), y estableciendo sus distintos parámetros.
- ***print():*** para obtener información general del modelo generado.
- ***predict():*** para realizar predicciones sobre un modelo.
- ***confusionMatrix():*** para generar una matriz de confusión a partir de unos datos dados.
- ***importance():*** para estimar la importancia de las variables de entrada del modelo, mediante el cálculo del *Mean Decrease Accuracy* y el *Mean Decrease Gini* para cada una de dichas variables.
- ***varImpPlot():*** para generar un gráfico con las dos medidas anteriores de importancia de cada una de las variables de entrada del modelo (como en la Fig. 14).
- ***plot():*** para generar un gráfico basado en el modelo construido, en el que se muestra la evolución del error del modelo frente al número de árboles de decisión que contiene el modelo (parámetro *Ntree*).

5. BASE DE DATOS

5.1. Introducción

La base de datos original fue proporcionada por el Instituto Universitario de Investigación del Automóvil Francisco Aparicio Izquierdo (INSIA), y fue realizada a partir de las fuentes de la Dirección General de Tráfico (DGT). Mientras, los registros existentes en la base de datos empleada para este proyecto son resultado de una depuración previa realizada por la investigadora Almudena Sanjurjo de No, de la que se obtiene un archivo Excel que cuenta con un total de 145.904 registros, los cuales representan a los conductores que se han visto implicados en accidentes de tráfico entre dos vehículos desde el año 2004 a 2013 en vías interurbanas.

En estos registros, cada fila representa a un conductor involucrado en un accidente, que se encuentra emparejado con el otro conductor que también se ha visto involucrado en la colisión, y que aparece en la siguiente fila. De esta manera, los conductores se encuentran referenciados mediante la primera variable (primera columna), que es exclusiva para cada conductor, y mediante la segunda variable (segunda columna), que empareja 2 a 2 a los conductores implicados en el mismo accidente, teniendo esta variable el mismo valor para ambos de ellos. Sin embargo, la cantidad de variables estudiadas para cada accidente es mucho mayor, de manera que en el archivo Excel aparecen 111 variables adicionales, que sumadas a las dos que se han explicado anteriormente hacen un total de 113 variables por cada una de las colisiones registradas. Todas estas variables proceden del formulario de la DGT que se rellena al sufrir un accidente de tráfico, y pueden hacer referencia a ciertas características o condiciones del conductor implicado (infracciones cometidas o condición psicofísica…), o a características generales del accidente, tales como la luminosidad o los factores atmosféricos.

5.2. Estudio de las variables

Antes que nada, conviene destacar que se va a trabajar con las variables más significativas de acuerdo con el objetivo planteado para el proyecto. De esta forma, no se emplearán todas las variables que aparecen en la base de datos, sino solo algunas. Estas variables más significativas que se van a utilizar en el desarrollo de la investigación son las siguientes: *Lesividad, Localización de las lesiones más graves, Defecto físico previo, Condiciones psicofísicas, Sexo, Infracciones de velocidad, Infracciones administrativas, Infracciones del conductor, Estado del vehículo, Luminosidad, Factores atmosféricos* y *Tipo de accidente.*

La variable respuesta (variable de salida o dependiente) de los modelos generados será la *Lesividad*, mientras que el resto se considerarán variables de entrada (variables independientes). En el caso de la *Lesividad*, ésta es una variable cualitativa de tipo ordinal que refleja el grado de lesividad que ha alcanzado la víctima involucrada en un accidente. Los distintos valores que puede tomar esta variable son los siguientes:

- 1 = Muerto
- 2 = Herido grave
- 3 = Herido leve
- 4 = Ileso
- 5 = Se ignora

Respecto a las variables de entrada, se va a realizar su modificación mediante una normalización. De esta manera, se van a convertir en variables binarias o ternarias, que solamente van a poder tomar una serie concreta de valores. Como se ha comentado, esta fase de modificaciones solo afecta a las variables de entrada, es decir, la variable lesividad (variable de salida) no se va a ver afectada por ellas. En el siguiente apartado se hablará más en detalle acerca de esta primera fase de transformaciones.

Posteriormente, en un segundo tratamiento de los datos, se modificará la variable respuesta del modelo, esto es, la *Lesividad*, transformándola en una variable binaria que podrá tomar los siguientes valores:

- 0 = HL (*herido leve*)
- 1 = MHG (*muerto* o *herido grave*)

Así, el nuevo valor *"0"* incluirá las observaciones que corresponden a *herido leve* (anteriormente *"3"*), mientras que el valor *"1"* albergará aquellas que pertenecen a *muerto* y *herido grave* (*"1"* y *"2"* con anterioridad). Por otro lado, han sido omitidos los datos en los que el grado de lesividad era *ileso* (*"4"*) o *se ignora* (*"5"*), ya que el objetivo principal de este proyecto es obtener información acerca de las lesividades más altas, para así poder trabajar en materia con el fin de reducirlas.

Finalmente, al observarse un problema de desequilibrio, se realizará un equilibrado de los datos, de manera que no exista una clase de observaciones que sea mayoritaria frente a la otra, y

puedan obtenerse resultados más precisos. Todas estas modificaciones realizadas se explicarán con más detalle en los siguientes apartados del trabajo.

5.3. Modificación de las variables

En este apartado se va a explicar en profundidad la primera de las modificaciones que se realiza a las variables del modelo. Como se ha comentado anteriormente, se efectúa una normalización de las variables de entrada (variables independientes), dejando sin modificar la *Lesividad*, ya que ésta es la variable respuesta del modelo. La mayoría de las variables pasarán, tras la transformación, a poder tomar únicamente dos o tres valores diferentes. A continuación, se explican los cambios específicos que se realizan en cada una de dichas variables.

La mayoría de ellas se han transformado en variables ternarias, las cuales pueden tomar tres valores distintos (*0; 0,25 y 1*). Éstas han sido: *Defecto físico previo, Condiciones psicofísicas, Infracciones de velocidad, Infracciones administrativas, Infracciones del conductor, Estado del vehículo y Factores atmosféricos*. El valor *0* de cada una de estas variables se corresponde con la ausencia de infracciones o hechos que puedan originar una mayor lesividad del accidente, mientras que el valor *1* se corresponde con la presencia de dichas infracciones o circunstancias (excesos de velocidad, no respetar la señalización, un exceso de agua en la carretera…). Por otro lado, el valor de *0,25* se reserva para aquellas variables que hayan sido ignoradas en la valoración del accidente.

Asimismo, la variable *Localización de las lesiones más graves* podrá tomar los valores *0,25* o *1*, en el caso de que se ignore esta variable o de que existan lesiones, respectivamente.

Respecto a la variable *Sexo*, ésta tomará el valor *0* si se trata de un hombre, *1* si se trata de una mujer, o *0,5* si se desconoce el género.

Sumado a esto, la variable *Luminosidad* se convertirá en una variable binaria de valor *0* si el siniestro ha sucedido de día, o *1* si ha sucedido de noche.

Mención especial merece el caso de la variable *Tipo de accidente*, la cual desaparece y da lugar a cuatro nuevas variables binarias (*Accidente de tipo alcance*, *Accidente de tipo frontal*, *Accidente de tipo frontolateral* y *Accidente de tipo lateral*), cada una de ellas asociada a una clase de accidente, y que podrán tomar el valor *1* si el siniestro producido ha sido de ese tipo, o *0* si no lo ha sido.

En la siguiente tabla (Tabla 2) se muestran las modificaciones realizadas a cada una de las variables de entrada (variables independientes) de la base de datos con la que se trabaja.

NOMBRE DE LA VARIABLE	ABREVIACIÓN	NUEVO VALOR
Localización de las lesiones más graves	Lesiones	**0,25: Se ignora**
		1: Lesión
Defecto físico previo	Defecto	**0: Sin defecto**
		0,25: Se ignora
		1: Defecto
Condiciones psicofísicas	Condpsic	**0: Condiciones normales**
		0,25: Se ignora
		1: Condiciones de alcohol, drogas, etc.
Sexo	Sexo	**0: Hombre**
		0,5: Desconocido
		1: Mujer
Infracciones de velocidad	Infveloc	**0: No hay infracción**
		0,25: Se ignora
		1: Infracción de velocidad
Infracciones administrativas	Infadm	**0: No hay infracción**
		0,25: Se ignora
		1: Infracción administrativa
Infracciones del conductor	Infcond	**0: No hay infracción**
		0,25: Se ignora
		1: Infracción del conductor
Estado del vehículo	Estado	**0: No tiene defectos**
		0,25: Se ignora
		1: Hay defecto
Luminosidad	Luminos	**0: Día**
		1: Noche
Factores atmosféricos	Factatm	**0: Buen tiempo**
		0,25: Se ignora
		1: Mal tiempo
Accidente de tipo alcance	Tipoacc_alc	**0: Otro tipo de accidente**
		1: Accidente de alcance
Accidente de tipo frontal	Tipoacc_frontal	**0: Otro tipo de accidente**
		1: Accidente frontal
Accidente de tipo frontolateral	Tipoacc_frontolat	**0: Otro tipo de accidente**
		1: Accidente frontolateral
Accidente de tipo lateral	Tipoacc_lat	**0: Otro tipo de accidente**
		1: Accidente lateral

Tabla 2. Modificación de las variables de entrada de la base de datos. (Diseño propio).

Así, con la modificación de las variables de entrada finalizada se procederá a la realización del primer modelo de predicción del trabajo, el cual se abordará y se explicará con más detalle en el apartado siguiente.

6. PROCEDIMIENTO

En esta sección se va a realizar la explicación del procedimiento que se ha llevado a cabo para investigar y analizar la lesividad en los accidentes de tráfico mediante la elaboración de modelos predictivos de *Random Forest*. Para ello, se justificará la metodología del algoritmo que ha sido implementado en R (*RStudio*), la elección realizada para los distintos parámetros de los modelos, los diversos modelos de predicción que han sido elaborados y las medidas que se obtienen para cada uno de ellos, tanto de error como de importancia de las variables.

6.1. Metodología del algoritmo

A continuación, se va a exponer de manera breve la forma en la que se han creado e implementado en R (*RStudio*) los distintos modelos predictivos del proyecto, para los que se ha empleado la técnica de *Random Forest*.

- En primer lugar, se cargan las librerías o paquetes de R que se van a necesitar para posteriores acciones.

- Se asigna la ruta en la que se encuentra el archivo Excel (base de datos) con lo que se va a trabajar a una nueva variable creada.

- Posteriormente, se realiza la lectura de este Excel y se le asigna a otra variable.

- A continuación, la variable que va a ser considerada como la respuesta del modelo (variable dependiente o de salida), es decir, la lesividad, se convierte en factor ya que se trata de una variable cualitativa de tipo ordinal.

- Se emplea la función *set.seed()* para que los resultados del modelo que se van a obtener posteriormente puedan ser replicables.

- Se realiza una división o partición de la base de datos (BBDD) con la que se trabaja, dando lugar a un conjunto de datos de entrenamiento (*training set*) y a otro de prueba (*test set*). Esto permitirá usar posteriormente el método *holdout* como técnica de validación cruzada.

- Es en este momento cuando se crea el modelo predictivo de *Random Forest* y se le asigna a una variable, especificándose el conjunto de datos que ha de usar, la variable respuesta del modelo, sus variables de entrada y los valores de sus parámetros más importantes.

- Desde este punto, las acciones se van a centrar en obtener información y lograr diversos resultados acerca del modelo generado.

- Antes que nada, se obtiene un resumen general del modelo creado mediante el uso de la función *print()*, la cual permite mostrar ciertas medidas de error de dicho modelo.

- Después de esto, se realizan predicciones mediante la función *predict()* a partir del conjunto de datos que se había reservado para realizar pruebas (*test set*) y utilizando el modelo generado. De esta manera, posteriormente se comprueba, en una matriz de confusión, la fiabilidad de dichas predicciones, comparándolas con los valores de salida que realmente se obtenían en dicho conjunto de datos de prueba (*test set*).

- A continuación, se obtienen datos de la importancia de cada una de las variables de entrada en el modelo mediante la función *importance()*, y dichas medidas se muestran en un gráfico con el uso de la función *varImpPlot()*.

- Finalmente, con la función *plot()* se grafica la evolución del error que comete el modelo predictivo en función del valor del parámetro *Ntree* con el que cuente dicho modelo.

Todos los códigos en lenguaje de programación R que han sido empleados e implementados en el entorno estadístico *RStudio* en el marco de la investigación realizada en el proyecto pueden encontrarse en el "Anexo R" ubicado al final de este documento.

6.2. Elección de parámetros de los modelos

En este apartado se va a presentar y justificar la elección llevada a cabo de los distintos valores de los parámetros más importantes con los que cuentan los modelos generados en el trabajo.

En primer lugar, respecto a la partición de la base de datos inicial en un conjunto de entrenamiento (*training set*) y otro de prueba (*test set*), se han procurado obtener agrupaciones de datos que fuesen lo suficientemente grandes como para entrenar al modelo correctamente y como para poder realizar su validación posterior mediante el método de *holdout*. Así, se ha decidido que el **70% del conjunto inicial de datos** pase a formar parte del ***training set* o conjunto de entrenamiento**, mientras que el **30% restante** sea el que se incluya en el ***test set* o conjunto de prueba**.

Por otro lado, en cuanto a uno de los parámetros más importantes de los modelos de *Random Forest*, esto es, *Ntree* o el número de árboles de decisión que forman el bosque, es conocido que cuanto mayor sea su valor mayor va a ser a su vez la fiabilidad del modelo. Sin embargo,

llega un momento en el que, aunque siga aumentando el valor de *Ntree*, dicha precisión del modelo deja de crecer y se estanca. Conocidos estos aspectos, se ha perseguido la elección de un valor para este parámetro que logre obtener una buena fiabilidad del modelo, sin llegar a comprometer el coste temporal en la ejecución del algoritmo. En este sentido, ha resultado de gran utilidad el gráfico que muestra la evolución del error cometido en el modelo frente a la del valor de *Ntree*, constituyendo realmente la fuente principal utilizada para la elección del valor de este parámetro. A continuación, se puede observar dicho gráfico (Fig. 15).

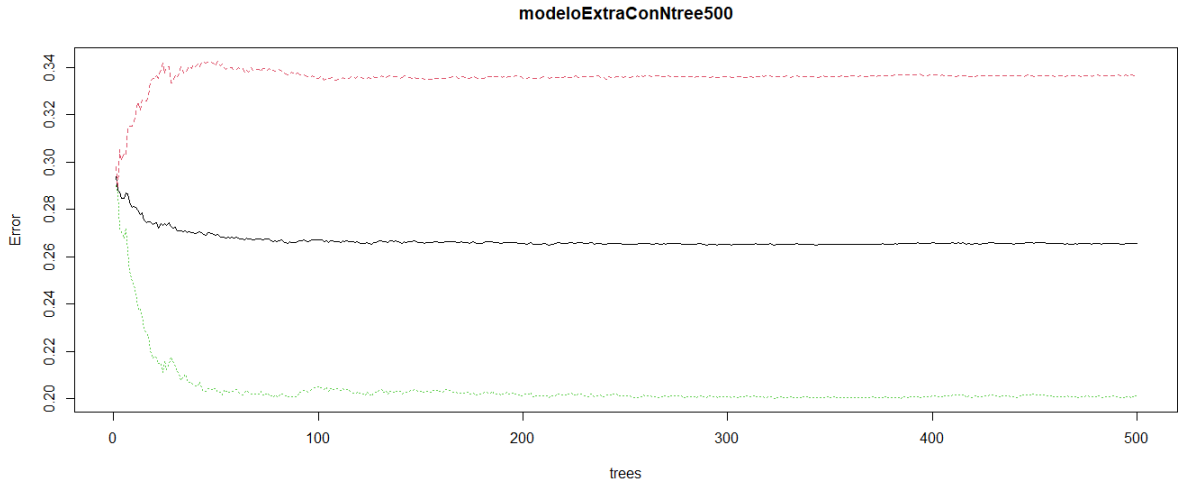


Figura 15. Evolución del error del modelo en función del parámetro Ntree. (Diseño propio).

De esta manera, se ha escogido para el parámetro *Ntree* un valor de "doscientos" **(*Ntree* = 200)**, con el cual se considera que se obtiene un modelo con una fiabilidad bastante alta, como se observa en la anterior imagen, a la vez que no supone un compromiso o coste temporal demasiado elevado al ejecutar el algoritmo.

En otro aspecto, la elección del parámetro *Mtry* o número de variables a tener en cuenta a la hora de realizar la partición de cada uno de los nodos de los árboles, también ha sido importante. La influencia de este parámetro en la precisión del modelo está más condicionada a cada situación y depende de cada problema concreto. Aun así, existen unos valores de *Mtry* que fueron recomendados por los creadores del algoritmo de *Random Forest*, Breiman y Adele, los cuales son: la raíz cuadrada del número de variables de entrada del modelo para problemas de clasificación, y un tercio del número de dichas variables de entrada para problemas de regresión.

En base a esta recomendación y a que se obtienen unos resultados competitivos, se ha decidido dar el valor "cuatro" al parámetro *Mtry* **(*Mtry* = 4)**, ya que en este proyecto se trabaja con un problema de clasificación (al ser la variable de salida una variable cualitativa de tipo ordinal) y el valor recomendado es $\sqrt{14} = 3{,}74$ (siendo 14 el número de variables de entrada del modelo del trabajo), por lo que el valor "cuatro" es el más próximo a dicha recomendación.

Por último, se encuentra un parámetro que no se ha comentado hasta ahora, y que es de bastante menor importancia que el resto. Este parámetro es *Maxnodes* y representa el número máximo de nodos terminales con los que puede contar el *Random Forest* (Bosque Aleatorio). Para él, se ha escogido un valor de "mil" **(*Maxnodes* = 1.000)**, el cual se considera suficiente para no limitar la fiabilidad del modelo predictivo.

6.3. Modelos realizados

A continuación, se explicará de manera detallada la construcción de los distintos modelos que han sido creados en este proyecto empleando la técnica de *Machine Learning* que es conocida como *Random Forest*, y que tienen como objetivo analizar y predecir la lesividad en el ámbito de los accidentes de tráfico.

Todos estos modelos generados son modelos de clasificación, al ser su variable respuesta (la *Lesividad*) una variable cualitativa de tipo ordinal que únicamente puede tomar una serie de valores concretos. Además, dichos modelos se han creado utilizando el lenguaje de programación R y el entorno estadístico *RStudio*, pudiéndose encontrar al final de este documento, en el "Anexo R", los distintos códigos en R que han sido empleados. Finalmente, también conviene destacar que en todos estos modelos se utiliza el método *holdout* para realizar la validación cruzada y poder así cuantificar su fiabilidad.

6.3.1. Modelos principales del trabajo

En este apartado, se van a abordar los modelos principales realizados en el proyecto, los cuales constituyen el núcleo principal de la investigación y análisis llevados a cabo en él. A partir de ellos, se obtendrán los resultados que van a tener mayor influencia y que van a ser de mayor importancia en el trabajo en cuestión, de los que podrán sacarse conclusiones aprovechables en el ámbito de la seguridad vial.

De esta manera, son tres los modelos principales que conforman el trabajo, cada uno de los cuales presenta notorias diferencias en la base de datos o en las variables empleadas frente al resto de modelos.

1. Primer modelo (*Modelo 1*)

En este primer modelo (*Modelo 1*), se trabaja con las variables que han sido elegidas como las más significativas en los accidentes de tráfico. Además, a las variables de entrada del modelo se les ha realizado una transformación mediante su normalización, la cual ya ha sido explicada con anterioridad y quedó reflejada en la *Tabla 2*, donde se muestran los nuevos valores que adquieren dichas variables.

Por otro lado, como ya se ha comentado en reiteradas ocasiones, la variable respuesta (variable dependiente) del modelo es la *Lesividad*, que no sufre transformación alguna respecto a la base de datos original, pudiendo tomar los siguientes valores en función del grado de lesividad alcanzado en el accidente:

- 1 = Muerto
- 2 = Herido grave
- 3 = Herido leve
- 4 = Ileso
- 5 = Se ignora

Mientras, el resto de variables se consideran variables de entrada (variables independientes) y son las siguientes: *Localización de las lesiones más graves, Defecto físico previo, Condiciones psicofísicas, Sexo, Infracciones de velocidad, Infracciones administrativas, Infracciones del conductor, Estado del vehículo, Luminosidad, Factores atmosféricos, Accidente de tipo alcance, Accidente de tipo frontal, Accidente de tipo frontolateral* y *Accidente de tipo lateral*.

De esta forma, para la realización de este modelo se utiliza una base de datos que contiene un total de 145.904 observaciones, parte de la cual se muestra en la siguiente imagen (Fig. 16).

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	lesiv	lesiones	defecto	condpsic	sexo	infveloc	infadm	infcond	estado	luminos	factatm	tipoacc_al	tipoacc_fr	tipoacc_fr	tipoacc_la
2	3	1	0	0	0	0	0	0	0	1	1	1	0	0	0
3	4	1	0	0	0	0	0	0,25	0	1	1	1	0	0	0
4	3	0,25	0	0	0	0	0,25	0	0	0	1	0	0	1	0
5	4	0,25	0	0	0	0	0,25	0	0	0	1	0	0	1	0
6	3	0,25	0	0	0	0	0	1	0	1	0	0	0	1	0
7	4	0,25	0	1	0	0	0,25	1	0	1	0	0	0	1	0
8	2	1	0	0	0	0	0	0	0	0	0	0	1	0	0
9	3	1	0	0	0	1	0	1	0	0	0	0	1	0	0
10	3	0,25	0	0	0	0	0	0	0	0	0	0	0	1	0
11	4	0,25	0	1	0	1	0,25	1	0	0	0	0	0	1	0
12	3	0,25	0	0	0	0	0	0	0	1	1	0	1	0	0
13	3	0,25	0	0	1	0	0	1	0	1	1	0	1	0	0
14	3	1	0	0	1	0	0	1	0	0	0	0	1	0	0
15	2	1	0	0	1	0	0	0	0	0	0	0	1	0	0
16	4	0,25	0,25	0	0	0,25	0	1	0	0	0	0	0	1	0
17	3	1	0,25	0	1	0	0	0	0	0	0	0	0	1	0
18	4	0,25	0	0	0	0	0	0	0	0	0	0	0	1	0
19	2	1	0	0	0	0,25	0	1	0	0	0	0	0	1	0
20	2	0,25	0	0,25	1	0	0	1	0	0	0	0	0	1	0
21	3	0,25	0	0,25	0	0	0	0	0	0	0	0	0	1	0
22	2	0,25	0	0	0	0	1	0,25	0	0	0	0	0	1	0
23	3	0,25	0	0	0	0	0	1	0	0	0	0	0	1	0
24	4	0,25	0	0	1	0,25	0,25	0	0	1	1	1	0	0	0
25	3	1	0	0	0	0,25	0,25	1	0	1	1	1	0	0	0
26	3	0,25	0,25	0	0	0,25	0,25	0	0	0	0	1	0	0	0

Figura 16. Parte de la BBDD utilizada para el Modelo 1. (Diseño Propio).

2. Segundo modelo (*Modelo 2*)

Para este segundo modelo (*Modelo 2*), se ha realizado una transformación de la variable de salida o variable respuesta del modelo, es decir, de la *Lesividad*, que se ha convertido en una variable binaria que puede tomar los siguientes valores:

- 0 = HL (*herido leve*)
- 1 = MHG (*muerto* o *herido grave*)

De esta manera, el nuevo valor *"1"* de la variable alberga las observaciones que pertenecen tanto a *muerto* como a *herido grave*, y nuevo el valor *"0"* incluye las correspondientes a *herido leve*. A su vez, aquellas observaciones en las que el grado de lesividad era *ileso* o *se ignora* se han omitido de la nueva base de datos.

Esta modificación atiende al objetivo principal del proyecto de analizar y predecir las lesividades más altas, con el fin de poder implementar ciertas medidas de seguridad que logren reducirlas.

Por otro lado, las variables de entrada no han sufrido ninguna modificación, siguen siendo las mismas que las empleadas en el anterior modelo y siguen teniendo los mismos valores.

La base de datos que es empleada para realizar este modelo ha sufrido una reducción en el número de observaciones totales, al no incluirse los datos en los que la lesividad era *ileso* o *se ignora*. Así, contiene un total de 82.403 observaciones, parte de las cuales pueden observarse en la siguiente imagen (Fig. 17).

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	lesiv	lesiones	defecto	condpsic	sexo	infveloc	infadm	infcond	estado	luminos	factatm	tipoacc_al	tipoacc_fr	tipoacc_fr	tipoacc_la
2	0	1	0	0	0	0	0	0	0	1	1	1	0	0	0
3	0	0,25	0	0	0	0	0,25	0	0	0	1	0	0	1	0
4	0	0,25	0	0	0	0	0	1	0	1	0	0	0	1	0
5	1	1	0	0	0	0	0	0	0	0	0	0	1	0	0
6	0	1	0	0	0	1	0	1	0	0	0	0	1	0	0
7	0	0,25	0	0	0	0	0	0	0	0	0	0	0	1	0
8	0	0,25	0	0	0	0	0	0	0	1	1	0	1	0	0
9	0	0,25	0	0	1	0	0	1	0	1	1	0	1	0	0
10	0	1	0	0	1	0	0	1	0	0	0	0	1	0	0
11	1	1	0	0	1	0	0	0	0	0	0	0	1	0	0
12	0	1	0,25	0	1	0	0	0	0	0	0	0	0	1	0
13	1	1	0	0	0	0,25	0	1	0	0	0	0	0	1	0
14	1	0,25	0	0,25	1	0	0	1	0	0	0	0	0	1	0
15	0	0,25	0	0,25	0	0	0	0	0	0	0	0	0	1	0
16	1	0,25	0	0	0	0	1	0,25	0	0	0	0	0	1	0
17	0	0,25	0	0	0	0	0	1	0	0	0	0	0	1	0
18	0	1	0	0	0	0,25	0,25	1	0	1	1	1	0	0	0
19	0	0,25	0,25	0	0	0,25	0,25	0	0	0	0	1	0	0	0
20	0	0,25	0,25	0,25	0	0	0	1	0	0	0	0	1	0	0
21	0	1	0	0	1	0	0	0	0	0	0	0	1	0	0
22	0	1	0	0	1	0,25	0,25	0	0	1	0	1	0	0	0
23	0	1	0	0	0	0	0	0	0	1	1	1	0	0	0
24	0	1	0	0	0	1	0	1	0	1	1	1	0	0	0
25	0	1	0	0	1	0	0	0	0	1	0	1	0	0	0
26	0	1	0	0	0	0	0	0	0	1	0	0	0	1	0

Figura 17. Parte de la BBDD utilizada para el Modelo 2. (Diseño Propio).

3. Tercer modelo (*Modelo 3*)

La elaboración de este tercer modelo (*Modelo 3*) se debe a que en la base de datos utilizada para la realización del anterior modelo (*Modelo 2*) existía un problema de desequilibrio de datos, siendo el número de observaciones de clase *"0"* (*HL*) más de seis veces superior a las de clase *"1"* (*MHG*). Este inconveniente es muy común en problemas de *Machine Learning*, y provoca que el algoritmo no logre una buena precisión en la clasificación de la clase minoritaria.

Persiguiendo resolver este problema, se ha empleado la técnica del *undersampling*, que consiste en eliminar observaciones de la clase mayoritaria hasta obtener una proporción de datos más o menos equilibrada entre las distintas clases existentes. Así, la modificación que se ha realizado para este *modelo 3* ha sido la eliminación de datos correspondientes a la clase mayoritaria, es decir, a la clase *"0"* (*HL*), hasta lograr una base de datos equilibrada entre ambas clases.

Mientras, las variables de entrada y la variable de salida del modelo siguen siendo las mismas, y pueden tomar los mismos valores que en el modelo anterior.

Cabe destacar que este es el modelo cuya información y resultados van a ser más estudiados y van a resultar de mayor utilidad, ya que van a constituir la base del trabajo que se pueda acometer en términos de medidas preventivas o de campos de acción en el ámbito de la seguridad vial.

Finalmente, su base de datos se ha visto reducida en gran manera debido al empleo de la técnica *undersampling*, que ha hecho que cuente con casi cuatro veces menos de datos que con los que contaba con anterioridad (ahora cuenta con 21.873 observaciones). En la siguiente imagen (Fig. 18) aparece una pequeña proporción de la base de datos utilizada, la cual tiene aproximadamente un 50% de observaciones de cada tipo al encontrarse ya equilibrada.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	lesiv	lesiones	defecto	condpsic	sexo	infveloc	infadm	infcond	estado	luminos	factatm	tipoacc_al	tipoacc_fr	tipoacc_fr	tipoacc_la
2	1	1	0	0	0	0	0	0	0	0	0	0	1	0	0
3	1	1	0	0	1	0	0	0	0	0	0	0	1	0	0
4	1	1	0	0	0	0,25	0	1	0	0	0	0	0	1	0
5	1	0,25	0	0,25	1	0	0	1	0	0	0	0	0	1	0
6	0	0,25	0	0,25	0	0	0	0	0	0	0	0	0	1	0
7	1	0,25	0	0	0	0	1	0,25	0	0	0	0	0	1	0
8	0	1	0	0	1	0	0	0	0	0	0	0	1	0	0
9	0	1	0	0	0	0	0	0	0	1	0	0	0	1	0
10	1	0,25	0	0	0	0,25	1	1	0	0	0	0	0	0	1
11	1	1	0	0	0	1	0,25	1	0	1	0	0	1	0	0
12	1	1	0	0	0	0	0,25	0	0	1	0	0	1	0	0
13	1	1	0	0	1	0,25	0,25	1	0	0	0	0	0	1	0
14	1	1	0	0	0	0	0	0	0	0	0	0	0	1	0
15	1	1	0	0,25	0	1	0	1	0	1	1	0	1	0	0
16	1	1	0	0,25	1	0,25	0	0	0	1	1	0	1	0	0
17	0	1	0	0	0	0,25	0,25	1	0	0	0	0	0	1	0
18	1	1	0	1	0	0,25	0	1	0	0	0	0	0	0	1
19	1	1	0,25	0	0	1	0	1	0	0	1	0	1	0	0
20	1	1	0	0	0	0,25	1	0	0	0	0	1	0	0	0
21	1	1	0	0	0	0,25	0,25	1	0	0	0	1	0	0	0
22	0	0,25	0,25	0	1	0,25	0,25	0	0	0	0	1	0	0	0
23	1	1	0	0	0	0,25	0,25	1	0	0	0	0	0	1	0
24	1	1	0	0	0	0,25	0,25	0	0	0	0	0	0	1	0
25	1	1	0	0	1	0,25	0,25	0	0	0	0	0	0	1	0
26	1	1	0	0	0	0,25	0,25	1	0	0	0	1	0	0	0

Figura 18. Parte de la BBDD utilizada para el Modelo 3. (Diseño Propio).

6.3.2. Modelos extra

En este proyecto también se han realizado modelos predictivos extra de *Random Forest*, que han sido generados a partir del tercer modelo principal del trabajo (*Modelo 3*), y que presentan ciertas alteraciones en las variables de entrada del modelo o en el valor de alguno de sus parámetros. Mientras, no se realiza ninguna modificación sobre la variable de salida (variable respuesta) respecto al *Modelo 3*, siendo ésta la variable *Lesividad*, y pudiendo adquirir los valores *"0"* (*HL*) o *"1"* (*MHG*). Para su construcción, se ha empleado a su vez la misma base de datos que en dicho modelo (Fig. 18), la cual ya se encuentra equilibrada respecto a la clase de sus datos.

Con la generación de estos modelos extra se pretende obtener una serie de resultados en los que sea posible analizar los cambios de fiabilidad o precisión que dichas alteraciones del *Modelo 3* han podido provocar.

a) <u>Eliminando una variable de entrada (catorce modelos)</u>

Al existir un total de catorce variables de entrada (variables independientes) en los modelos principales del trabajo, se han realizado catorce modelos extra, en cada uno de los cuales se ha dejado sin introducir una variable de entrada.

b) <u>Eliminando las dos variables de entrada de mayor importancia (dos modelos)</u>

Se han generado dos modelos en los que han sido suprimidas las dos variables de entrada de mayor influencia, en un modelo según el *Mean Decrease Accuracy* (Disminución Media de la Precisión), y en el otro según el *Mean Decrease Gini* (Disminución Media del Índice de Gini).

c) <u>Eliminando las dos variables de entrada de menor importancia (dos modelos)</u>

A su vez, se han creado dos modelos en los que se han omitido las dos variables independientes de menor importancia del algoritmo, en uno de ellos según el *Mean Decrease Accuracy* (Disminución Media de la Precisión), y según el *Mean Decrease Gini* (Disminución Media del Índice de Gini) en el otro.

d) Eliminando las variables de entrada referidas a infracciones (un modelo)

Se ha generado un modelo en el que se han suprimido las variables de entrada que están referidas a diversos tipos de infracciones cometidas. Estas variables son las siguientes: *Infracciones del conductor, Infracciones de velocidad e Infracciones administrativas*.

e) Eliminando las variables de entrada referidas al tipo de accidente (un modelo)

De manera paralela al anterior modelo, se ha creado otro modelo, pero en este caso omitiendo las variables de entrada que expresan los distintos tipos de accidentes existentes. Así, se han suprimido estas variables: *Accidente de tipo alcance, Accidente de tipo frontal, Accidente de tipo frontolateral y Accidente de tipo lateral*.

f) Modificando el valor del parámetro *Ntree* (un modelo)

Se ha realizado una modificación del parámetro *Ntree* del modelo (número de árboles de decisión del Bosque Aleatorio), incrementando su valor a "quinientos" (*Ntree = 500*). De esta manera, se pretende comprobar que la elección realizada en los modelos principales de dar un valor de "doscientos" a este parámetro (*Ntree = 200*) fue correcta, fundamentándose en el gráfico que muestra la evolución del error del modelo frente al valor de *Ntree*, y en la ausencia de diferencias de fiabilidad entre ambos modelos.

g) Modificando el valor del parámetro *Mtry* (dos modelos)

Finalmente, se han generado dos nuevos modelos realizando cambios en el parámetro *Mtry* (número de variables consideradas a la hora de realizar las particiones en cada uno de los nodos de los distintos árboles). En primer lugar, se le ha dado a dicho parámetro un valor de "cinco" (*Mtry = 5*), con el objetivo de expresar las similitudes en los resultados respecto al tercer modelo principal del trabajo (*Modelo 3*), en los que *Mtry = 4*. En último lugar, se le ha otorgado el valor de "ocho" (*Mtry = 8*), pretendiendo mostrar las diferencias obtenidas, también frente al *Modelo 3* del trabajo.

6.4. Medidas a obtener en los modelos

En este apartado se procede a indicar y explicar cada una de las diferentes magnitudes o medidas que se van a obtener en el proyecto en cuestión tras la ejecución de los distintos modelos predictivos de *Random Forest* elaborados. Estas medidas podrán cuantificar el error de predicción que ha cometido el algoritmo en cuestión, o estimar qué variables de entrada son de mayor importancia o tienen más influencia en la salida del modelo, en este caso, en el grado de lesividad alcanzado en un accidente de tráfico.

6.4.1. Medidas de error del modelo

A continuación, se presentan las distintas magnitudes que van a ser capaces de evaluar la fiabilidad de cada modelo generado, midiendo el error de predicción que lleva asociado cada uno de ellos.

- **Out of Bag Error (OOB Error)**

El *Out of Bag Error* es una medida del error de predicción que se comete en un modelo, cuyo uso es muy común en algoritmos de *Random Forest* y en aquellos que también utilizan la técnica de *"bootstrapping"* en su construcción. Representa la proporción de datos del *OOB Dataset* (conjunto de observaciones que no han sido incluidas en la elaboración de los árboles de decisión) que, al ejecutarse sobre dichos árboles en cuya construcción no han participado, predicen de manera incorrecta el valor de la variable de salida. En este trabajo, en el *apartado 3.3.2.* se ha hablado más a fondo acerca de esta magnitud de error.

Resulta una medida que tiene gran importancia a la hora de analizar los resultados obtenidos de cada algoritmo, que se obtiene en la información general del modelo mediante el uso en lenguaje de programación R de la función *print()*, y la cual va a servir como primera referencia para conocer la exactitud de un modelo.

- **Matrices de confusión**

Las matrices de confusión son herramientas que permiten estimar la fiabilidad de las predicciones efectuadas por un modelo, y son de gran utilidad en *Machine Learning*. Estas estimaciones se realizan representando en las filas de una matriz las observaciones que forman la base de datos usada, separándolas por clases, mientras que en las columnas de dicha matriz

se refleja el conjunto de predicciones realizadas por el modelo, dividiéndolas a su vez según su clase. De esta manera, en las filas quedan reflejadas las observaciones reales, mientras que en las columnas aparecen las predicciones que ha realizado el modelo.

En la siguiente imagen (Fig. 19) se puede observar una matriz de confusión relativa a un problema en el que la variable de salida solamente puede tomar dos valores (*Positivo* y *Negativo*). En el caso de que dicha variable pudiese tomar una cantidad mayor de valores (como sucede en el *modelo 1* de este trabajo), el funcionamiento y las distintas medidas de error que se obtienen a partir de la matriz serían extensibles.

		Predicción	
		Positivos	**Negativos**
Observación	**Positivos**	Verdaderos Positivos (VP)	Falsos Negativos (FN)
	Negativos	Falsos Positivos (FP)	Verdaderos Negativos (VN)

Figura 19. Ejemplo de matriz de confusión. (Zelada, 2017).

De esta manera, el total de observaciones de la base de datos se distribuye en la matriz de confusión anterior de la siguiente forma:

- Verdaderos positivos (*VP*): se corresponden con las observaciones de clase *Positivo* que han sido predichas también de tipo *Positivo,* es decir, que se han clasificado correctamente.

- Verdaderos negativos (*VN*): hacen referencia a los datos de clase *Negativo* que también han sido clasificadas por el modelo como de tipo *Negativo,* es decir, que también han sido predichas de manera correcta.

- Falsos negativos (*FN*): muestran las observaciones que realmente son de tipo *Positivo*, pero que han sido clasificadas como de clase *Negativo*, es decir, de manera defectuosa.

- Falsos positivos (*FP*): indican los datos de clase *Negativo* que se han predicho como de tipo *Positivo*, esto es, de manera también incorrecta.

De esta manera, la diagonal descendente de la matriz de confusión (la que incluye los verdaderos positivos y verdaderos negativos) alberga los datos de los que se ha realizado una correcta predicción, mientras que su diagonal ascendente (donde se incluyen los falsos negativos y falsos positivos) representa los datos predichos de manera errónea.

Por todo lo comentado, las matrices de confusión resultan de gran utilidad para conocer la fiabilidad con la que cuenta un modelo de predicción. Así, los parámetros más importantes con los que se va a trabajar en este proyecto y que permiten medir los errores de predicción son:

- Exactitud o Precisión Global (*Accuracy*): indica la precisión global del modelo de predicción, representando la proporción de observaciones que se han clasificado correctamente (*VP + VN*) respecto al total de datos existentes (*VP + VN +FN + FP*).

$$Precisión\ Global = \frac{VP + VN}{Total\ de\ observaciones}$$

- Precisión Local: representa la proporción del total de observaciones de una clase determinada que el modelo ha predicho de manera correcta. Por ello, se mide para cada uno de los tipos existentes de variable respuesta.

$$P.L._{Positivo} = \frac{VP}{VP + FN} \qquad P.L._{Negativo} = \frac{VN}{VN + FP}$$

En este trabajo se van a obtener dos matrices de confusión en cada modelo predictivo, las cuales se diferencian entre sí en el conjunto de observaciones que se emplea para su construcción. De esta manera, se distingue:

A. Matriz de confusión realizada con el conjunto de entrenamiento (*training set*)

Esta matriz de confusión se genera utilizando el conjunto de observaciones que se ha reservado para entrenar el modelo (*training set*), y sirve como referencia, pero no va a ser la medida de fiabilidad más relevante en el estudio de cada uno de los modelos. Se obtiene, al igual que el *Out of Bag Error*, en la información general del modelo predictivo, a partir de la función de R *print()*.

B. Matriz de confusión realizada con el conjunto de prueba (*test set*)

Esta es la matriz de confusión de mayor importancia, y que junto al *Out of Bag Error*, van a constituir las medidas principales de precisión de cada modelo, y de las cuales va a ser posible obtener conclusiones más certeras respecto a la exactitud de cada uno de ellos.

Se construye utilizando el conjunto de datos reservado inicialmente para realizar pruebas (*test set*), y supone la realización de la validación cruzada de cada modelo de este proyecto con el empleo del método *holdout*, que ya ha sido explicado con anterioridad en el *apartado 3.3.4.*

Para su obtención en *RStudio*, en primer lugar, se emplea la función *predict()* para generar predicciones del conjunto de datos que se había destinado para pruebas (*test set)*. Posteriormente, mediante la función *confusionMatrix()* se representan en una matriz de confusión dichas predicciones realizadas junto con los valores reales de salida de las observaciones del *test set*.

- **Gráfico de la evolución del error del modelo vs. valor del parámetro *Ntree***

Este gráfico va a mostrar la evolución del error cometido por el modelo predictivo en función del valor que adquiera el parámetro *Ntree* (número total de árboles de decisión que forman el Bosque Aleatorio). Va a permitir percatarse de si se ha escogido un valor adecuado para dicho parámetro, y su obtención se logra haciendo uso de la función de R *plot()*.

6.4.2. Medidas de importancia de las variables

La medida de la importancia de cada una de las variables de entrada en un modelo de predicción va a ser posible gracias a las siguientes magnitudes:

- ***Mean Decrease Accuracy* y *Mean Decrease Gini***

Como ya se ha explicado en el *apartado 3.3.5.*, el *Mean Decrease Accuracy* (Disminución Media de la Precisión) es una magnitud que representa la pérdida de precisión que sufre el modelo cuando se excluye una variable de entrada. Mientras que el *Mean Decrease Gini* (Disminución Media del Índice de Gini) expresa la contribución por parte de una variable concreta en la realización de las particiones de los nodos de los distintos árboles de decisión que forman el algoritmo.

Ambas son medidas que expresan la importancia e influencia que tienen cada una de las distintas variables de entrada de un modelo en su variable respuesta o de salida (variable dependiente), y cuanto mayor sean sus valores, mayor será la importancia de dicha variable en el modelo, teniendo a su vez un mayor valor predictivo para el problema en cuestión.

La obtención de estos valores se produce gracias a la función de R *importance()*, mientras que con la función *varImpPlot()* se logra un gráfico en el que se representan dichas magnitudes en orden decreciente para cada una de las variables de entrada del modelo.

7. RESULTADOS

En este apartado, se va a realizar la exposición de los resultados obtenidos en los diversos modelos de análisis y predicción de la lesividad alcanzada en los accidentes de tráfico que han sido generados en este proyecto empleando la técnica específica de autoaprendizaje del *Random Forest*. Además, se lleva a cabo una discusión acerca de dichos resultados obtenidos, tanto de los que expresan el error cometido en la predicción como de los que muestran la importancia de cada una de las distintas variables en la respuesta del modelo.

Por otro lado, se recuerda que todos estos modelos creados son modelos de clasificación, ya que su variable de salida (variable respuesta o dependiente), la *Lesividad*, únicamente puede tomar una serie de valores concretos, cada uno de los cuales expresa un grado diferente de la lesividad que se ha alcanzado en el siniestro vial.

Finalmente, cabe destacar que la totalidad de los resultados han sido obtenidos a partir del entorno estadístico *RStudio*, mediante la programación e implementación de los distintos modelos del proyecto utilizando el lenguaje de programación R.

7.1. Modelos principales

A continuación, se presentan y analizan los resultados de cada uno de los tres modelos principales del trabajo (*Modelo 1*, *Modelo 2* y *Modelo 3*), los cuales constituyen el núcleo trascendental de la investigación, y cuya información es la de mayor relevancia en el ámbito de este proyecto.

7.1.1. Modelo 1

En este primer modelo, la variable respuesta, la *Lesividad*, puede tomar los siguientes cinco valores en función del grado de lesividad alcanzado:

- 1 = Muerto
- 2 = Herido grave
- 3 = Herido leve
- 4 = Ileso
- 5 = Se ignora

Mientras, las variables de entrada (variables independientes) del modelo son: *Localización de las lesiones más graves, Defecto físico previo, Condiciones psicofísicas, Sexo, Infracciones de velocidad, Infracciones administrativas, Infracciones del conductor, Estado del vehículo, Luminosidad, Factores atmosféricos, Accidente de tipo alcance, Accidente de tipo frontal, Accidente de tipo frontolateral* y *Accidente de tipo lateral*.

Por otro lado, la base de datos empleada para su construcción cuenta con un total de 145.904 observaciones.

En la siguiente imagen (Fig. 20) aparece la información general del *Modelo 1* y se muestran sus primeros resultados.

```
> print(modelo1)

Call:
 randomForest(formula = lesiv ~ ., data = training1, mtry = 4,      ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 30.22%
Confusion matrix:
   1   2     3     4   5 class.error
1 17 211   795   223   0   0.9863563
2 32 538  4971  1224   2   0.9204965
3 18 393 32487 16757  15   0.3459432
4  0  99  5631 38062  68   0.1321933
5  0   8    73   350 161   0.7280405
```

Figura 20. Información general y primeros resultados del Modelo 1. (Diseño Propio).

En primer lugar, se observa que el ***Out of Bag (OOB) Error* es de un 30,22%**, el cual no es un mal valor aparentemente, pero que será necesario estudiar junto al resto de medidas de error obtenidas en el modelo.

Además, también se muestra la matriz de confusión realizada a partir del conjunto de datos de entrenamiento (*training set*), que no va a constituir la medida de precisión que se considere de mayor importancia en los distintos modelos generados, pero que va a servir como primera referencia. En ella, a través de las precisiones locales o errores de clasificación de cada una de las clases (mostradas en la tabla mediante el *"class.error"*), se puede contemplar la **escasa fiabilidad en las predicciones de los grados más altos de lesividad**, especialmente de los *muertos* (clase *"1"*) y *heridos graves* (clase *"2"*).

Por otro lado, a continuación (Tabla 3) se puede observar la matriz de confusión que es empleada como medida más importante respecto a la exactitud de los modelos, que se construye con el conjunto de datos reservado para pruebas (*test set*), y que sirve como método de validación cruzada, habiendo hecho uso de la técnica *holdout*. Además, se ha calculado posteriormente la precisión global en las predicciones realizadas junto a las distintas precisiones locales de cada una de las clases de la variable respuesta.

	Predicccciones Realizadas				
Datos Reales	**1**	**2**	**3**	**4**	**5**
1	16	101	319	98	0
2	7	236	2130	526	0
3	3	164	13895	7219	6
4	0	36	2303	16434	23
5	0	1	39	137	76

Tabla 3. Matriz de confusión del Modelo 1 realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 70{,}04\%$$

$$P.L._1 = 3\% \qquad P.L._2 = 8{,}1\% \qquad P.L._3 = 65{,}3\% \qquad P.L._4 = 87{,}4\% \qquad P.L._5 = 30\%$$

De estos resultados, se observa que se logra una **correcta precisión global** de las predicciones, con aproximadamente un **70% de exactitud**. Sin embargo, las **precisiones locales** calculadas muestran que las fiabilidades obtenidas en las **clases *"1" (muertos)* y *"2" (heridos graves)* son excesivamente bajas**, resultando esto un gran inconveniente, ya que precisamente estos altos grados de lesividad son los que más se pretende abordar y analizar con este proyecto.

En otro aspecto, en el siguiente gráfico (Fig. 21) se representa la evolución del error cometido por el modelo predictivo en función del valor que tome su parámetro *Ntree* (número de árboles de decisión que forman el Bosque Aleatorio). Cada una de las líneas que lo forman corresponde a una clase de la variable respuesta (*Lesividad*), mientras que la línea negra lo hace al modelo en general.

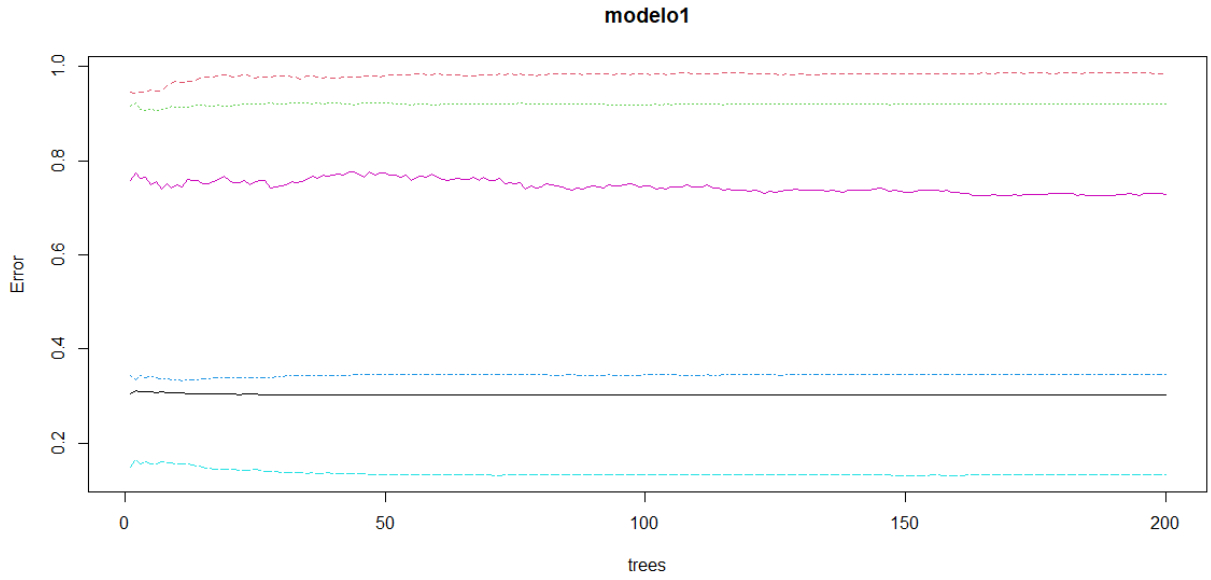


Figura 21. Evolución del error predictivo del Modelo 1 en función del parámetro Ntree. (Diseño propio).

En él, se puede observar como para el valor de *Ntree* escogido (*Ntree = 200*) el error ya se ha estabilizado lo suficiente, por lo que la **elección de este parámetro fue realizada de manera correcta.**

Por su parte, en las siguientes imágenes (Fig. 22 y Fig. 23) se muestra la importancia o influencia de cada una de las variables de entrada (variables independientes) en la salida del modelo, mediante su valor del *Mean Decrease Accuracy* (Disminución Media de la Precisión) y del *Mean Decrease Gini* (Disminución Media del Índice de Gini).

```
> importance(modelo1)

                MeanDecreaseAccuracy MeanDecreaseGini
lesiones                  199.408107      11060.22913
defecto                    43.424605        450.43961
condpsic                   54.971128        627.90071
sexo                      115.014285       1728.27339
infveloc                   22.627029        297.94218
infadm                     33.444137        300.82514
infcond                    55.678275       1520.99049
estado                     39.648459        266.86822
luminos                     4.718015        136.02284
factatm                     2.558170        159.60436
tipoacc_alc                12.982651        389.04317
tipoacc_frontal            28.145440        732.90506
tipoacc_frontolat           8.526987        143.12655
tipoacc_lat                 6.356413         89.81226
```

Figura 22. Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio).

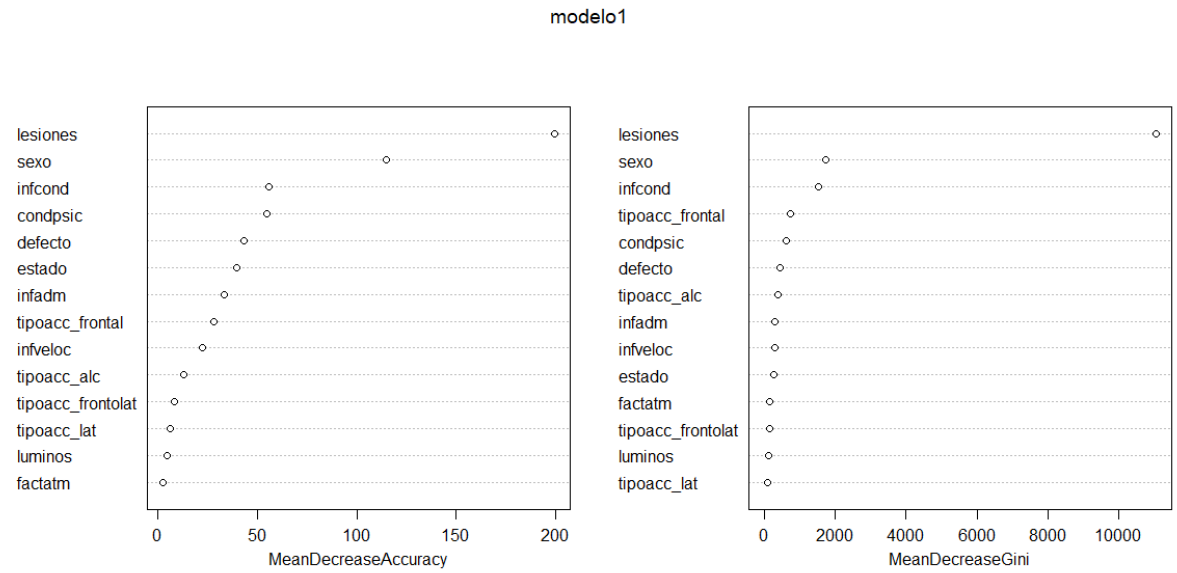


Figura 23. Representación en orden decreciente del Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio).

Según estas medidas, las variables que más influyen en la lesividad, tanto por su Mean Decrease Accuracy como por su Mean Decrease Gini, son *Localización de las lesiones más graves (lesiones)* y *Sexo*. En cambio, las que menos importancia tienen según su Mean Decrease Accuracy son *Factores atmosféricos* y *Luminosidad*, y según su Mean Decrease Gini *Accidente de tipo lateral* y *Luminosidad*.

Sin embargo, estos resultados obtenidos **no se van a poder tomar como referencia** en el proyecto debido a la enorme **falta de precisión** que existe a la hora de **clasificar las observaciones que presentan un grado de lesividad más alto**, en concreto, las que corresponden a *muertos* (*"1"*) y *heridos graves* (*"2"*). Concretamente, estos casos más altos de lesividad son los que más interesa estudiar y analizar a fondo en este trabajo, y los grandes errores que se cometen en su predicción pueden tener origen en el **desequilibrio que existe en la base de datos utilizada** para este modelo, la cual contiene solamente un 7,8% de clases *"1"* y *"2"*, mientras que las clases *"3"* y *"4"* representan el 91,6% del total de observaciones.

7.1.2. Modelo 2

En este nuevo modelo, se realiza una modificación de la variable de salida (*Lesividad*), que pasa a convertirse en una variable binaria y únicamente puede tomar los siguientes dos valores:

- 0 = HL (*herido leve*)
- 1 = MHG (*muerto* o *herido grave*)

De esta manera, el valor *"0"* representa los datos correspondientes a *herido leve* (*HL*), y el valor *"1"* incluye las observaciones tanto de la clase *muerto* como *herido grave* (*MHG*). Por otro lado, se suprimen aquellos datos de tipo *ileso* y *se ignora*, provocando que la base de datos utilizada para este modelo vea reducida el número total de sus observaciones, que pasa a ser 82.403. Mientras, las variables de entrada (variables independientes) siguen siendo las mismas que en el modelo anterior, y no se les ha realizado ningún cambio.

La siguiente imagen (Fig. 24) muestra la información general del *Modelo 2* junto a sus primeros resultados de error.

```
> print(modelo2)

Call:
 randomForest(formula = lesiv ~ ., data = training2, mtry = 4,      ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 12.98%
Confusion matrix:
      0    1 class.error
0 48959  711  0.01431448
1  6775 1238  0.84550106
```

Figura 24. Información general y primeros resultados del Modelo 2. (Diseño propio).

Como se puede observar, el ***Out of Bag (OOB) Error* es de un 12,98%**, cifra la cual es muy competitiva, pero que ha de estudiarse a su vez junto al resto de medidas de error que se obtengan del modelo para poder llegar a conclusiones definitivas.

Por otro lado, la matriz de confusión realizada con el *training set* muestra una **gran probabilidad de fallo (casi un 85%) al clasificar las observaciones de clase *"1"***, esto es, de *muertos* y *heridos graves* (MHG), aspecto el cual va a ser clave en las conclusiones que puedan ser establecidas con este modelo.

Además, a continuación (Tabla 4), aparece la matriz de confusión confeccionada a partir del *test set*, que resulta de mayor importancia para evaluar la exactitud del modelo. También, se ha calculado la precisión global junto a su variación respecto del anterior modelo, y las diversas precisiones locales correspondientes a cada una de las dos clases de respuesta (*Lesividad*) existentes.

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	20967	320
1	2915	518

Tabla 4. Matriz de confusión del Modelo 2 realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 86{,}91\%$$ (↑16,87% respecto al *Modelo 1*)

$$P.L._0 = 98{,}5\% \qquad P.L._1 = 15{,}1\%$$

Se observa un **gran aumento en la precisión global o exactitud** del modelo respecto al *Modelo 1*, alcanzando una cifra del **86,91%**. Además, la **precisión local** de las observaciones **de clase *"0"*** (*heridos leves*) es casi perfecta, llegando hasta un **98,5%**. Sin embargo, no sucede lo mismo con las **observaciones de clase *"1"*** (*muertos* y *heridos graves*), que presentan una **nefasta precisión local de solo un 15,1%**. Ésta es precisamente la clase cuyo comportamiento interesa analizar e investigar en mayor medida en este proyecto, ya que corresponde a los grados de lesividad más altos que se alcanzan y, por tanto, en los que más se requiere un trabajo continuo.

Esta baja fiabilidad del modelo al estudiar la clase que representa la mayor lesividad es **consecuencia de un desequilibrio existente en la base de datos** entre las observaciones de clase *"0"* (*heridos leves*) y de clase *"1"* (*muertos* y *heridos graves*). La clase mayoritaria es la de tipo *"0"* (*heridos leves*), que representa el 86,1% del total de la base de datos, mientras que la de tipo *"1"* (*muertos* y *heridos graves*) representa solo el 13,9% de todos ellos. Esto explica que se obtenga una más que correcta predicción de las observaciones de clase *"0"* (*heridos leves*) y una muy mala de las de clase *"1"* (*muertos* y *heridos graves*), lo que va a ser condicionante respecto a las conclusiones que se obtengan de este modelo.

Por otro lado, en el siguiente gráfico (Fig. 25) se muestra la evolución del error de predicción que comete el modelo frente al valor de su parámetro *Ntree*. La línea verde corresponde a la clase de salida *"1"* (*MHG*), la roja a la clase *"0"* (*HL*) y la negra a la precisión del modelo en general.

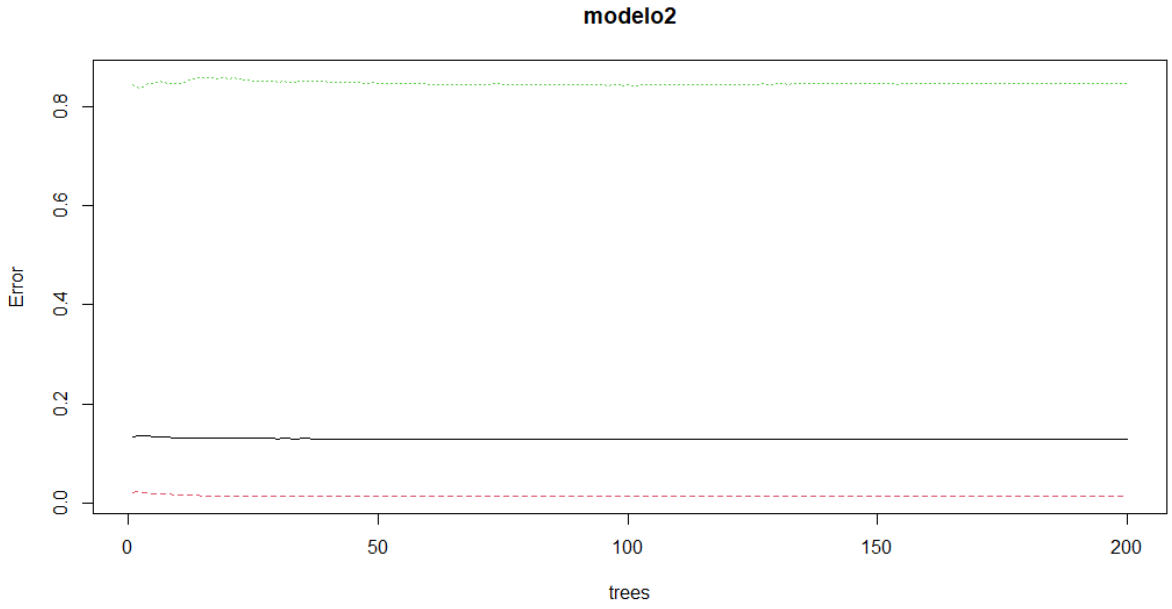


Figura 25. Evolución del error predictivo del Modelo 2 en función del parámetro Ntree. (Diseño propio).

En dicho gráfico, se observa de manera clara como el error ya se ha estabilizado suficientemente para un valor del parámetro *Ntree* de 200 (*Ntree = 200*), que es el que se ha escogido para la realización del modelo. De esta forma, dicha **elección se realizó correctamente**.

En otro aspecto, en las siguientes imágenes (Fig. 26 y Fig. 27) es posible observar la importancia que tiene cada una de las variables sobre la salida del modelo predictivo, esto es, sobre la variable *Lesividad*. Para ello, se muestran el *Mean Decrease Accuracy* y el *Mean Decrease Gini* para cada una de dichas variables, y después se representan en una gráfica en orden decreciente.

```
> importance(modelo2)

                MeanDecreaseAccuracy MeanDecreaseGini
lesiones                  32.9573921        246.31136
defecto                   37.6536705        188.63313
condpsic                  55.7197791        399.71625
sexo                      13.0544923        103.67923
infveloc                  24.3913720        227.46086
infadm                    22.9400244        194.50097
infcond                   29.0997986        283.15661
estado                    35.5076785        263.63151
luminos                    5.0219436         94.12631
factatm                    0.9573881        110.88490
tipoacc_alc               17.5239581        311.22626
tipoacc_frontal           25.0547966        641.86240
tipoacc_frontolat         10.6903783        102.89138
tipoacc_lat                5.3792967         49.29677
```

Figura 26. Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio).

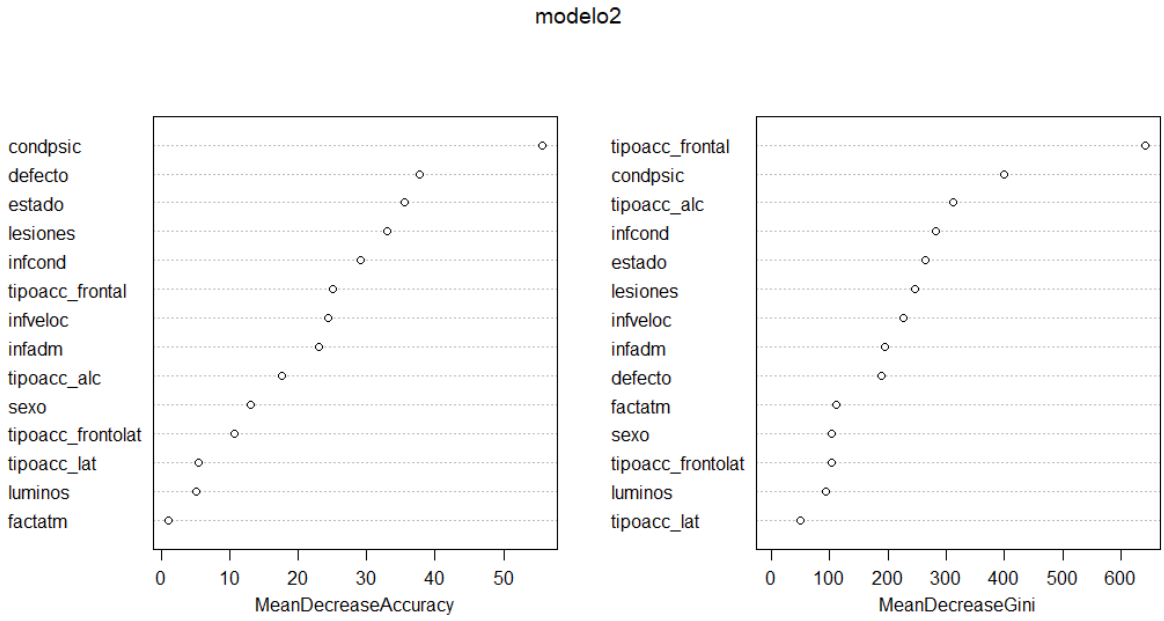


Figura 27. Representación en orden decreciente del Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio).

De esta forma, según el *Mean Decrease Accuracy* la variable de entrada más importante es *Condiciones psicofísicas* seguida de lejos por *Defecto físico previo*. En cambio, si se utiliza el *Mean Decrease Gini* la variable de mayor influencia en la lesividad de salida es *Accidente de tipo frontal* a la que sigue, también de lejos, *Condiciones psicofísicas*. Por otro lado, las variables menos importantes son *Factores atmosféricos* según el *Mean Decrease Accuracy*, y *Accidente de tipo lateral* según el *Mean Decrease Gini*.

Sin embargo, a pesar de que la precisión global del modelo y la precisión local de la clase *"0"* son bastante buenas, la **nefasta precisión local de las lesividades más altas**, esto es, de la clase *"1"* (*muertos* y *heridos graves*), las cuales son las de mayor importancia de cara al análisis que se pretende llevar a cabo, provoca que los **resultados obtenidos en este modelo no sean considerados lo suficientemente certeros** como para llegar a conclusiones a partir de ellos. Como se ha comentado anteriormente, esta falta de fiabilidad es **causa del desequilibrio que presenta la base de datos** empleada en este modelo, en la que la clase *"0"* (*heridos leves*) es mayoritaria, con el 86,1% del total de datos, respecto a la clase *"1"* (*muertos* y *heridos graves*), la cual solo representa el 13,9% de las observaciones totales.

7.1.3. Modelo 3

Para la realización de este tercer y último modelo principal del trabajo, se ha realizado un equilibrado de la base de datos empleando la técnica de *undersampling* (eliminar datos de la clase predominante), de manera que no exista un tipo de datos que sea claramente mayoritario al otro, y obteniendo así una nueva BBDD de la que el 47,7% es de clase *"0"* (*heridos leves*) y el 52,3% es de clase *"1"* (*muertos* y *heridos graves*).

La variable de salida del modelo (*Lesividad*) sigue siendo la misma y no sufre modificación alguna. Así, puede tomar el valor *"0"* si en una observación el grado de la lesividad alcanzada es *herido leve*, o *"1"* si el grado de lesividad es *muerto* o *herido grave*.

Por otro lado, las variables de entrada (variables independientes) del algoritmo se conservan respecto a los dos modelos anteriores, y siguen pudiendo tomar, a su vez, los mismos valores.

A continuación, en esta primera imagen (Fig. 28) puede observarse la información general acerca del modelo de *Random Forest* generado y los primeros resultados obtenidos en cuanto a su error de predicción.

```
> print(modelo3)

Call:
 randomForest(formula = lesiv ~ ., data = training3, mtry = 4,      ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.55%
Confusion matrix:
     0    1 class.error
0 4850 2449   0.3355254
1 1617 6396   0.2017971
```

Figura 28. Información general y primeros resultados del Modelo 3. (Diseño propio).

Como se observa, el valor del ***Out of Bag (OOB) Error*** **sufre un aumento** respecto al *Modelo 2*, alcanzando un valor del **26,55%**. Este aumento en el error general de las predicciones que realiza el modelo, como se apreciará en detalle en la matriz de confusión realizada a partir del *test set* y como ya se ha hecho notar en la matriz de confusión que se muestra en la imagen y que ha sido construida mediante el *training set*, va **acompañado de una gran disminución en el error de clasificación** que se produce en las observaciones **de mayor lesividad**, es decir, de clase *"1"* (*muertos* y *heridos graves*), que es la que más interés tiene en este trabajo.

En este aspecto, la siguiente tabla (Tabla 5) representa la matriz de confusión del modelo, realizada a partir del conjunto de datos reservado para pruebas (*test set*), y la cual ha sido utilizada para calcular la precisión global del modelo y las precisiones locales de las dos clases de respuesta que existen, junto con las variaciones de éstas que se han producido respecto a los modelos anteriores (*Modelo 1* y *Modelo 2*).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2066	1062
1	637	2796

Tabla 5. Matriz de confusión del Modelo 3 realizada a partir del test set. (Diseño propio).

$Precisión\ Global = 74{,}1\%$ (↓12,81% respecto al *Modelo 2*, ↑4,06% respecto al *Modelo 1*)

$P.L._0 = 66{,}1\%$ (↓32,4% respecto al *Modelo 2*) $P.L._1 = 81{,}4\%$ (↑66,3% respecto al *Modelo 2*)

Como se muestra, tanto la **precisión global** del modelo predictivo como la **precisión local de la clase *"0"*** (*heridos leves*) **disminuyen** respecto al anterior modelo (*Modelo 2*), obteniendo para ellas unos valores de **74,1% y 66,1%,** respectivamente. Sin embargo, se produce un **gran aumento de la precisión local** a la hora de clasificar las **observaciones de clase *"1"*** (*muertos* y *heridos graves*), alcanzando una fiabilidad del **81,4%**.

Ésta última **es el tipo de variable respuesta**, es decir, de lesividad alcanzada en un accidente de tráfico, en la que se tiene **más interés de análisis** en el proyecto en cuestión, ya que representa los grados de lesividad más altos posibles, y en los que se hace necesaria una mayor implicación y estudio constantes.

Por otro lado, en el siguiente gráfico (Fig. 29) se representa la evolución del error de predicción que comete el modelo en función del valor que tome su parámetro *Ntree*. La línea roja se corresponde con el error que se produce de la clase *"0"* (*HL*), la línea verde con el de la clase de mayor lesividad, es decir, de la clase *"1"* (*MHG*), y la línea negra con el del modelo en general.

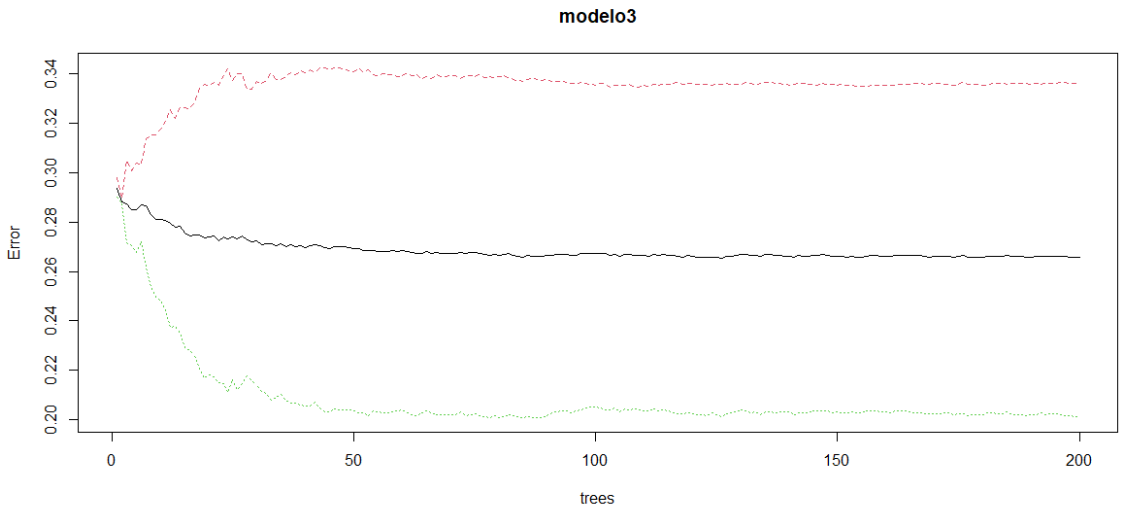


Figura 29. Evolución del error predictivo del Modelo 3 en función del parámetro Ntree. (Diseño propio).

En él, se puede observar como para el valor "doscientos" de *Ntree* (*Ntree = 200*), el cual ha sido el escogido para dicho parámetro, los distintos errores ya se han estabilizado de manera más que suficiente, por lo que se puede concluir que su **elección fue realizada correctamente**.

En otro aspecto, las siguientes imágenes (Fig. 30 y Fig. 31) muestran la importancia o influencia que tienen cada una de las variables de entrada (variables independientes) en la salida o respuesta del modelo, esto es, en la lesividad alcanzada en un siniestro vial. Esta mayor o menor relevancia queda representada mediante sus valores del *Mean Decrease Accuracy* (Disminución Media de la Precisión) y del *Mean Decrease Gini* (Disminución Media del Índice de Gini), los cuales, posteriormente, se muestran ordenados de manera decreciente.

```
> importance(modelo3)

                MeanDecreaseAccuracy MeanDecreaseGini
lesiones                  54.1088293        265.82782
defecto                   33.7201602        147.76798
condpsic                  34.6396728        195.97801
sexo                      16.7192399         81.54783
infveloc                  36.5372721        210.61917
infadm                    34.5724140        172.59260
infcond                   43.8589836        241.19938
estado                    30.7554502        121.01344
luminos                    0.3750979         70.20535
factatm                    8.3212477         84.64142
tipoacc_alc               22.1201620        513.35420
tipoacc_frontal           33.7284600        472.49777
tipoacc_frontolat         16.9499912        116.91084
tipoacc_lat               11.3087256         54.57277
```

Figura 30. Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio).

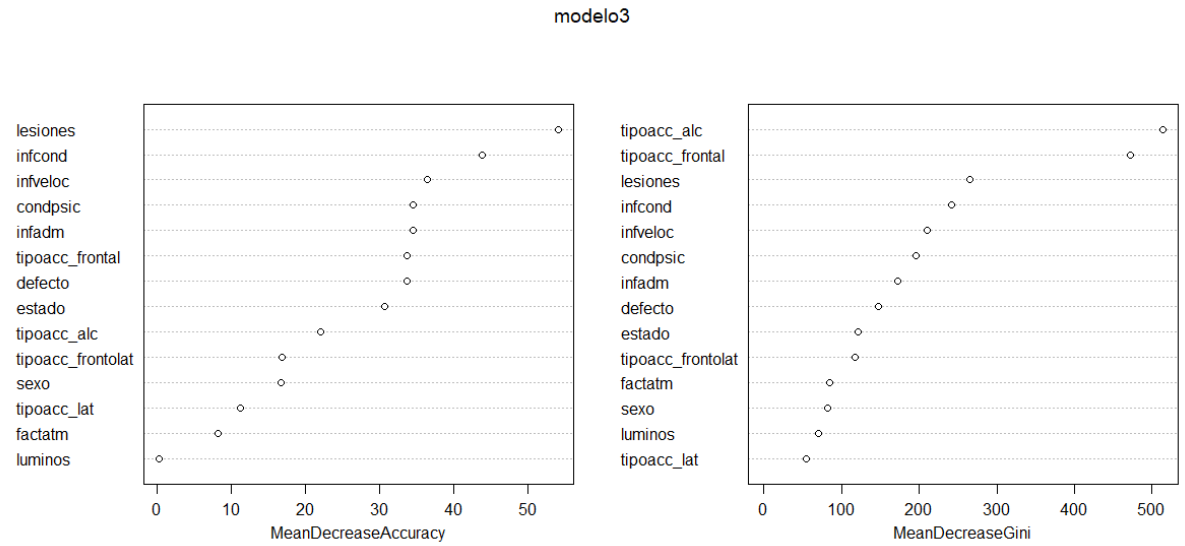


Figura 31. Representación en orden decreciente del Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio).

De esta manera, las variables que presentan una **mayor influencia en la lesividad** que se alcanza en los accidentes de tráfico son ***Localización de las lesiones más graves (lesiones)*** e ***Infracciones del conductor*** según la medida del ***Mean Decrease Accuracy***, mientras que, según el ***Mean Decrease Gini***, son las variables ***Accidente de tipo alcance*** y ***Accidente de tipo frontal***.

Por otro lado, las variables que se consideran, según las medidas del ***Mean Decrease Accuracy***, que tienen una **menor importancia** en dicha lesividad son ***Factores atmosféricos*** y ***Luminosidad***, mientras que, según las medidas del ***Mean Decrease Gini,*** estas variables son ***Accidente de tipo lateral*** y ***Luminosidad***.

Finalmente, cabe destacar que como se obtiene una precisión local bastante buena de las observaciones de clase *"1"* (*muertos* y *heridos graves*), las cuales son las de mayor importancia en el estudio en cuestión, los **resultados obtenidos en este modelo** van a ser considerados como **los más importantes y concluyentes** respecto al análisis llevado a cabo en este proyecto.

En este aspecto, se cuenta con un modelo de análisis y predicción de la lesividad de los accidentes de tráfico en el que el ***OOB Error*** **es de un 26,55%**, la **precisión global** de su matriz de confusión generada a partir del conjunto de datos de prueba (*test set*) es de un **74,1%** y la **precisión local de la clase de lesividad más alta** (*muertos* y *heridos graves*) es de un **81,4%**. Mientras, su **precisión local de la otra clase de lesividad** (*heridos leves*) es de un **66,1%**.

De manera paralela, este modelo ha estimado que las variables o características que tienen **mayor influencia en la lesividad** alcanzada en los accidentes de tráfico son: la **localización** (o existencia) **de las lesiones más graves** que se han producido y **las infracciones cometidas por el conductor**, si se tiene en cuenta la medida del ***Mean Decrease Accuracy*** (Disminución Media de la Precisión); o los **accidentes** que se producen **por alcance** y los **accidentes frontales**, si se considera el ***Mean Decrease Gini*** (Disminución Media del Índice de Gini).

Por ello, éstas pueden ser consideradas las **áreas** en las que, según el modelo de *Machine Learning* generado, resultaría **más provechoso trabajar** con el fin de **reducir la lesividad** que se alcanza habitualmente en los siniestros viales.

7.2. Modelos extra

Por otro lado, a continuación, se muestran y analizan los resultados obtenidos de los diversos modelos extra que han sido generados, en los cuales ha sido realizado algún tipo de modificación del *Modelo 3* del trabajo, bien suprimiendo u omitiendo algunas de las variables de entrada, o bien alterando el valor de algunos de sus parámetros.

De esta manera, todos estos modelos han sido construidos a partir de la misma base de datos que ha sido empleada en el *Modelo 3*, simplemente cambiando ciertos aspectos de su código de implementación en R para así poder adecuarse a los cambios que se ha pretendido realizar en cada uno de ellos. A su vez, la variable respuesta (*Lesividad*) sigue pudiendo tomar el valor *"0"* en el caso de *heridos leves* o *"1"* en el caso de *muertos* o *heridos graves*, mientras que las variables de entrada (independientes) continúan siendo las mismas y no han sufrido ninguna transformación.

Por último, cabe destacar que los resultados que van a ser expuestos y que corresponden a estos modelos extra del trabajo son los que resultan de mayor importancia de cara al análisis que se pueda llevar a cabo a partir de ellos. Así, de cada modelo se va a obtener generalmente el *Out of Bag (OOB) Error* y su matriz de confusión realizada con el conjunto de datos de pruebas (*test set*), con la que se calcula la precisión global y las precisiones locales de cada una de sus clases junto a la variación que ha sufrido cada una de ellas respecto al *Modelo 3*.

7.2.1. Eliminando una variable de entrada

A continuación, se muestran los resultados para cada uno de los modelos en los que una variable de entrada distinta ha sido suprimida en la formación del algoritmo de *Random Forest*. Dicha variable omitida es la que se indica en el título de cada uno de estos modelos.

- *Localización (existencia) de las lesiones más graves*

```
> print(modeloExtraSinLesiones)

Call:
 randomForest(formula = lesiv ~ defecto + condpsic + sexo + infveloc +      infadm + infcond + estado + luminos + factatm + tipoacc_alc +
 tipoacc_frontal + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 27.16%
```

Figura 32. Información general y OOB Error sin la variable Localización (existencia) de las lesiones más graves. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2200	928
1	807	2626

Tabla 6. Matriz de confusión sin la variable Localización de las lesiones más graves, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}56\%$$ (↓0,54% respecto al *Modelo 3*)

$P.L._0 = 70{,}3\%$ (↑4,2% respecto al *Modelo 3*) $P.L._1 = 76{,}5\%$ (↓4,9% respecto al *Modelo 3*)

- *Defecto físico previo*

```
> print(modeloExtraSinDefecto)

Call:
 randomForest(formula = lesiv ~ lesiones + condpsic + sexo + infveloc +      infadm + infcond + estado + luminos + factatm + tipoacc_alc +
  tipoacc_frontal + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.48%
```

Figura 33. Información general y OOB Error sin la variable Defecto físico previo. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2068	1060
1	642	2791

Tabla 7. Matriz de confusión sin la variable Defecto físico previo, realizada a partir del test set. (Diseño propio).

$Precisión\ Global = 74{,}06\%$ (↓0,04% respecto al *Modelo 3, es decir, permanece prácticamente igual*)

$P.L._0 = 66{,}1\%$ (igual respecto al *Modelo 3*) $P.L._1 = 81{,}3\%$ (↓0,1% respecto al *Modelo 3*)

- *Condiciones psicofísicas*

```
> print(modeloExtraSinCondpsic)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + sexo + infveloc +      infadm + infcond + estado + luminos + factatm + tipoacc_alc +
  tipoacc_frontal + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.9%
```

Figura 34. Información general y OOB Error sin la variable Condiciones psicofísicas. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2021	1107
1	620	2813

Tabla 8. Matriz de confusión sin la variable Condiciones psicofísicas, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}68\%$$ (↓0,42% respecto al *Modelo 3*)

$P.L._0 = 64{,}6\%$ (↓1,5% respecto al *Modelo 3*)

$P.L._1 = 81{,}9\%$ (↑0,5% respecto al *Modelo 3*)

- *Sexo*

```
> print(modeloExtraSinSexo)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      infveloc + infadm + infcond + estado + luminos + factatm +
 tipoacc_alc + tipoacc_frontal + tipoacc_frontolat + tipoacc_lat,      data = trainingExtra, mtry = 4, ntree = 200, maxnodes = 1000,
      importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.94%
```

Figura 35. Información general y OOB Error sin la variable Sexo. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2155	973
1	737	2696

Tabla 9. Matriz de confusión sin la variable Sexo, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}94\%$$ (↓0,16% respecto al *Modelo 3*)

$P.L._0 = 68{,}9\%$ (↑2,8% respecto al *Modelo 3*)

$P.L._1 = 78{,}5\%$ (↓2,9% respecto al *Modelo 3*)

- *Infracciones de velocidad*

```
> print(modeloExtraSinInfveloc)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infadm + infcond + estado + luminos + factatm + tipoacc_alc +
 tipoacc_frontal + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.74%
```

Figura 36. Información general y OOB Error sin la variable Infracciones de velocidad. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2069	1059
1	652	2781

Tabla 10. Matriz de confusión sin la variable Infracciones de velocidad, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}92\%$$ (↓0,18% respecto al *Modelo 3*)

$P.L._0 = 66{,}1\%$ (igual respecto al *Modelo 3*)

$P.L._1 = 81\%$ (↓0,4% respecto al *Modelo 3*)

- *Infracciones administrativas*

```
> print(modeloExtraSinInfadm)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infcond + estado + luminos + factatm +      tipoacc_alc +
 tipoacc_frontal + tipoacc_frontolat + tipoacc_lat,      data = trainingExtra, mtry = 4, ntree = 200, maxnodes = 1000,      importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.82%
```

Figura 37. Información general y OOB Error sin la variable Infracciones administrativas. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2063	1065
1	657	2776

Tabla 11. Matriz de confusión sin la variable Infracciones administrativas, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}75\%$$ (↓0,35% respecto al *Modelo 3*)

$P.L._0 = 66\%$ (↓0,1% respecto al *Modelo 3*) $P.L._1 = 80{,}9\%$ (↓0,5% respecto al *Modelo 3*)

- *Infracciones del conductor*

```
> print(modeloExtraSinInfcond)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + estado + luminos + factatm + tipoacc_alc +
   tipoacc_frontal + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.78%
```

Figura 38. Información general y OOB Error sin la variable Infracciones del conductor. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2103	1025
1	689	2744

Tabla 12. Matriz de confusión sin la variable Infracciones del conductor, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}88\%$$ (↓0,22% respecto al *Modelo 3*)

$P.L._0 = 67{,}2\%$ (↑1,1% respecto al *Modelo 3*) $P.L._1 = 79{,}9\%$ (↓1,5% respecto al *Modelo 3*)

- *Estado del vehículo*

```
> print(modeloExtraSinEstado)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + luminos + factatm +      tipoacc_alc +
 tipoacc_frontal + tipoacc_frontolat + tipoacc_lat,      data = trainingExtra, mtry = 4, ntree = 200, maxnodes = 1000,      importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.74%
```

Figura 39. Información general y OOB Error sin la variable Estado del vehículo. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2058	1070
1	640	2793

Tabla 13. Matriz de confusión sin la variable Estado del vehículo, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}94\%$$ (↓0,16% respecto al *Modelo 3*)

$P.L._0 = 65{,}8\%$ (↓0,3% respecto al *Modelo 3*) $P.L._1 = 81{,}4\%$ (igual respecto al *Modelo 3*)

- *Luminosidad*

```
> print(modeloExtraSinLuminos)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + estado + factatm + tipoacc_alc +
 tipoacc_frontal + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.73%
```

Figura 40. Información general y OOB Error sin la variable Luminosidad. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2067	1061
1	621	2812

Tabla 14. Matriz de confusión sin la variable Luminosidad, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 74{,}36\%$$ (↑0,26% respecto al *Modelo 3*)

$P.L._0 = 66{,}1\%$ (igual respecto al *Modelo 3*) $P.L._1 = 81{,}9\%$ (↑0,5% respecto al *Modelo 3*)

- *Factores atmosféricos*

```
> print(modeloExtraSinFactatm)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + estado + luminos + tipoacc_alc +
  tipoacc_frontal + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.44%
```

Figura 41. Información general y OOB Error sin la variable Factores atmosféricos. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2061	1067
1	635	2798

Tabla 15. Matriz de confusión sin la variable Factores atmosféricos, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 74{,}06\%$$ (↓0,04% respecto al *Modelo 3*)

$P.L._0 = 65{,}9\%$ (↓0,2% respecto al *Modelo 3*) $P.L._1 = 81{,}5\%$ (↑0,1% respecto al *Modelo 3*)

- *Accidente de tipo alcance*

```
> print(modeloExtraSinTipoacc_alc)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + estado + luminos + factatm +
 tipoacc_frontal + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.62%
```

Figura 42. Información general y OOB Error sin la variable Accidente de tipo alcance. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2058	1070
1	635	2798

Tabla 16. Matriz de confusión sin la variable Accidente de tipo alcance, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 74{,}01\%$$ (↓0,09% respecto al *Modelo 3*)

$P.L._0 = 65{,}8\%$ (↓0,3% respecto al *Modelo 3*) $P.L._1 = 81{,}5\%$ (↑0,1% respecto al *Modelo 3*)

- *Accidente de tipo frontal*

```
> print(modeloExtraSinTipoacc_frontal)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + estado + luminos + factatm +
 tipoacc_alc + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.56%
```

Figura 43. Información general y OOB Error sin la variable Accidente de tipo frontal. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2027	1101
1	615	2818

Tabla 17. Matriz de confusión sin la variable Accidente de tipo frontal, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}85\%$$ (↓0,25% respecto al *Modelo 3*)

$P.L._0 = 64{,}8\%$ (↓1,3% respecto al *Modelo 3*) $P.L._1 = 82{,}1\%$ (↑0,7% respecto al *Modelo 3*)

- *Accidente de tipo frontolateral*

```
> print(modeloExtraSinTipoacc_frontolat)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + estado + luminos + factatm +
 tipoacc_alc + tipoacc_frontal + tipoacc_lat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.68%
```

Figura 44. Información general y OOB Error sin la variable Accidente de tipo frontolateral. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2072	1056
1	648	2785

Tabla 18. Matriz de confusión sin la variable Accidente de tipo frontolateral, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 74{,}03\%$$ (↓0,07% respecto al *Modelo 3*)

$P.L._0 = 66{,}2\%$ (↑0,1% respecto al *Modelo 3*) $P.L._1 = 81{,}1\%$ (↓0,3% respecto al *Modelo 3*)

- *Accidente de tipo lateral*

```
> print(modeloExtraSinTipoacc_lat)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + estado + luminos + factatm +
 tipoacc_alc + tipoacc_frontal + tipoacc_frontolat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.65%
```

Figura 45. Información general y OOB Error sin la variable Accidente de tipo lateral. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2053	1075
1	625	2808

Tabla 19. Matriz de confusión sin la variable Accidente de tipo lateral, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 74{,}09\%$$ (↓0,01% respecto al *Modelo 3*)

$P.L._0 = 65{,}6\%$ (↓0,5% respecto al *Modelo 3*) $P.L._1 = 81{,}8\%$ (↑0,4% respecto al *Modelo 3*)

En términos generales, se puede observar cómo estas modificaciones realizadas **no producen grandes cambios** en las fiabilidades predictivas obtenidas en los modelos. Además, las variables cuya **eliminación** provoca un **menor descenso de la precisión** del modelo son ***Luminosidad, Factores atmosféricos*** y ***Defecto físico previo***, lo que indica que estas variables no suelen presentar una influencia significativa en la lesividad que se alcanza en los accidentes viales. En el caso de la variable *Luminosidad*, con su omisión incluso se produce un aumento de la precisión global y precisión local de la clase de *muertos* y *heridos graves* que consigue el modelo predictivo, permaneciendo constante la precisión local de la clase *heridos leves*.

En cambio, la **precisión local** del modelo a la hora de predecir los **casos más altos de lesividad**, es decir, los de la clase de *muertos* y *heridos graves* (clase *1*), sufre un **mayor descenso** y se ve más lastrada cuando se realiza la **supresión** de la variable ***Localización* (o existencia) *de las lesiones más graves***, lo que refleja que esta es la variable que cuenta con mayor importancia sobre los siniestros viales en los que se alcanzan altas lesividades.

7.2.2. Eliminando las dos variables de mayor importancia

En este caso, se han omitido del modelo las dos variables de entrada que cuentan con una mayor importancia en su respuesta, en primer lugar, según el *Mean Decrease Accuracy* (Disminución Media de la Precisión), y posteriormente, según el *Mean Decrease Gini* (Disminución Media del Índice de Gini).

- Según el *Mean Decrease Accuracy* (*Localización* (o existencia) *de las lesiones más graves* e *Infracciones del conductor*)

```
> print(modeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy)

Call:
 randomForest(formula = lesiv ~ defecto + condpsic + sexo + infveloc +      infadm + estado + luminos + factatm + tipoacc_alc + tipoacc_frontal +
     tipoacc_frontolat + tipoacc_lat, data = trainingExtra, mtry = 4,      ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 27.95%
```

Figura 46. Información general y OOB Error sin las dos variables más influyentes según el Mean Decrease Accuracy. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2261	867
1	918	2515

Tabla 20. Matriz de confusión sin las dos variables más influyentes según el Mean Decrease Accuracy, realizada a partir del test set. (Diseño propio).

$Precisión\ Global = 72{,}79\%$ (↓1,31% respecto al *Modelo 3*)

$P.L._0 = 72{,}3\%$ (↑6,2% respecto al *Modelo 3*) $P.L._1 = 73{,}3\%$ (↓8,1% respecto al *Modelo 3*)

- Según el *Mean Decrease Gini* (*Accidente de tipo alcance* y *Accidente de tipo frontal*)

```
> print(modeloExtraSin2VarsMasInfluenciaMeanDecreaseGini)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + estado + luminos + factatm +
  tipoacc_frontolat + tipoacc_lat, data = trainingExtra, mtry = 4,      ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 33.24%
```

Figura 47. Información general y OOB Error sin las dos variables más influyentes según el Mean Decrease Gini. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	1766	1362
1	842	2591

Tabla 21. Matriz de confusión sin las dos variables más influyentes según el Mean Decrease Gini, realizada a partir del test set. (Diseño propio).

$Precisión\ Global = 66{,}41\%$ (↓7,69% respecto al *Modelo 3*)

$P.L._0 = 56{,}5\%$ (↓9,6% respecto al *Modelo 3*) $P.L._1 = 75{,}5\%$ (↓5,9% respecto al *Modelo 3*)

En ambos casos, se puede observar cómo se produce una **disminución de la precisión global** del modelo productivo, siendo ésta bastante más acusada cuando se omiten las variables más importantes según el *Mean Decrease Gini*. Además, también se produce una **caída bastante grande de la precisión local para las lesividades más altas** (*muertos* y *heridos graves*), la cual, en este caso, es de mayor magnitud cuando se suprimen las variables de mayor influencia según el *Mean Decrease Accuracy*.

7.2.3. Eliminando las dos variables de menor importancia

Por otro lado, se han eliminado las dos variables independientes que cuentan con una menor influencia en la lesividad alcanzada. De manera paralela a los modelos realizados anteriormente, dichas variables vienen determinadas, en primer lugar, por la Disminución Media de la Precisión, y, en segundo lugar, por la Disminución Media del Índice de Gini.

- Según el *Mean Decrease Accuracy* (*Luminosidad* y *Factores atmosféricos*)

```
> print(modeloExtraSin2VarsMenosInfluenciaMeanDecreaseAccuracy)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond +
 estado + tipoacc_alc +      tipoacc_frontal + tipoacc_frontolat + tipoacc_lat, data = trainingExtra,
  mtry = 4, ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.34%
```

Figura 48. Información general y OOB Error sin las dos variables menos influyentes según el Mean Decrease Accuracy. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2068	1060
1	632	2801

Tabla 22. Matriz de confusión sin las dos variables menos influyentes según el Mean Decrease Accuracy, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 74{,}21\%$$ (↑0,11% respecto al *Modelo 3*)

$P.L._0 = 66{,}1\%$ (igual respecto al *Modelo 3*) $P.L._1 = 81{,}6\%$ (↑0,2% respecto al *Modelo 3*)

- Según el *Mean Decrease Gini* (*Accidente de tipo lateral* y *Luminosidad*)

```
> print(modeloExtraSin2VarsMenosInfluenciaMeanDecreaseGini)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + estado + factatm +
 tipoacc_alc +      tipoacc_frontal + tipoacc_frontolat, data = trainingExtra,      mtry = 4, ntree = 200, maxnodes = 1000,
 importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.82%
```

Figura 49. Información general y OOB Error sin las dos variables menos influyentes según el Mean Decrease Gini. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2059	1069
1	612	2821

Tabla 23. Matriz de confusión sin las dos variables menos influyentes según el Mean Decrease Gini, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 74{,}38\%$$ (↑0,28% respecto al *Modelo 3*)

$P.L._0 = 65{,}8\%$ (↓0,3% respecto al *Modelo 3*) $P.L._1 = 82{,}2\%$ (↑0,8% respecto al *Modelo 3*)

En estos modelos, se observa cómo la supresión de dichas variables, al ser las de menor influencia en la lesividad de los siniestros viales, **no provoca apenas diferencias** en la capacidad predictiva del algoritmo, e incluso produce un incremento de su precisión global y de la precisión local de los casos de lesividad más altos (*muertos* y *heridos graves*).

7.2.4. Eliminando las variables referidas a infracciones

A continuación, se muestran los resultados obtenidos cuando no se introducen en el modelo las variables referidas a los diferentes tipos de infracción existentes. Estas variables son: *Infracciones de velocidad*, *Infracciones administrativas* e *Infracciones del conductor*.

```
> print(modeloExtraSinVarsDeTipoInfraccion)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + estado + luminos + factatm +
 tipoacc_alc + tipoacc_frontal +      tipoacc_frontolat + tipoacc_lat, data = trainingExtra, mtry = 4,
   ntree = 200, maxnodes = 1000, importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 27.74%
```

Figura 50. Información general y OOB Error sin las variables referidas a infracciones. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2152	976
1	785	2648

Tabla 24. Matriz de confusión sin las variables referidas a infracciones, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}16\%$$ (↓0,94% respecto al *Modelo 3*)

$P.L._0 = 68{,}8\%$ (↑2,7% respecto al *Modelo 3*) $P.L._1 = 77{,}1\%$ (↓4,3% respecto al *Modelo 3*)

En este modelo, como puede observarse, se produce una **reducción moderada de su precisión global** o exactitud, y un **gran descenso de la precisión en las observaciones que presentan un alto grado de lesividad** (*clase 1*). Esto muestra la importancia relativa que tienen las variables que expresan el tipo de infracción cometida en la lesividad del incidente.

7.2.5. Eliminando las variables referidas al tipo de accidente

Por otro lado, se han suprimido también las variables que expresan la clase de accidente que se ha producido, las cuales son: *Accidente de tipo alcance*, *Accidente de tipo frontal*, *Accidente de tipo frontolateral* y *Accidente de tipo lateral*.

```
> print(modeloExtraSinVarsDeTipoDeAccidente)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond + estado +
 luminos + factatm,      data = trainingExtra, mtry = 4, ntree = 200, maxnodes = 1000,      importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 4

        OOB estimate of  error rate: 34.05%
```

Figura 51. Información general y OOB Error sin las variables referidas al tipo de accidente. (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	1698	1430
1	805	2628

Tabla 25. Matriz de confusión sin las variables referidas al tipo de accidente, realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 65{,}94\%$$ (↓8,16% respecto al *Modelo 3*)

$P.L._0 = 54{,}3\%$ (↓11,8% respecto al *Modelo 3*) $P.L._1 = 76{,}6\%$ (↓4,8% respecto al *Modelo 3*)

En estos resultados, se muestra cómo **disminuyen claramente las diferentes fiabilidades** de predicción del modelo, tanto la **precisión global** como las **precisiones locales** de ambas clases. Este hecho explica la considerable importancia que tiene el tipo de accidente de tráfico que se produzca en la lesividad que se alcanza en cada uno de ellos, así como en la obtención de un modelo predictivo que presente una correcta fiabilidad.

7.2.6. Modificando *Ntree*

En el modelo que se presenta a continuación, se ha realizado una modificación del valor de su parámetro *Ntree* (número total de árboles de decisión que componen el *Random Forest*), otorgándole un nuevo valor bastante mayor que el que ha sido empleado para los modelos principales del trabajo. Así, se le ha dado el valor de "quinientos" (*Ntree = 500*).

```
> print(modeloExtraConNtree500)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond +
 estado + luminos + factatm +      tipoacc_alc + tipoacc_frontal + tipoacc_frontolat + tipoacc_lat,
 data = trainingExtra, mtry = 4, ntree = 500, maxnodes = 1000,      importance = TRUE)
               Type of random forest: classification
                     Number of trees: 500
No. of variables tried at each split: 4

        OOB estimate of  error rate: 26.58%
```

Figura 52. Información general y OOB Error modificando Ntree (Ntree=500). (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2062	1066
1	640	2793

Tabla 26. Matriz de confusión modificando Ntree (Ntree=500), realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 74\%$$ (↓0,1% respecto al *Modelo 3*)

$P.L._0 = 65{,}9\%$ (↓0,2% respecto al *Modelo 3*) $P.L._1 = 81{,}4\%$ (igual respecto al *Modelo 3*)

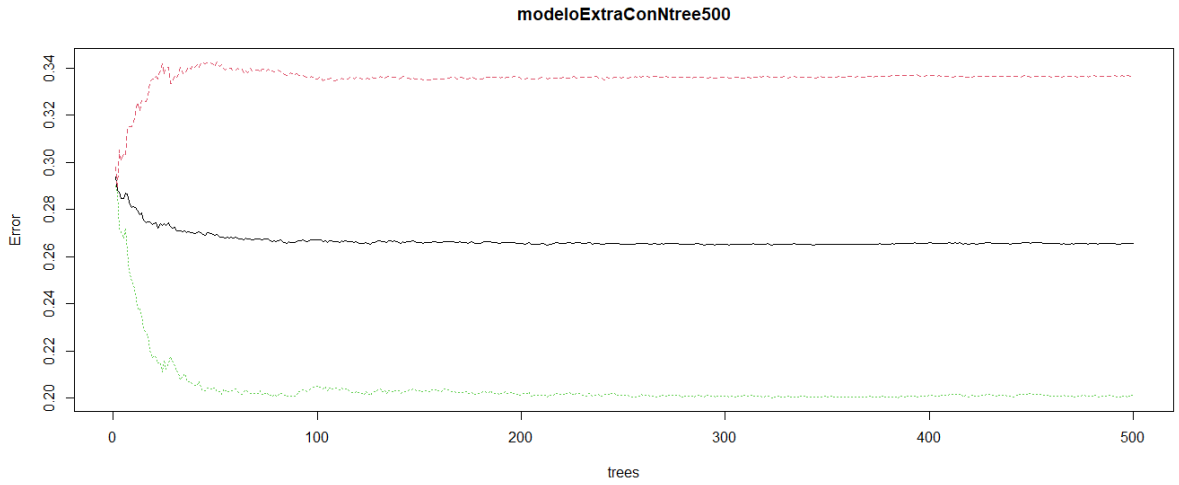


Figura 53. Evolución del error que comete el modelo en función del valor del parámetro Ntree. (Diseño propio).

Se observa cómo el aumento generado del valor de *Ntree* **no supone ninguna mejora** en cuanto a la fiabilidad del modelo predictivo, ni en el ámbito de su precisión global ni en el de ninguna de sus precisiones locales. Además, el último gráfico (Fig. 53) muestra que el error cometido por el modelo se estabiliza de manera temprana, es decir, desde un valor relativamente bajo de *Ntree*. Así, todos estos resultados obtenidos y consideraciones realizadas demuestran que la **elección del parámetro *Ntree*** que fue **realizada** para los modelos principales del trabajo (*Ntree = 200*) **fue correcta**.

7.2.7. Modificando *Mtry*

En los siguientes modelos, se ha realizado una modificación del parámetro *Mtry* (número de variables a considerar a la hora de realizar la partición o división de cada uno de los nodos de los que están formados los árboles de decisión). De esta forma, en uno de los modelos generados se ha optado por un valor de *Mtry* de "cinco" (*Mtry = 5*), el cual es similar al que tiene este parámetro en los modelos principales del trabajo (*Mtry = 4*). Por otro lado, se generó un modelo en el que dicho valor estuviese más alejado del que se ha empleado recurrentemente en el resto de algoritmos de este proyecto, otorgándole un valor de "ocho" (*Mtry = 8*).

- Con *Mtry = 5*

```
> print(modeloExtraConMtry5)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond +
 estado + luminos + factatm +      tipoacc_alc + tipoacc_frontal + tipoacc_frontolat + tipoacc_lat,
 data = trainingExtra, mtry = 5, ntree = 200, maxnodes = 1000,      importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 5

        OOB estimate of  error rate: 26.86%
```

Figura 54. Información general y OOB Error modificando Mtry (Mtry=5). (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2073	1055
1	654	2779

Tabla 27. Matriz de confusión modificando Mtry (Mtry=5), realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}95\%$$ (↓0,15% respecto al *Modelo 3*)

$P.L._0 = 66{,}3\%$ (↑0,2% respecto al *Modelo 3*) $P.L._1 = 81\%$ (↓0,4 respecto al *Modelo 3*)

- Con *Mtry = 8*

```
> print(modeloExtraConMtry8)

Call:
 randomForest(formula = lesiv ~ lesiones + defecto + condpsic +      sexo + infveloc + infadm + infcond +
 estado + luminos + factatm +      tipoacc_alc + tipoacc_frontal + tipoacc_frontolat + tipoacc_lat,
 data = trainingExtra, mtry = 8, ntree = 200, maxnodes = 1000,      importance = TRUE)
               Type of random forest: classification
                     Number of trees: 200
No. of variables tried at each split: 8

        OOB estimate of  error rate: 27.25%
```

Figura 55. Información general y OOB Error modificando Mtry (Mtry=8). (Diseño propio).

	Predicciones Realizadas	
Datos Reales	**0**	**1**
0	2074	1054
1	687	2746

Tabla 28. Matriz de confusión modificando Mtry (Mtry=8), realizada a partir del test set. (Diseño propio).

$$Precisión\ Global = 73{,}46\%$$ (↓0,64% respecto al *Modelo 3*)

$P.L._0 = 66{,}3\%$ (↑0,2% respecto al *Modelo 3*) $P.L._1 = 80\%$ (↓1,4 respecto al *Modelo 3*)

En estos modelos, se observa cómo al emplear un valor de ***Mtry = 5*** se produce un ligero descenso de la precisión que **apenas produce cambios apreciables** en la fiabilidad predictiva del algoritmo. Sin embargo, con el uso de ***Mtry = 8*** se aprecia un **mayor descenso de la exactitud** del modelo, **especialmente en la precisión local** de las observaciones **de *clase 1*** (*muertos* y *heridos graves*).

8. CONCLUSIONES DEL TRABAJO

En el presente Trabajo de Fin de Grado se ha llevado a cabo un estudio con el objetivo de analizar y predecir la lesividad en los accidentes de tráfico. Para ello, ha sido empleada la técnica de *Machine Learning* conocida como *Random Forest* (Bosque Aleatorio), mediante la cual se han generado diversos modelos predictivos haciendo uso del lenguaje de programación R y de su entorno estadístico *RStudio*.

En primer lugar, se realizó la elección, con su posterior modificación, de las variables o características que se consideraron más acordes para la generación del estudio. Además, se concluyó qué valor tomarían los parámetros más importantes del modelo, *Ntree* y *Mtry*.

Sin embargo, en el primer modelo generado se obtuvieron unas excesivamente bajas precisiones a la hora de predecir los casos de lesividad más altos, lo que derivó en una transformación de la variable respuesta del algoritmo, es decir, del grado de lesividad alcanzado en un accidente, que se convirtió en una variable binaria, en la que una de sus clases englobaba a *muertos* y *heridos graves*, mientras que la otra incluía los *heridos leves*.

Así, fue creado el segundo modelo del trabajo, el cual presentó a su vez una bastante mala fiabilidad en las predicciones de las observaciones correspondientes a *muertos* y *heridos graves*, que representan precisamente los casos cuyo análisis resulta de mayor interés en el proyecto en cuestión por tratarse de los grados más altos de lesividad que se pueden alcanzar en un siniestro vial.

La causa de estos malos resultados se encontraba en el desequilibrio existente en la base de datos empleada, en la que una de sus clases era claramente mayoritaria frente a la otra. Esto provocó que se recurriera a realizar un equilibrado de dichos datos empleando la técnica de *undersampling*, hasta que la proporción de sus dos tipos de observaciones fuese similar.

De esta manera, se dio lugar a la generación del tercer y último modelo principal del trabajo, que logra unos resultados aceptables en cuanto a su precisión global, y unos bastante buenos respecto a la precisión local de su clase de mayor lesividad, es decir, la que incluye a *muertos* y *heridos graves*. Este hecho motivó que dicho modelo fuese considerado como el más influyente de cara al análisis que se estaba llevando a cabo, y del cual iba a ser posible sustraer información de mayor utilidad.

En este aspecto, el algoritmo predictivo cuenta con un *Out of Bag Error* del 26,55%, y una precisión global del 74,1%. Mientras, la precisión local de la clase *heridos leves* es del 66,1% frente a un 81,4% de la clase *muertos* y *heridos graves* que, como se comenta, presenta mayor fiabilidad de predicción. Cabe destacar que estas magnitudes se han obtenido a partir de la

matriz de confusión, que se emplea como método de validación cruzada del modelo, y que ha sido generada con el conjunto de datos que había sido reservado para pruebas (*test set*).

Por otro lado, el modelo concluye, empleando dos criterios diferentes, qué variables de entrada tienen una mayor importancia o influencia en su respuesta, esto es, en la lesividad que se alcanza en los accidentes de tráfico. De esta forma, se estima que los factores que mejor explican y que tienen mayor relevancia sobre el grado de lesividad que presenta un siniestro vial son la existencia de lesiones y las infracciones cometidas por el conductor, según el criterio de la Disminución Media de la Precisión, y que el accidente se produzca por alcance o que sea de tipo frontal, según el criterio de la Disminución Media del Índice de Gini. Por tanto, se puede concluir que son en estos aspectos y áreas, sin olvidar el resto, sobre las que más conviene poner el foco cuando se persigue reducir la lesividad que se da en este tipo de sucesos.

En cambio, las variables que se consideran de menor importancia en la lesividad son la luminosidad y los factores atmosféricos si se hace referencia a la Disminución Media de la Precisión, y los accidentes de tipo lateral y la luminosidad si se emplea la Disminución Media del Índice de Gini. Estas características, aunque tengan menos influencia, no hay que olvidar tenerlas en cuenta en el ámbito de la seguridad vial.

Además, fueron realizados varios modelos extra modificando algún aspecto del algoritmo principal, los cuales confirmaron la gran importancia con la que cuenta la presencia de lesiones sobre la lesividad, y la escasa relevancia de la luminosidad y los factores atmosféricos.

Finalmente, es de resaltar la enorme utilidad que presenta la técnica de autoaprendizaje (*Machine Learning*) del *Random Forest*, que proporciona información muy provechosa de cara a posibles investigaciones o estudios que se deseen realizar. En el caso concreto de este proyecto, mediante el uso del lenguaje de programación R, el cual presenta a su vez un amplio abanico de utilidades y funciones de libre acceso con las que puede resultar interesante trabajar, ha generado resultados de gran valor para un ámbito tan importante de la sociedad como el de la seguridad vial.

9. LÍNEAS FUTURAS DE INVESTIGACIÓN

Este proyecto cuenta con una serie de líneas futuras posibles de investigación que podrían resultar de utilidad, y varias de las cuales se presentan a continuación:

- Emplear una técnica o algoritmo predictivo de *Machine Learning* diferente al que ha sido utilizado en este proyecto (*Random Forest*), observando las diferencias en los resultados obtenidos.

- Realizar una selección distinta del conjunto de variables de la base inicial de datos, que se escogen para la elaboración de los diferentes modelos predictivos en base a que se considera que son las de mayor importancia y las que más influencia tendrán.

- Eliminar del modelo todas las variables que, según los resultados obtenidos, no presentan una importancia o influencia significativa sobre la variable respuesta, es decir, sobre la lesividad de los accidentes de tráfico.

- Escoger una variable diferente a la lesividad como respuesta del modelo (variable de salida), con el fin de estudiar y analizar otras características o aspectos de los siniestros viales.

- Utilizar una base de datos más actualizada y diversa, ya que la empleada en este trabajo corresponde al periodo de 2004-2013 e incluye únicamente datos de accidentes producidos en vías interurbanas.

10. PLANIFICACIÓN TEMPORAL

En este apartado se explica la planificación temporal seguida en la elaboración del proyecto en cuestión. Con este fin, a continuación, se presentan desglosadas las distintas fases que ha sido necesario realizar, junto con un diagrama de Gantt (Fig. 56) que muestra la dedicación y extensión en el tiempo de cada una de estas tareas.

1) Planteamiento del proyecto
    a. Elección del tema
    b. Comprensión del tema escogido

2) Aprendizaje de la metodología *Random Forest*
    a. Comprensión de los *CART*
    b. Comprensión del *Random Forest*

3) Comprensión de *RStudio*
    a. Aprendizaje de uso del entorno estadístico
    b. Aprendizaje del lenguaje de programación R
    c. Aprendizaje del empleo de *Random Forest* mediante R

4) Base de datos utilizada
    a. Obtención del conjunto de datos inicial
    b. Comprensión de dicho conjunto de datos

5) Modelos de análisis y predicción
    a. Elección de variables más significantes
    b. Modificación de variables
    c. Generación de los distintos modelos
    d. Obtención de resultados
    e. Conclusiones

6) Redacción de la memoria
    a. Búsqueda de datos respecto a la seguridad vial
    b. Redacción de los resultados obtenidos
    c. Composición del resto del trabajo

7) Revisión
    a. Comprobación con los tutores y últimos cambios
    b. Entrega del proyecto

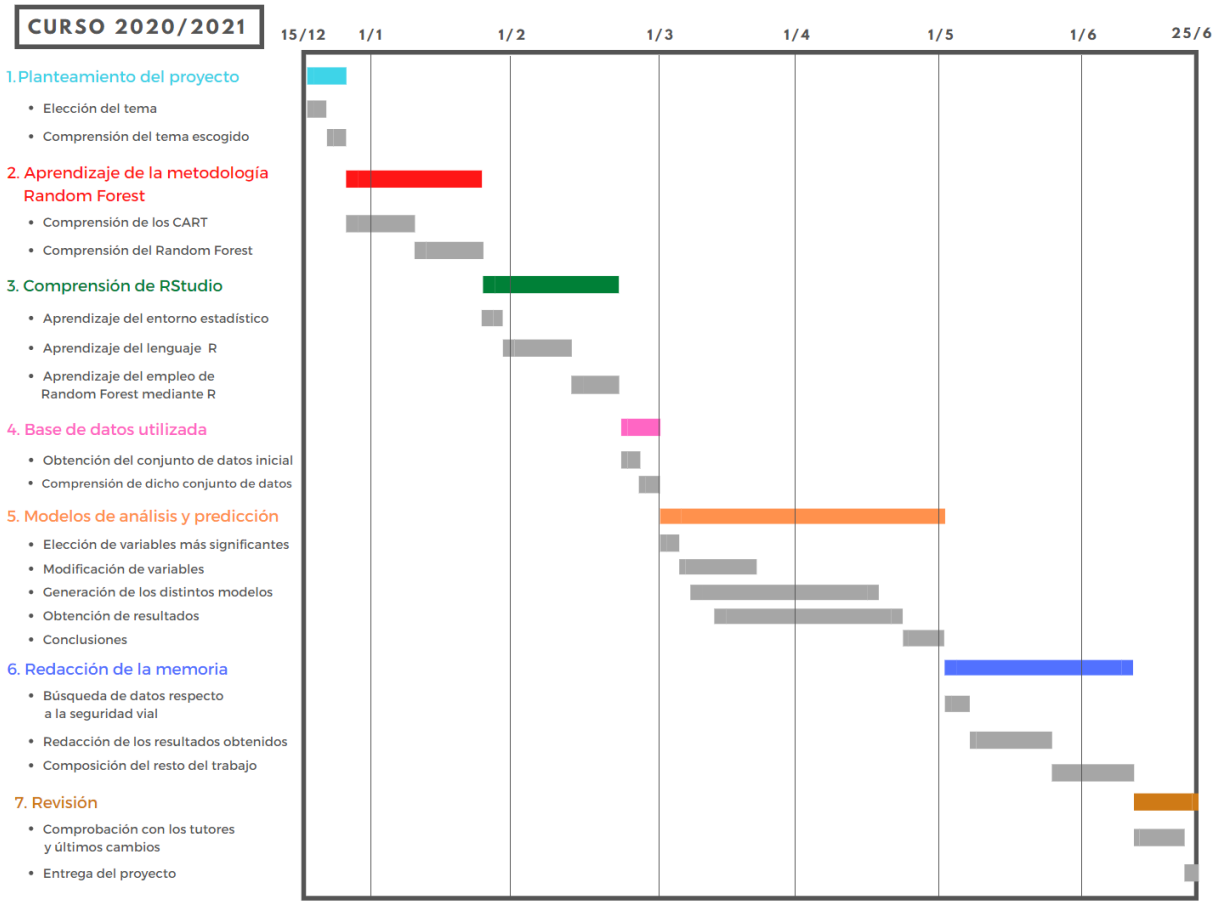


Figura 56. Diagrama de Gantt del proyecto realizado. (Diseño propio).

11. PRESUPUESTO

En este apartado se van a presentar los diferentes costes asociados a la realización del Trabajo de Fin de Grado. Para ello, se desglosará el presupuesto en mano de obra que ha requerido el proyecto y en recursos utilizados.

En primer lugar, respecto a la mano de obra (Tabla 29), se distingue el trabajo realizado por el alumno y la ayuda de sus tutores.

CONCEPTO	Nº DE HORAS EMPLEADAS	COSTE POR HORA (€/H)	COSTE TOTAL (€)
Alumno	370	10	3700
Tutores	30	30	900
COSTE TOTAL DE MANO DE OBRA			**4600**

Tabla 29. Coste de la mano de obra. (Diseño propio).

Por otro lado, en cuanto a los recursos empleados, se diferencian los costes de software, los costes del material utilizado y el coste de la electricidad requerida. Todos ellos aparecen desglosados a continuación (Tabla 30, Tabla 31 y Tabla 32).

CONCEPTO	CANTIDAD EMPLEADA	PRECIO (€)	COSTE TOTAL (€)
Microsoft Office	1	25	25
Rstudio (R)	1	0	0
COSTE TOTAL DE SOFTWARE			**25**

Tabla 30. Coste de software. (Diseño propio).

CONCEPTO	PRECIO DE ADQUISICIÓN (€)	TIEMPO DE VIDA ÚTIL (AÑOS)	TIEMPO EMPLEADO (MESES)	COSTE TOTAL (€)
Ordenador portátil Lenovo	670	5	6,3	70,35
Calculadora	15	20	1,5	0,1
Escritorio	300	15	6,3	10,5
Silla	110	10	6,3	5,78
COSTE TOTAL DE MATERIAL UTILIZADO				**86,73**

Tabla 31. Coste del material utilizado. (Diseño propio).

CONCEPTO	ENERGÍA CONSUMIDA (kWh)	PRECIO MEDIO POR KILOVATIO HORA (€/kWh)	COSTE TOTAL (€)
Electricidad para uso del ordenador	0,15 x 340	0,2	10,2
Electricidad para uso de la lámpara	0,015 x 370	0,2	1,11
COSTE TOTAL DE ELECTRICIDAD			**11,31**

Tabla 32.Coste de electricidad. (Diseño propio).

De esta manera, en la siguiente tabla (Tabla 33) se representa el total de los costes referidos a los recursos utilizados.

CONCEPTO	COSTE TOTAL (€)
Costes de software	25
Costes del material utilizado	86,73
Costes de la electricidad	11,31
COSTE TOTAL DE LOS RECURSOS UTILIZADOS	**123,04**

Tabla 33. Coste total de los recursos utilizados. (Diseño propio).

Finalmente, sumando el coste total de la mano de obra con el de los recursos utilizados, y aplicándole el valor de IVA correspondiente (21%), se obtiene el total del presupuesto neto del proyecto (Tabla 34).

CONCEPTO	COSTE TOTAL (€)
Coste total de mano de obra	4600
Coste total de los recursos utilizados	123,04
PRESUPUESTO TOTAL ANTES DE APLICAR EL IVA	**4723,04**
Impuesto sobre el Valor Añadido (IVA) (21%)	991,84
PRESUPUESTO TOTAL NETO DEL PROYECTO	**5714,88**

Tabla 34. Presupuesto total neto del proyecto. (Diseño propio).

De esta forma, el **presupuesto total neto** asociado a la realización de este Trabajo de Fin de Grado es de **5.714,88 €**.

12. ACRÓNIMOS Y ABREVIATURAS

- TFG: Trabajo de Fin de Grado
- UE: Unión Europea
- OMS: Organización Mundial de la Salud
- DGT: Dirección General de Tráfico
- PIB: Producto Interior Bruto
- CART: Classification and Regression Trees
- OOB: Out of Bag
- BBDD: Base de datos
- HL: Heridos leves
- MHG: Muertos y heridos graves
- IVA: Impuesto sobre el Valor Añadido
- Lesiv: Lesividad
- Lesiones: Localización (o existencia) de las lesiones más graves
- Defecto: Defecto físico previo
- Condpsic: Condiciones psicofísicas
- Infveloc: Infracciones de velocidad
- Infadm: Infracciones administrativas
- Infcond: Infracciones del conductor
- Estado: Estado del vehículo
- Luminos: Luminosidad
- Factatm: Factores atmosféricos
- Tipoacc_alc: Accidente de tipo alcance
- Tipoacc_frontal: Accidente de tipo frontal
- Tipoacc_frontolat: Accidente de tipo frontolateral
- Tipoacc_lat: Accidente de tipo lateral
- Fig: Figura

13. BIBLIOGRAFÍA

ABC. (19 de Febrero de 2014). *Los gastos por accidentes de tráfico son el 2% del PIB español*. Obtenido de https://www.abc.es/motor-reportajes/20140219/abci-gasto-accidentes-trafico-201402181407.html

Alvear, J. O. (12-16 de Noviembre de 2018). *Arboles de decisión y Random Forest.* Obtenido de https://bookdown.org/content/2031/

Amazon. (s.f.). *Validación cruzada*. Obtenido de https://docs.aws.amazon.com/es_es/machine-learning/latest/dg/cross-validation.html

Arce, J. I. (26 de Julio de 2019). *La matriz de confusión y sus métricas*. Obtenido de https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas/

BBVA. (8 de Noviembre de 2019). *'Machine learning': ¿qué es y cómo funciona?* Obtenido de https://www.bbva.com/es/machine-learning-que-es-y-como-funciona/

Berrendero, J. R. (s.f.). *Introducción a CARET*. Obtenido de https://rpubs.com/joser/caret

Cran.r-project. (2018, Marzo 25). *Package 'randomForest'*. Retrieved from https://cran.r-project.org/web/packages/randomForest/randomForest.pdf

D. Buskirk, T., & Kolenikov, S. (2015, Febrero 20). *Finding Respondents in the Forest: A Comparison of Logistic Regression and Random Forest Models for Response Propensity Weighting and Stratification*. Retrieved from https://surveyinsights.org/?p=5108

Delgado, A. (17 de Mayo de 2021). *Más vida, menos ruidos y menos humos*. Obtenido de https://revista.dgt.es/es/noticias/nacional/2021/05MAYO/0517-Jornada30.shtml

Delgado, R. (18 de Julio de 2018). *Introducción a la Validación Cruzada (k-fold Cross Validation) en R*. Obtenido de http://rstudio-pubs-static.s3.amazonaws.com/405322_6d94d05e54b24ba99438f49a6f8662a9.html

Dirección General de Tráfico (DGT). (2019). *Tablas estadísticas*. Obtenido de https://www.dgt.es/es/seguridad-vial/estadisticas-e-indicadores/accidentes-30dias/tablas-estadisticas/

Dirección General de Tráfico (DGT). (11 de Noviembre de 2020). *Políticas internacionales de seguridad vial relevantes para el decenio 2021-2030*. Obtenido de https://www.dgt.es/es/seguridad-vial/paises-y-organizaciones-internacionales/Documentacion/Politicas_internacionales_de_seguridad_vial_relevantes_para_el_decenio_2021_2030.shtml

Dirección General de Tráfico (DGT). (2021). *España, entre los cuatro países con menos accidentes*. Obtenido de https://revista.dgt.es/es/noticias/nacional/2021/04ABRIL/0421-Informe-CE-accidentalidad-en-europa.shtml#:~:text=Espa%C3%B1a%20con%2029%20fallecidos%20por,como%20Holanda%20(31)%2C%20Alemania

Dirección General de Tráfico (DGT). (s.f.). *Series históricas*. Obtenido de https://www.dgt.es/es/seguridad-vial/estadisticas-e-indicadores/accidentes-30dias/series-historicas/index.shtml

Dirección General de Tráfico (DGT). (s.f.). *Tablas estadísticas 2019*. Obtenido de https://www.dgt.es/es/seguridad-vial/estadisticas-e-indicadores/accidentes-30dias/tablas-estadisticas/2019/

Economía Digital. (1 de Febrero de 2016). *Las consecuencias económicas de los accidentes de tráfico*. Obtenido de https://www.economiadigital.es/politica/las-consecuencias-economicas-de-los-accidentes-de-trafico_181429_102.html

El Orden Mundial. (1 de Septiembre de 2020). *Los muertos por accidentes de tráfico en el mundo*. Obtenido de Los muertos por accidentes de tráfico en el mun

El Periódico. (11 de Mayo de 2021). *Límite de velocidad a 30km/h: ¿Qué vías se ven afectadas?* Obtenido de https://www.elperiodico.com/es/sociedad/20210511/limite-de-velocidad-30km-h-calles-sentido-unico-reglamento-circulacion-espana-11715341

Eurostat. (2021). *People killed in road accidents*. Retrieved from https://ec.europa.eu/eurostat/databrowser/view/sdg_11_40/default/line?lang=en

Geron, A. (2019). *Hands-On Machine Learning with Scikit-Lear (2nd edition).* O'REILLY.

González, A. (s.f.). *¿Qué es Machine Learning?* Obtenido de https://cleverdata.io/que-es-machine-learning-big-data/

González, M. (20 de Septiembre de 2019). *El impacto económico de los accidentes de tráfico en España*. Obtenido de https://cocaadvocats.com/es/el-impacto-economico-de-los-accidentes-de-trafico-en-espanya

Gutiérrez, A. (22 de Enero de 2018). *Las muertes en accidente de tráfico frenan el crecimiento económico*. Obtenido de https://revista.dgt.es/es/noticias/internacional/2018/0122banco-mundial-seguridad-vial-y-economia.shtml

Hastie, T., Tibshirani, R., & Friedman, J. (2008). *The Elements of Statisitical Learning (2nd edition)*. Springer.

Heras, J. M. (18 de Septiembre de 2020). *Random Forest (Bosque Aleatorio): combinando árboles*. Obtenido de https://www.iartificial.net/random-forest-bosque-aleatorio/

Hernández, F. (18 de Marzo de 2021). *Modelos Predictivos*. Obtenido de https://fhernanb.github.io/libro_mod_pred/

Hernández, F., & Mazo, M. (30 de Octubre de 2020). *Modelos de Regresión con R*. Obtenido de https://fhernanb.github.io/libro_regresion/predict.html

How do you explain 'mean decrease accuracy' and 'mean decrease gini' in layman's terms? (n.d.). Retrieved from https://www.quora.com/How-do-you-explain-%E2%80%98mean-decrease-accuracy%E2%80%99-and-%E2%80%98mean-decrease-gini%E2%80%99-in-layman%E2%80%99s-terms

Iberdrola. (s.f.). *Descubre los principales beneficios del 'Machine Learning'*. Obtenido de https://www.iberdrola.com/innovacion/machine-learning-aprendizaje-automatico

Instituto Nacional de Salud Pública de México. (26 de Agosto de 2020). *México, séptimo lugar mundial en siniestros viales*. Obtenido de https://www.insp.mx/avisos/4761-seguridad-vial-accidentes-transito.html

Lantz, B. (2015). *Machine Learning with R (2nd edition)*. Packt Publishing.

Martinez-Taboada, F., & Ignacio Redondo, J. (2020, Abril 1). *Variable importance plot (mean decrease accuracy and mean decrease Gini)*. Retrieved from https://plos.figshare.com/articles/figure/Variable_importance_plot_mean_decrease_accuracy_and_mean_decrease_Gini_/12060105/1

Merayo, P. (2020). *QUÉ SON LOS ÁRBOLES DE DECISIÓN Y PARA QUÉ SIRVEN*. Obtenido de https://www.maximaformacion.es/blog-dat/que-son-los-arboles-de-decision-y-para-que-sirven/

Merino, Á. (2020). *Gráfico, Fuente: Organización para la Cooperación y el Desarrollo Económicos.* Obtenido de https://elordenmundial.com/mapas/muertos-accidentes-trafico-mundo/

Observatorio Nacional de Seguridad Vial. (16 de Octubre de 2020). *Políticas internacionales de seguridad vial relevantes para el decenio 2021-2030.* Obtenido de https://www.dgt.es/Galerias/seguridad-vial/paises-y-organizaciones-internacionales/Documentacion/2021/20201016.-Politicas-internacionales-de-SV-para-2021-2030_v.1.3.pdf

Organización Mundial de la Salud (OMS). (Julio de 2017). *10 datos sobre la seguridad vial en el mundo*. Obtenido de https://www.who.int/features/factfiles/roadsafety/es/

Paradis, E. (3 de Marzo de 2003). *R para Principiantes.* Obtenido de https://cran.r-project.org/doc/contrib/rdebuts_es.pdf

Raschka, S., & Mirjalili, V. (2017). *Python Machine Learning (2nd edition).* Packt Publishing.

R-coder. (s.f.). *Fijar semilla en R*. Obtenido de https://r-coder.com/fijar-semilla-r/#:~:text=El%20prop%C3%B3sito%20de%20la%20funci%C3%B3n,(con%20el%20argumento%20kind%20).

R-coder. (s.f.). *Plot en R*. Obtenido de https://r-coder.com/plot-en-r/#:~:text=La%20funci%C3%B3n%20plot%20en%20R,de%20los%20datos%20de%20entrada.&text=Con%20la%20funci%C3%B3n%20plot%20se,de%20los%20argumentos%20de%20entrada.

RDocumentation. (n.d.). *Importance: Extract variable importance measure*. Retrieved from https://www.rdocumentation.org/packages/randomForest/versions/4.6-14/topics/importance

RDocumentation. (n.d.). *varImpPlot: Variable Importance Plot*. Retrieved from https://www.rdocumentation.org/packages/randomForest/versions/4.6-14/topics/varImpPlot

Redacción APD. (4 de Marzo de 2019). *¿Qué es Machine Learning y cómo funciona?* Obtenido de https://www.apd.es/que-es-machine-learning/

Rodrigo, J. A. (Febrero de 2017). *Árboles de decisión, random forest, gradient boosting y C5.0*. Obtenido de https://www.cienciadedatos.net/documentos/33_arboles_decision_random_forest_gradient_boosting_c50

Rpubs. (s.f.). *Creación de modelos*. Obtenido de https://rpubs.com/ljencisoo/509744

Salas, J. G. (7 de Mayo de 2018). *23 - La técnica de Random Forest en RStudio*. Obtenido de https://www.youtube.com/watch?v=HJB6XFkmezM

Sampere, Á. G. (11 de Agosto de 2016). *Accidentes de tráfico: Principal causa de muerte de los jóvenes*. Obtenido de https://revista.dgt.es/es/noticias/internacional/2016/0810-Accidente-trafico-jovenes.shtml

SAS. (s.f.). *Aprendizaje automático: Qué es y por qué es importante*. Obtenido de https://www.sas.com/es_es/insights/analytics/machine-learning.html

Serrano, C. (22 de Julio de 2019). *Datos compuestos en R: Factores*. Obtenido de https://cio.edu.umh.es/2019/07/22/datos-compuestos-en-r-factores/

Simplilearn. (2018, Octubre 17). *Random Forest In R | Random Forest Algorithm | Random Forest Tutorial |Machine Learning |Simplilearn*. Retrieved from https://www.youtube.com/watch?v=HeTT73WxKIc

Starmer, S. w. (2018, Enero 22). *StatQuest: Decision Trees*. Retrieved from https://www.youtube.com/watch?v=7VeUPuFGJHk

Starmer, S. w. (2018, Febrero 5). *StatQuest: Random Forests Part 1 - Building, Using and Evaluating*. Retrieved from https://www.youtube.com/watch?v=J4Wdy0Wc_xQ

Vega, J. B. (9 de Julio de 2016). *Importar hojas de cálculo de Excel a R con readxl*. Obtenido de https://rpubs.com/jboscomendoza/importar_hojas_calculo_excel_r_readxl

Vega, J. B. (s.f.). *R para principiantes.* Obtenido de https://bookdown.org/jboscomendoza/r-principiantes4/hojas-de-calculo-de-excel.html

Wikipedia. (s.f.). *Aprendizaje automático*. Obtenido de https://es.wikipedia.org/wiki/Aprendizaje_autom%C3%A1tico

Wikipedia. (s.f.). *Aprendizaje basado en árboles de decisión*. Obtenido de https://es.wikipedia.org/wiki/Aprendizaje_basado_en_%C3%A1rboles_de_decisi%C3%B3n

Wikipedia. (s.f.). *R (lenguaje de programación)*. Obtenido de https://es.wikipedia.org/wiki/R_(lenguaje_de_programaci%C3%B3n)

Wikipedia. (s.f.). *Random forest*. Obtenido de https://es.wikipedia.org/wiki/Random_forest

Wikipedia. (s.f.). *Rstudio*. Obtenido de https://es.wikipedia.org/wiki/RStudio

Wikipedia. (s.f.). *Validación cruzada*. Obtenido de https://es.wikipedia.org/wiki/Validaci%C3%B3n_cruzada

Zelada, C. (10 de Mayo de 2017). *Evaluación de modelos de clasificación*. Obtenido de https://rpubs.com/chzelada/275494

14. ÍNDICE DE FIGURAS

Figura 1. Muertos en accidentes de tráfico por cada 100.000 habitantes (2017). (Merino, 2020). 12
Figura 2. Número de víctimas mortales en accidentes de tráfico en la Unión Europea. (Eurostat, 2021)..... 13
Figura 3. Tasa de mortalidad (por cada 100.000 habitantes) en accidentes de tráfico en la Unión Europea..... 14
Figura 4. Número de víctimas mortales en accidentes de tráfico en España. (Eurostat, 2021). 14
Figura 5. Tasa de mortalidad (por cada 100.000 habitantes) en accidentes de tráfico en España. (Eurostat, 2021). 15
Figura 6. Evolución de la tasa de mortalidad en accidentes de tráfico en España (verde) vs en Europa (azul). 16
Figura 7. Ejemplo de un CART con dos variables independientes (X1 y X2) en el que se han realizado cinco particiones. 22
Figura 8. División del espacio de dos dimensiones en seis regiones (R_1-R_6). (Alvear, 2018). 23
Figura 9. Random Forest para problemas de clasificación y de regresión. (Hernández, Modelos Predictivos, 2021)..... 28
Figura 10. Variación del OOB Error en función de los parámetros Ntree y Mtry del modelo. (D. Buskirk & Kolenikov, 2015). 30
Figura 11. Método de validación cruzada holdout o de retención. (Wikipedia, s.f.). 31
Figura 12. Validación cruzada de K iteraciones (K-fold cross-validation). (Wikipedia, s.f.) . 32
Figura 13. Validación cruzada aleatoria (Aleatory Cross Validation). (Wikipedia, s.f.). 33
Figura 14. Representación de Mean Decrease Accuracy y Mean Decrease Gini para las variables de entrada de un modelo. (Martinez-Taboada & Ignacio Redondo, 2020). 34
Figura 15. Evolución del error del modelo en función del parámetro Ntree. (Diseño propio). 45
Figura 16. Parte de la BBDD utilizada para el Modelo 1. (Diseño Propio). 47
Figura 17. Parte de la BBDD utilizada para el Modelo 2. (Diseño Propio). 48
Figura 18. Parte de la BBDD utilizada para el Modelo 3. (Diseño Propio). 49
Figura 19. Ejemplo de matriz de confusión. (Zelada, 2017). 53
Figura 20. Información general y primeros resultados del Modelo 1. (Diseño Propio). 58
Figura 21. Evolución del error predictivo del Modelo 1 en función del parámetro Ntree. (Diseño propio). 60
Figura 22. Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio). 60
Figura 23. Representación en orden decreciente del Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio). 61
Figura 24. Información general y primeros resultados del Modelo 2. (Diseño propio). 62
Figura 25. Evolución del error predictivo del Modelo 2 en función del parámetro Ntree. (Diseño propio). 64

Figura 26. Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio). 64
Figura 27. Representación en orden decreciente del Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio). 65
Figura 28. Información general y primeros resultados del Modelo 3. (Diseño propio). 66
Figura 29. Evolución del error predictivo del Modelo 3 en función del parámetro Ntree. (Diseño propio). 68
Figura 30. Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio). 68
Figura 31. Representación en orden decreciente del Mean Decrease Accuracy y Mean Decrease Gini (importancia) de las variables de entrada. (Diseño propio). 69
Figura 32. Información general y OOB Error sin la variable Localización (existencia) de las lesiones más graves. 71
Figura 33. Información general y OOB Error sin la variable Defecto físico previo. (Diseño propio). 72
Figura 34. Información general y OOB Error sin la variable Condiciones psicofísicas. (Diseño propio). 73
Figura 35. Información general y OOB Error sin la variable Sexo. (Diseño propio). 74
Figura 36. Información general y OOB Error sin la variable Infracciones de velocidad. (Diseño propio). 75
Figura 37. Información general y OOB Error sin la variable Infracciones administrativas. (Diseño propio). 76
Figura 38. Información general y OOB Error sin la variable Infracciones del conductor. (Diseño propio). 77
Figura 39. Información general y OOB Error sin la variable Estado del vehículo. (Diseño propio). 78
Figura 40. Información general y OOB Error sin la variable Luminosidad. (Diseño propio). 79
Figura 41. Información general y OOB Error sin la variable Factores atmosféricos. (Diseño propio). 80
Figura 42. Información general y OOB Error sin la variable Accidente de tipo alcance. (Diseño propio). 81
Figura 43. Información general y OOB Error sin la variable Accidente de tipo frontal. (Diseño propio). 82
Figura 44. Información general y OOB Error sin la variable Accidente de tipo frontolateral. (Diseño propio). 83
Figura 45. Información general y OOB Error sin la variable Accidente de tipo lateral. (Diseño propio). 84
Figura 46. Información general y OOB Error sin las dos variables más influyentes según el Mean Decrease Accuracy. (Diseño propio). 85
Figura 47. Información general y OOB Error sin las dos variables más influyentes según el Mean Decrease Gini. 86
Figura 48. Información general y OOB Error sin las dos variables menos influyentes según el Mean Decrease Accuracy. 87

Figura 49. Información general y OOB Error sin las dos variables menos influyentes según el Mean Decrease Gini. 88
Figura 50. Información general y OOB Error sin las variables referidas a infracciones. (Diseño propio). 89
Figura 51. Información general y OOB Error sin las variables referidas al tipo de accidente. (Diseño propio). 90
Figura 52. Información general y OOB Error modificando Ntree (Ntree=500). (Diseño propio). 91
Figura 53. Evolución del error que comete el modelo en función del valor del parámetro Ntree. (Diseño propio). 92
Figura 54. Información general y OOB Error modificando Mtry (Mtry=5). (Diseño propio). 93
Figura 55. Información general y OOB Error modificando Mtry (Mtry=8). (Diseño propio). 94
Figura 56. Diagrama de Gantt del proyecto realizado. (Diseño propio). 99
Figura 57. Código R del Modelo 1. (Diseño propio). 115
Figura 58. Código R del Modelo 2. (Diseño propio). 116
Figura 59. Código R del Modelo 3. (Diseño propio). 117
Figura 60. Código R cuando se elimina la variable Localización de las lesiones más graves (lesiones). (Diseño propio). 118
Figura 61. Código R cuando se eliminan las dos variables de mayor importancia según el Mean Decrease Accuracy. 119
Figura 62. Código R cuando se eliminan las variables referidas a infracciones cometidas. (Diseño propio). 120
Figura 63. Código R cuando se modifica el parámetro Ntree (Ntree = 500). (Diseño propio). 121
Figura 64. Código R cuando se modifica el parámetro Mtry (Mtry = 5). (Diseño propio). .. 122

15. ÍNDICE DE TABLAS

Tabla 1. Comparativa de datos de accidentes de 2009 vs 2019. (Diseño propio, (Dirección General de Tráfico (DGT), 2019)). 15
Tabla 2. Modificación de las variables de entrada de la base de datos. (Diseño propio)..... 41
Tabla 3. Matriz de confusión del Modelo 1 realizada a partir del test set. (Diseño propio). ... 59
Tabla 4. Matriz de confusión del Modelo 2 realizada a partir del test set. (Diseño propio). ... 63
Tabla 5. Matriz de confusión del Modelo 3 realizada a partir del test set. (Diseño propio). ... 67
Tabla 6. Matriz de confusión sin la variable Localización de las lesiones más graves, realizada a partir del test set..... 71
Tabla 7. Matriz de confusión sin la variable Defecto físico previo, realizada a partir del test set. (Diseño propio). 72
Tabla 8. Matriz de confusión sin la variable Condiciones psicofísicas, realizada a partir del test set. (Diseño propio). 73
Tabla 9. Matriz de confusión sin la variable Sexo, realizada a partir del test set. (Diseño propio). 74
Tabla 10. Matriz de confusión sin la variable Infracciones de velocidad, realizada a partir del test set. (Diseño propio). 75
Tabla 11. Matriz de confusión sin la variable Infracciones administrativas, realizada a partir del test set. (Diseño propio). 76
Tabla 12. Matriz de confusión sin la variable Infracciones del conductor, realizada a partir del test set. (Diseño propio). 77
Tabla 13. Matriz de confusión sin la variable Estado del vehículo, realizada a partir del test set. (Diseño propio). 78
Tabla 14. Matriz de confusión sin la variable Luminosidad, realizada a partir del test set. (Diseño propio). 79
Tabla 15. Matriz de confusión sin la variable Factores atmosféricos, realizada a partir del test set. (Diseño propio). 80
Tabla 16. Matriz de confusión sin la variable Accidente de tipo alcance, realizada a partir del test set. (Diseño propio). 81
Tabla 17. Matriz de confusión sin la variable Accidente de tipo frontal, realizada a partir del test set. (Diseño propio). 82
Tabla 18. Matriz de confusión sin la variable Accidente de tipo frontolateral, realizada a partir del test set. (Diseño propio)..... 83
Tabla 19. Matriz de confusión sin la variable Accidente de tipo lateral, realizada a partir del test set. (Diseño propio). 84
Tabla 20. Matriz de confusión sin las dos variables más influyentes según el Mean Decrease Accuracy, realizada a partir del test set. (Diseño propio). 85
Tabla 21. Matriz de confusión sin las dos variables más influyentes según el Mean Decrease Gini, realizada a partir del test set. (Diseño propio)..... 86
Tabla 22. Matriz de confusión sin las dos variables menos influyentes según el Mean Decrease Accuracy, realizada a partir del test set. (Diseño propio). 87

Tabla 23. Matriz de confusión sin las dos variables menos influyentes según el Mean Decrease Gini, realizada a partir del test set. (Diseño propio)..... 88
Tabla 24. Matriz de confusión sin las variables referidas a infracciones, realizada a partir del test set. (Diseño propio). 89
Tabla 25. Matriz de confusión sin las variables referidas al tipo de accidente, realizada a partir del test set. (Diseño propio)..... 90
Tabla 26. Matriz de confusión modificando Ntree (Ntree=500), realizada a partir del test set. (Diseño propio). 91
Tabla 27. Matriz de confusión modificando Mtry (Mtry=5), realizada a partir del test set. (Diseño propio). 93
Tabla 28. Matriz de confusión modificando Mtry (Mtry=8), realizada a partir del test set. (Diseño propio). 94
Tabla 29. Coste de la mano de obra. (Diseño propio)..... 100
Tabla 30. Coste de software. (Diseño propio)..... 100
Tabla 31. Coste del material utilizado. (Diseño propio). 101
Tabla 32.Coste de electricidad. (Diseño propio)..... 101
Tabla 33. Coste total de los recursos utilizados. (Diseño propio)..... 101
Tabla 34. Presupuesto total neto del proyecto. (Diseño propio). 102

16. ANEXO R

A continuación, se muestran los códigos de programación en lenguaje R que han sido creados e implementados en *RStudio* para la generación de los distintos modelos del proyecto.

En primer lugar, se observa el código R del *Modelo 1* (Fig. 57):

```r
#Librerías que se van a utilizar

library(caret)
library(readxl)
library(randomForest)


#Se asigna la ruta del Excel que se va a usar a la variable "ruta_excel1"

ruta_excel1 <- "C:\\Users\\juanh\\OneDrive\\Escritorio\\TFG\\BBDD utilizadas\\BBDD_variablesutilizadas_normalizadas.xlsx"


#Se asigna la lectura del Excel a la variable "BBDD1"

BBDD1 <- read_excel(ruta_excel1)


#Se convierte en factor la variable respuesta, es decir, la lesividad

BBDD1$lesiv <- factor(BBDD1$lesiv)


#Para que los resultados sean replicables se añade la siguiente función

set.seed(2021)


#Se realiza una división o partición de los datos, dando lugar a una parte de entrenamiento (70%) y a otra de test (30%)

t.ind1 <- createDataPartition(BBDD1$lesiv, p=0.7, list=F)
test1 <- BBDD1[-t.ind1,]
training1 <- BBDD1[t.ind1,]


#Se crea el modelo de Random Forest y se le asigna a la variable "modelo1"

modelo1 <- randomForest(lesiv~., data = training1, mtry=4, ntree=200, maxnodes=1000, importance=TRUE)

#A continuación, se va a obtener información y varios resultados del modelo generado

#Resumen del modelo

print(modelo1)


#Realización de predicciones con el conjunto de datos dedicado a test

prediccionModelo1 <- predict(modelo1,test1)


#Matriz de confusión

confusionMatrix(prediccionModelo1,test1$lesiv)


#Importancia de cada variable de entrada en el modelo

importance(modelo1)


#Gráfico de la importancia de cada variable de entrada en el modelo

varImpPlot(modelo1)


#Gráfico del parámetro ntree vs error del modelo

plot(modelo1)

```

Figura 57. Código R del Modelo 1. (Diseño propio).

En segundo lugar, se presenta el código R empleado en la realización del *Modelo 2* (Fig. 58), el cual solo se distingue del anterior en el empleo de una nueva base de datos:

```r
#Librerías que se van a utilizar

library(caret)
library(readxl)
library(randomForest)


#Se asigna la ruta del Excel que se va a usar a la variable "ruta_excel2"

ruta_excel2 <- "C:\\Users\\juanh\\OneDrive\\Escritorio\\TFG\\BBDD utilizadas\\BBDD_variablesutilizadas_normalizadas_tratadas.xlsx"


#Se asigna la lectura del Excel a la variable "BBDD2"

BBDD2 <- read_excel(ruta_excel2)


#Se convierte en factor la variable respuesta, es decir, la lesividad

BBDD2$lesiv <- factor(BBDD2$lesiv)


#Para que los resultados sean replicables se añade la siguiente función

set.seed(2021)


#Se realiza una división o partición de los datos, dando lugar a una parte de entrenamiento (70%) y a otra de test (30%)

t.ind2 <- createDataPartition(BBDD2$lesiv, p=0.7, list=F)
test2 <- BBDD2[-t.ind2,]
training2 <- BBDD2[t.ind2,]


#Se crea el modelo de Random Forest y se le asigna a la variable "modelo2"

modelo2 <- randomForest(lesiv~., data = training2, mtry=4, ntree=200, maxnodes=1000, importance=TRUE)

#A continuación, se va a obtener información y varios resultados del modelo generado

#Resumen del modelo

print(modelo2)


#Realización de predicciones con el conjunto de datos dedicado a test

prediccionModelo2 <- predict(modelo2,test2)


#Matriz de confusión

confusionMatrix(prediccionModelo2,test2$lesiv)


#Importancia de cada variable de entrada en el modelo

importance(modelo2)


#Gráfico de la importancia de cada variable de entrada en el modelo

varImpPlot(modelo2)


#Gráfico del parámetro ntree vs error del modelo

plot(modelo2)

```

Figura 58. Código R del Modelo 2. (Diseño propio).

En tercer lugar, se muestra el código R implementado del *Modelo 3* (Fig. 59), que a su vez únicamente ve modificada la base de datos respecto a los dos modelos principales anteriores:

```r
#Librerías que se van a utilizar

library(caret)
library(readxl)
library(randomForest)


#Se asigna la ruta del Excel que se va a usar a la variable "ruta_excel3"

ruta_excel3 <- "C:\\Users\\juanh\\OneDrive\\Escritorio\\TFG\\BBDD utilizadas\\BBDD_variablesutilizadas_normalizadas_tratadas_equilibradas.xlsx"


#Se asigna la lectura del Excel a la variable "BBDD3"

BBDD3 <- read_excel(ruta_excel3)


#Se convierte en factor la variable respuesta, es decir, la lesividad

BBDD3$lesiv <- factor(BBDD3$lesiv)


#Para que los resultados sean replicables se añade la siguiente función

set.seed(2021)


#Se realiza una división o partición de los datos, dando lugar a una parte de entrenamiento (70%) y a otra de test (30%)

t.ind3 <- createDataPartition(BBDD3$lesiv, p=0.7, list=F)
test3 <- BBDD3[-t.ind3,]
training3 <- BBDD3[t.ind3,]


#Se crea el modelo de Random Forest y se le asigna a la variable "modelo3"

modelo3 <- randomForest(lesiv~., data = training3, mtry=4, ntree=200, maxnodes=1000, importance=TRUE)


#A continuación, se va a obtener información y varios resultados del modelo generado

#Resumen del modelo

print(modelo3)


#Realización de predicciones con el conjunto de datos dedicado a test

prediccionModelo3 <- predict(modelo3,test3)


#Matriz de confusión

confusionMatrix(prediccionModelo3,test3$lesiv)


#Importancia de cada variable de entrada en el modelo

importance(modelo3)


#Gráfico de la importancia de cada variable de entrada en el modelo

varImpPlot(modelo3)


#Gráfico del parámetro ntree vs error del modelo

plot(modelo3)

```

Figura 59. Código R del Modelo 3. (Diseño propio).

De aquí en adelante, se van a presentar los códigos R pertenecientes a los modelos extra que se han realizado en el proyecto a partir del *Modelo 3*.

Respecto a los modelos en los que se eliminan una o varias variables de entrada, la única modificación que se produce en ellos respecto al *Modelo 3* es que se dejan sin introducir dichas variables como parámetros del modelo generado, es decir, en la función *randomForest()* de R.

A continuación, se muestra el código R empleado (Fig. 60) cuando se omite la variable *Localización de las lesiones más graves* (*lesiones* en *RStudio*), siendo éste extensible para el resto de modelos de este tipo si se va dejando sin incluir una variable por cada uno de ellos.

```r
#Librerías que se van a utilizar

library(caret)
library(readxl)
library(randomForest)


#Se asigna la ruta del Excel que se va a usar a la variable "ruta_excelExtra"

ruta_excelExtra <- "C:\\Users\\juanh\\OneDrive\\Escritorio\\TFG\\BBDD utilizadas\\BBDD_variablesutilizadas_normalizadas_tratadas_equilibradas.xlsx"


#Se asigna la lectura del Excel a la variable "BBDDExtra"

BBDDExtra <- read_excel(ruta_excelExtra)


#Se convierte en factor la variable respuesta, es decir, la lesividad

BBDDExtra$lesiv <- factor(BBDDExtra$lesiv)


#Para que los resultados sean replicables se añade la siguiente función

set.seed(2021)


#Se realiza una división o partición de los datos, dando lugar a una parte de entrenamiento (70%) y a otra de test (30%)

t.indExtra <- createDataPartition(BBDDExtra$lesiv, p=0.7, list=F)
testExtra <- BBDDExtra[-t.indExtra,]
trainingExtra <- BBDDExtra[t.indExtra,]


#Se crea el modelo de Random Forest y se le asigna a la variable "modeloExtraSinLesiones"

modeloExtraSinLesiones <- randomForest(lesiv~defecto+condpsic+sexo+infveloc+infadm+infcond+estado+luminos+factatm+tipoacc_alc+tipoacc_frontal+
                                       tipoacc_frontolat+tipoacc_lat, data = trainingExtra, mtry=4, ntree=200, maxnodes=1000, importance=TRUE)

#A continuación, se va a obtener información y varios resultados del modelo generado

#Resumen del modelo

print(modeloExtraSinLesiones)


#Realización de predicciones con el conjunto de datos dedicado a test

prediccionModeloExtraSinLesiones <- predict(modeloExtraSinLesiones,testExtra)


#Matriz de confusión

confusionMatrix(prediccionModeloExtraSinLesiones,testExtra$lesiv)


#Importancia de cada variable de entrada en el modelo

importance(modeloExtraSinLesiones)


#Gráfico de la importancia de cada variable de entrada en el modelo

varImpPlot(modeloExtraSinLesiones)


#Gráfico del parámetro ntree vs error del modelo

plot(modeloExtraSinLesiones)

```

Figura 60. Código R cuando se elimina la variable Localización de las lesiones más graves (lesiones). (Diseño propio).

Por otro lado, se presenta el código empleado en el modelo en el que se eliminan las dos variables de mayor importancia según el *Mean Decrease Accuracy* (Disminución Media de la Precisión) (Fig. 61), siendo igualmente extensible al resto de algoritmos de los que se omiten dos variables.

```r
#Librerías que se van a utilizar

library(caret)
library(readxl)
library(randomForest)


#Se asigna la ruta del Excel que se va a usar a la variable "ruta_excelExtra"

ruta_excelExtra <- "C:\\Users\\juanh\\OneDrive\\Escritorio\\TFG\\BBDD utilizadas\\BBDD_variablesutilizadas_normalizadas_tratadas_equilibradas.xlsx"


#Se asigna la lectura del Excel a la variable "BBDDExtra"

BBDDExtra <- read_excel(ruta_excelExtra)


#Se convierte en factor la variable respuesta, es decir, la lesividad

BBDDExtra$lesiv <- factor(BBDDExtra$lesiv)


#Para que los resultados sean replicables se añade la siguiente función

set.seed(2021)


#Se realiza una división o partición de los datos, dando lugar a una parte de entrenamiento (70%) y a otra de test (30%)

t.indExtra <- createDataPartition(BBDDExtra$lesiv, p=0.7, list=F)
testExtra <- BBDDExtra[-t.indExtra,]
trainingExtra <- BBDDExtra[t.indExtra,]


#Se crea el modelo de Random Forest y se le asigna a la variable "modeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy"

modeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy <- randomForest(lesiv~defecto+condpsic+sexo+infveloc+infadm+estado+luminos+factatm+tipoacc_alc
                                                                     +tipoacc_frontal+tipoacc_frontolat+tipoacc_lat, data = trainingExtra, mtry=4,
                                                                     ntree=200, maxnodes=1000, importance=TRUE)


#A continuación, se va a obtener información y varios resultados del modelo generado

#Resumen del modelo

print(modeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy)


#Realización de predicciones con el conjunto de datos dedicado a test

prediccionModeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy <- predict(modeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy,testExtra)


#Matriz de confusión

confusionMatrix(prediccionModeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy,testExtra$lesiv)


#Importancia de cada variable de entrada en el modelo

importance(modeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy)


#Gráfico de la importancia de cada variable de entrada en el modelo

varImpPlot(modeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy)


#Gráfico del parámetro ntree vs error del modelo

plot(modeloExtraSin2VarsMasInfluenciaMeanDecreaseAccuracy)
```

Figura 61. Código R cuando se eliminan las dos variables de mayor importancia según el Mean Decrease Accuracy. (Diseño propio).

De igual manera, a continuación, se muestra el código R empleado cuando se eliminan las variables de entrada referidas a infracciones cometidas (Fig. 62). Este código puede extenderse también al modelo en el que se omiten las variables referidas al tipo de accidente producido, si se dejan sin introducir dichas variables en el algoritmo.

```r
#Librerías que se van a utilizar

library(caret)
library(readxl)
library(randomForest)


#Se asigna la ruta del Excel que se va a usar a la variable "ruta_excelExtra"

ruta_excelExtra <- "C:\\Users\\juanh\\OneDrive\\Escritorio\\TFG\\BBDD utilizadas\\BBDD_variablesutilizadas_normalizadas_tratadas_equilibradas.xlsx"


#Se asigna la lectura del Excel a la variable "BBDDExtra"

BBDDExtra <- read_excel(ruta_excelExtra)


#Se convierte en factor la variable respuesta, es decir, la lesividad

BBDDExtra$lesiv <- factor(BBDDExtra$lesiv)


#Para que los resultados sean replicables se añade la siguiente función

set.seed(2021)


#Se realiza una división o partición de los datos, dando lugar a una parte de entrenamiento (70%) y a otra de test (30%)

t.indExtra <- createDataPartition(BBDDExtra$lesiv, p=0.7, list=F)
testExtra <- BBDDExtra[-t.indExtra,]
trainingExtra <- BBDDExtra[t.indExtra,]


#Se crea el modelo de Random Forest y se le asigna a la variable "modeloExtraSinVarsDeTipoInfraccion"

modeloExtraSinVarsDeTipoInfraccion <- randomForest(lesiv~lesiones+defecto+condpsic+sexo+estado+luminos+factatm+tipoacc_alc+tipoacc_frontal+
                                                     tipoacc_frontolat+tipoacc_lat, data = trainingExtra, mtry=4, ntree=200,
                                                   maxnodes=1000, importance=TRUE)


#A continuación, se va a obtener información y varios resultados del modelo generado

#Resumen del modelo

print(modeloExtraSinVarsDeTipoInfraccion)


#Realización de predicciones con el conjunto de datos dedicado a test

prediccionModeloExtraSinVarsDeTipoInfraccion <- predict(modeloExtraSinVarsDeTipoInfraccion,testExtra)


#Matriz de confusión

confusionMatrix(prediccionModeloExtraSinVarsDeTipoInfraccion,testExtra$lesiv)


#Importancia de cada variable de entrada en el modelo

importance(modeloExtraSinVarsDeTipoInfraccion)


#Gráfico de la importancia de cada variable de entrada en el modelo

varImpPlot(modeloExtraSinVarsDeTipoInfraccion)


#Gráfico del parámetro ntree vs error del modelo

plot(modeloExtraSinVarsDeTipoInfraccion)

```

Figura 62. Código R cuando se eliminan las variables referidas a infracciones cometidas. (Diseño propio).

En otro aspecto, en el caso de los algoritmos en los que se produce una modificación del valor de alguno de sus parámetros más importantes (*Ntree* o *Mtry*), la única diferencia en el código usado respecto al *Modelo 3* es la asignación de un valor diferente para dicho parámetro al emplear la función *randomForest()*.

De esta forma, el código R empleado para el modelo en el que *Ntree* pasa a valer "quinientos" (*Ntree = 500*) es el siguiente (Fig. 63):

```r
#Librerías que se van a utilizar

library(caret)
library(readxl)
library(randomForest)


#Se asigna la ruta del Excel que se va a usar a la variable "ruta_excelExtra"

ruta_excelExtra <- "C:\\Users\\juanh\\OneDrive\\Escritorio\\TFG\\BBDD utilizadas\\BBDD_variablesutilizadas_normalizadas_tratadas_equilibradas.xlsx"


#Se asigna la lectura del Excel a la variable "BBDDExtra"

BBDDExtra <- read_excel(ruta_excelExtra)


#Se convierte en factor la variable respuesta, es decir, la lesividad

BBDDExtra$lesiv <- factor(BBDDExtra$lesiv)


#Para que los resultados sean replicables se añade la siguiente función

set.seed(2021)


#Se realiza una división o partición de los datos, dando lugar a una parte de entrenamiento (70%) y a otra de test (30%)

t.indExtra <- createDataPartition(BBDDExtra$lesiv, p=0.7, list=F)
testExtra <- BBDDExtra[-t.indExtra,]
trainingExtra <- BBDDExtra[t.indExtra,]


#Se crea el modelo de Random Forest y se le asigna a la variable "modeloExtraConNtree500"

modeloExtraConNtree500 <- randomForest(lesiv~lesiones+defecto+condpsic+sexo+infveloc+infadm+infcond+estado+luminos+factatm+tipoacc_alc+
                                         tipoacc_frontal+tipoacc_frontolat+tipoacc_lat, data = trainingExtra, mtry=4, ntree=500,
                                       maxnodes=1000, importance=TRUE)


#A continuación, se va a obtener información y varios resultados del modelo generado

#Resumen del modelo

print(modeloExtraConNtree500)


#Realización de predicciones con el conjunto de datos dedicado a test

prediccionModeloExtraConNtree500 <- predict(modeloExtraConNtree500,testExtra)


#Matriz de confusión

confusionMatrix(prediccionModeloExtraConNtree500,testExtra$lesiv)


#Importancia de cada variable de entrada en el modelo

importance(modeloExtraConNtree500)


#Gráfico de la importancia de cada variable de entrada en el modelo

varImpPlot(modeloExtraConNtree500)


#Gráfico del parámetro ntree vs error del modelo

plot(modeloExtraConNtree500)

```

Figura 63. Código R cuando se modifica el parámetro Ntree (Ntree = 500). (Diseño propio).

Por último, se presenta el código R usado cuando se modifica el parámetro *Mtry* y pasa a valer "cinco" (*Mtry = 5*) (Fig. 64), código que a su vez es extensible para el modelo en el que se convierte en "ocho" (*Mtry = 8*) si se modifica correctamente el valor de dicho parámetro dentro de la función *randomForest()*.

```r
#Librerías que se van a utilizar

library(caret)
library(readxl)
library(randomForest)


#Se asigna la ruta del Excel que se va a usar a la variable "ruta_excelExtra"

ruta_excelExtra <- "C:\\Users\\juanh\\OneDrive\\Escritorio\\TFG\\BBDD utilizadas\\BBDD_variablesutilizadas_normalizadas_tratadas_equilibradas.xlsx"


#Se asigna la lectura del Excel a la variable "BBDDExtra"

BBDDExtra <- read_excel(ruta_excelExtra)


#Se convierte en factor la variable respuesta, es decir, la lesividad

BBDDExtra$lesiv <- factor(BBDDExtra$lesiv)


#Para que los resultados sean replicables se añade la siguiente función

set.seed(2021)


#Se realiza una división o partición de los datos, dando lugar a una parte de entrenamiento (70%) y a otra de test (30%)

t.indExtra <- createDataPartition(BBDDExtra$lesiv, p=0.7, list=F)
testExtra <- BBDDExtra[-t.indExtra,]
trainingExtra <- BBDDExtra[t.indExtra,]


#Se crea el modelo de Random Forest y se le asigna a la variable "modeloExtraConMtry5"

modeloExtraConMtry5 <- randomForest(lesiv~lesiones+defecto+condpsic+sexo+infveloc+infadm+infcond+estado+luminos+factatm+tipoacc_alc+
                                      tipoacc_frontal+tipoacc_frontolat+tipoacc_lat, data = trainingExtra, mtry=5, ntree=200,
                                      maxnodes=1000, importance=TRUE)


#A continuación, se va a obtener información y varios resultados del modelo generado

#Resumen del modelo

print(modeloExtraConMtry5)


#Realización de predicciones con el conjunto de datos dedicado a test

prediccionModeloExtraConMtry5 <- predict(modeloExtraConMtry5,testExtra)


#Matriz de confusión

confusionMatrix(prediccionModeloExtraConMtry5,testExtra$lesiv)


#Importancia de cada variable de entrada en el modelo

importance(modeloExtraConMtry5)


#Gráfico de la importancia de cada variable de entrada en el modelo

varImpPlot(modeloExtraConMtry5)


#Gráfico del parámetro ntree vs error del modelo

plot(modeloExtraConMtry5)
```

Figura 64. Código R cuando se modifica el parámetro Mtry (Mtry = 5). (Diseño propio).